Предисловие

Данное учебное пособие написано на основе курса лекций по вычислительной математике, читаемого авторами в течение ряда лет студентам различных специальностей университета. В пособии в сжатом виде приводятся необходимые сведения о численных методах решения прикладных задач, возникающих при разработке и проектировании вычислительных систем. При отборе материала авторы в первую очередь руководствовались требованиями, предусмотренными программой курса «Вычислительная математика». Для понимания содержания всех разделов пособия достаточно знания основного курса высшей математики, читаемого в течение первых трех семестров обучения. Некоторые дополнительные понятия, используемые в основном тексте, приведены в первом разделе, носящем вспомогательный характер и содержащем необходимые для более ясного понимания численных методов сведения из математического и функционального анализа.

Как и всякое другое пособие по численным методам, эта книга содержит изложение основных положений теории, в данном случае относящихся к решению алгебраических уравнений и систем, а также методам приближения функций. Второй раздел пособия целиком посвящен методам решения задач линейной алгебры. Способы решения нелинейных уравнений приведены в третьем разделе; в четвертом обсуждаются наиболее распространенные методы интерполяции и аппроксимации функций.

Следует иметь в виду, что материал пособия включает отдельные, вызывающие наибольшую трудность при обучении, вопросы программы, и, тем самым, не исчерпывает полностью содержание курса «Вычислительная математика». Среди существующей учебной литературы наибольшей полнотой изложения вычислительных методов отличается двухтомник [1], достаточно подробное описание содержится в стандартных учебниках [2–3]. С отдельными вопросами курса можно более детально ознакомиться по специализированным

учебным пособиям [4–8], каждое из которых целиком посвящено тому или разделу вычислительной математики.

Данное пособие должно служить основой для последующего более глубокого изучения численных методов и их применения в различных технических задачах.

1. АНАЛИТИЧЕСКИЕ ОСНОВЫ ЧИСЛЕННЫХ МЕТОДОВ

Прежде, чем переходить к непосредственному изложению, попытаемся определить место теории численных методов при решении определенной научно–исследовательской задачи. Как правило, в реальной ситуации явное (аналитическое) решение задачи найти невозможно – не потому, что мы не умеем его искать, а потому, что ответ не выражается через привычные функции: элементарные или известные специальные. При этом развитие одной лишь вычислительной техники не снимает проблемы: любая ЭВМ может выполнить определенную последовательность простейших арифметических и логических операций и не более того. Численные методы – это и есть методы решения задач, сводящиеся в конечном итоге к действиям, которые выполняет ЭВМ. В зависимости от конкретной ситуации исследователю приходится выбирать тот или иной численный метод из числа имеющихся или разрабатывать новый, учитывающий особую специфику задачи. Выбирая (или предлагая новый) численный метод нужно знать о его преимуществах и недостатках по сравнению с другими; убедиться в его сходимости и устойчивости; определить число необходимых операций и размеры требующейся памяти ЭВМ. Как правило, ответы на эти вопросы, являющиеся частью вычислительной математики, находятся аналитически. Тем самым вычислительная математика по своему построению и используемому аппарату ближе к традиционному математическому анализу и алгебре, чем, например, к программированию. Кроме этого, любой численный метод не зависит от того, на каком из языков программирования и на какой ЭВМ будет реализован алгоритм (за исключением, быть может, развивающихся в последнее время

методов параллельных вычислений, предусматривающих одновременную работу нескольких процессоров). Поэтому в данном пособии основное внимание уделяется описанию метода, доказательству его корректности, анализу работы метода и априорному оцениванию возникающих погрешностей.

1.1 Погрешности численного решения

Решение, полученное численным способом, всегда является приближенным. Источников погрешности приближенного решения несколько: это, во-первых, несоответствие математической модели изучаемому реальному явлению и погрешности исходных данных; во-вторых, погрешности численного метода решения; и, в-третьих, погрешности округлений при выполнении арифметических и других действий над числами.

Погрешность, обусловленную неадекватностью математической модели и погрешностью входных параметров, называют неустранимой погрешностью. Оценку влияния такой погрешности можно получить, решая задачу с различными начальными данными в пределах погрешности и сравнивая полученные результаты.

Численные методы сами по себе являются в большинстве случаев приближенными. Даже при точных начальных данных и сколь угодно точных вычислениях решение исходной задачи получается с некоторой погрешностью, называемой погрешностью численного метода. Такая погрешность появляется, когда метод основывается на некотором бесконечном сходящемся процессе, который при вычислениях обрывается на некотором шаге, либо, когда численным методом решается не исходная задача, а более простая, ее аппроксимирующая. Анализ или оценку погрешности метода иногда удается провести аналитическими средствами, выразив ее через известные величины (например, число итераций или шаг при использовании сеточных методов). Это позволяет при вычислениях эффективно управлять погрешностью метода, делая ее меньшей, чем неустранимая погрешность.

Намного более сложным является учет погрешности округления в арифметических действиях – вычислительной погрешности. Анализ вычислительной погрешности необходим, когда решение задачи на ЭВМ требует большого числа операций, например, при решении уравнений с частными производными. Причем в этой ситуации оказывается, что учитывать влияние погрешности округления в каждом действии нереально, и, кроме того, даже если такой учет и провести – получится слишком завышенная оценка погрешности. К сожалению, эффективно применяемые оценки вычислительной погрешности на основе статистического анализа влияния округлений требуют глубокого понимания теории систем случайных величин, и поэтому их описание далеко выходит за рамки настоящего пособия.

Для успешного применения численного метода необходимо, чтобы его собственная погрешность была в несколько раз меньше неустранимой погрешности, а вычислительная погрешность, в свою очередь, в несколько раз меньше погрешности метода.

1.2 Метрическое пространство.

В результате решения задачи численным методом мы хотим получить результат, который был бы близок к точному ответу. Что такое «близко»? Очевидно, для двух чисел x_1 и x_2 надо требовать малости $|x_2 - x_1|$; близость же двух векторов или функций можно определить разными способами. Эти вопросы рассматриваются в функциональном анализе, некоторые основные понятия которого будут сейчас изложены.

Множество M элементов произвольной природы (векторов, функций и т. п.) называется метрическим пространством, если в нем определена числовая функция $\rho(x,y)$ для каждой пары элементов x и y из M, называемая расстоянием или метрикой и удовлетворяющая следующим аксиомам:

1. Положительность: $\rho(x,y) \geq 0$, причем $\rho(x,y) = 0$ тогда и только тогда, когда $x = y$.

2. Симметричность $\rho(x,y)=\rho(y,x)$. (1.1)

3. Неравенство треугольника

$\rho(x,y)\le\rho(x,z)+\rho(y,z)$, $\forall x,y,z\in M$.

Эти аксиомы выполнены, разумеется, для обычного евклидова расстояния в пространстве n – мерных векторов R^n:

$$\rho(\mathbf{x},\mathbf{y})=\sqrt{\sum_{k=1}^{n}(x_k-y_k)^2}. \quad (1.2)$$

Соответственно, любое подмножество пространства R^n, снабженное метрикой (1.2), будет метрическим пространством. Например, замкнутый шар $B_r(\mathbf{a})=\{\mathbf{x}: \rho(\mathbf{x},\mathbf{a})\le r\}$ часто будет рассматриваться как метрическое пространство. Другие примеры будут приведены в следующем подразделе.

1.3 Линейное нормированное пространство.

Часто множество M, в котором ищется возможное решение задачи, является линейным пространством, когда в M определены сложение элементов и умножение их на действительные числа, не выводящие за пределы M. Более строго, M – линейное пространство, если выполнены следующие условия (здесь α, β – числа; f, g, h – элементы M):

1. $f+g\in M$
2. $\alpha f\in M$
3. $f+g=g+f$
4. $(f+g)+h=f+(g+h)$
5. Существует нулевой элемент $0\in M$, такой что (1.3)
   $f+0=f$
6. $0\cdot f=0$
7. $(\alpha+\beta)f=\alpha f+\beta f$
8. $\alpha(f+g)=\alpha f+\alpha g$
9. $\alpha(\beta f)=(\alpha\beta)f$

10.1· $f = f$

Из функциональных пространств чаще всего мы будем иметь дело с линейным пространством непрерывных на интервале $[a,b]$ функций, которое обозначается $C_{[a,b]}$. Функция $f(x)$ принадлежит $C_{[a,b]}$, если она определена на отрезке $[a,b]$, и существует функция $f^*(x)$, заданная на $(a-\varepsilon_1, b+\varepsilon_2)$ при $\varepsilon_{1,2}>0$, непрерывная на этом интервале и совпадающая с $f(x)$ на $[a,b]$. Выполнение аксиом (1.3) для пространства $C_{[a,b]}$ достаточно очевидно; роль нулевого элемента, разумеется, играет функция, тождественно равная нулю на интервале $[a,b]$. Аналогичным образом определяется $C^k_{[a,b]}$ – пространство k раз непрерывно дифференцируемых функций на интервале $[a,b]$.

Линейное пространство называется нормированным пространством, если каждому элементу f поставлено в соответствие действительное число $\|f\|$, которое называется нормой f и должно удовлетворять аксиомам нормы:

1. $\|f\| \geq 0$, причем $\|f\| = 0$ тогда и только тогда, когда $f = 0$, т.е. f является нулевым элементом линейного пространства.
2. $\|\alpha f\| = |\alpha| \|f\|$.
3. $\|f + g\| \leq \|f\| + \|g\|$ – неравенство треугольника для нормы.

В одном и том же линейном пространстве норму можно вводить разными способами. Рассмотрим это на примере пространства $C_{[a,b]}$.

В качестве нормы в $C_{[a,b]}$ можно взять максимальное отклонение функции от нуля:

$$\|f\|_C = \max_{[a,b]} |f(x)|. \quad (1.4)$$

Выполнение первых двух аксиом для нормы (1.4) очевидно, а неравенство треугольника следует из теоремы Вейерштрасса для непрерывных функций о существовании точки x^*, в которой достигается максимум функции, в частности, $\max|f(x)+g(x)|$. Тогда

$$\|f + g\|_C = \max_{[a,b]} |f(x) + g(x)| = |f(x^*) + g(x^*)| \leq |f(x^*)| + |g(x^*)| \leq$$
$$\leq \max_{[a,b]} |f(x)| + \max_{[a,b]} |g(x)| = \|f\|_C + \|g\|_C$$

Другой способ задания нормы в $C_{[a,b]}$ получается, если взять среднеквадратичное отклонение функции на интервале $[a,b]$:

$$\|f\|_{L_2} = \left(\int_a^b |f(x)|^2 \, \mathrm{d}x \right)^{1/2}. \quad (1.5)$$

Выполнение аксиом нормы в этом случае следует из соответствующих свойств интеграла. Выбор той или иной нормы часто определяется конкретными условиями задачи. Например, при рассмотрении равномерного приближения функции необходимо пользоваться нормой (1.4), а при приближении методом наименьших квадратов разумно взять норму (1.5). Отметим, что любое линейное нормированное пространство является метрическим, поскольку в качестве расстояния можно взять норму разности:

$$\rho(f,g) = \|f-g\|. \quad (1.6)$$

В этом случае говорят, что метрика индуцируется нормой. Аксиомы расстояния 1 и 2 выполняются в силу аксиом 1, 2 нормы, а неравенство треугольника для расстояния следует из неравенства треугольника для нормы:

$$\rho(f,g) = \|f-g\| = \|(f-h)+(h-g)\| \le \|f-h\| + \|h-g\| = \rho(f,h) + \rho(h,g).$$

В соответствии с этим пространство $C_{[a,b]}$ является метрическим пространством с равномерной $\rho_C(f,g) = \|f-g\|_C$ либо среднеквадратичной $\rho_{L_2}(f,g) = \|f-g\|_{L_2}$ метрикой.

1.4. Вычислительные погрешности

Пусть x – точное, вообще говоря, неизвестное решение задачи в некотором линейном нормированном пространстве; x^*– найденное приближенным методом численное решение. Величина

$$\Delta(x^*) = \|x - x^*\|$$

называется абсолютной погрешностью приближенного решения x^*; а величина

$$\delta(x^*) = \frac{\Delta(x^*)}{\|x^*\|}$$

называется его относительной грешностью. Точное значение погрешности, разумеется, также неизвестно, как и точное решение *x*. Можно ввести предельную погрешность, которая оценивала бы наверняка погрешность вычислений. Любые два числа $\overline{\Delta(x)}$ и $\overline{\delta(x)}$, которые оценивают, соответственно, погрешности $\Delta(x)$ и $\delta(x)$:

$$\Delta(x) \le \overline{\Delta(x)}, \qquad \delta(x) \le \overline{\delta(x)}$$

называются предельной абсолютной и относительной погрешностью. В простейших ситуациях, например, когда речь идет об арифметических операциях над числами, учет погрешности можно провести в явной форме. Очевидно, если *c*=*a*+*b*, то

$$\Delta(c^*) \le \Delta(a^*) + \Delta(b^*)$$

и, следовательно, в качестве предельной погрешности можно взять сумму

$$\overline{\Delta(c^*)} = \overline{\Delta(a^*)} + \overline{\Delta(b^*)}.$$

Таким образом, при сложении (и, аналогично, вычитании) двух чисел их абсолютные предельные погрешности складываются.

Пусть $c = a \cdot b$, $c^* = a^* \cdot b^*$. Тогда

$$\Delta(c) = \left| c - c^* \right| = \left| a \cdot b - a^* \cdot b^* \right| = \left| a \cdot b - a \cdot b^* + a \cdot b^* - a^* \cdot b^* \right| \le$$
$$\le |a| \cdot \left| b - b^* \right| + \left| b^* \right| \cdot \left| a - a^* \right| = \left| a - a^* + a^* \right| \cdot \left| b - b^* \right| + \left| b^* \right| \cdot \left| a - a^* \right| \le$$
$$\le \left| a^* \right| \cdot \left| b - b^* \right| + \left| b^* \right| \cdot \left| a - a^* \right| + \left| a - a^* \right| \cdot \left| b - b^* \right|.$$

Поскольку обычно погрешность значительно меньше абсолютного значения числа, последним слагаемым можно пренебречь, записав

$$\overline{\Delta(c)} \approx \left| a^* \right| \cdot \overline{\Delta(b)} + \left| b^* \right| \cdot \overline{\Delta(a)}.$$

В случае произведения двух приближенных чисел удобнее перейти к относительной погрешности

$$\overline{\delta(c)} \approx \frac{\left| a^* \right| \cdot \overline{\Delta(b)} + \left| b^* \right| \cdot \overline{\Delta(a)}}{\left| a^* \right| \cdot \left| b^* \right|} \approx \frac{\overline{\Delta(a)}}{\left| a^* \right|} + \frac{\overline{\Delta(b)}}{\left| b^* \right|} = \overline{\delta(a)} + \overline{\delta(b)}.$$

Аналогичный результат получается и в случае деления. Итак, при умножении и делении складываются предельные относительные погрешности приближенных чисел. Получение оценок погрешности в более сложных

ситуациях не столь очевидно и требует применения специальных методов, различных для различных задач. Они будут изложены в соответствующих разделах пособия при анализе уже конкретных вычислительных процедур.

1.5 Пространство со скалярным произведением

Рассмотрим линейное пространство E. Говорят, что в линейном пространстве введено скалярное произведение, если каждой паре f и g элементов из E поставлено в соответствие действительное число $\langle f, g\rangle$, называемое скалярным произведением элементов f и g, которое удовлетворяет следующим аксиомам скалярного произведения:

1. $\langle f, g\rangle=\langle g, f\rangle$.
2. $\langle f, f\rangle\geq 0$, причем $\langle f, f\rangle=0$ тогда и только тогда, когда $f=0$.
3. $\langle \alpha f, g\rangle= \alpha\langle f, g\rangle$.
4. $\langle f_1+f_2, g\rangle=\langle f_1, g\rangle+\langle f_2, g\rangle$.

Линейное пространство со скалярным произведением называется евклидовым пространством. В дальнейшем мы будем пользоваться двумя конкретными евклидовыми пространствами. Первое – пространство непрерывных на отрезке $[a,b]$ функций со скалярным произведением

$$\langle f, g\rangle = \int_a^b f(x)g(x)\,\mathrm{d}x. \quad (1.7)$$

Второе – линейное пространство E_{n+1} функций, заданных на дискретном множестве точек x_0, x_1, …, x_n некоторого отрезка $[a,b]$ со скалярным произведением

$$\langle f, g\rangle = \frac{1}{n+1}\sum_{k=0}^{n} f(x_k)g(x_k). \quad (1.8)$$

В последнем случае функцию $f \in E_{n+1}$ можно считать $(n+1)$ – мерным вектором, соответственно, пространство E_{n+1} эквивалентно пространству векторов. Убедимся, что (1.7) является скалярным произведением в $C_{[a,b]}$.

Выполнение аксиомы 1 очевидно, проверка аксиом 3 и 4 проводится с помощью свойства линейности интеграла (1.7). Проверим вторую аксиому:

предположим, что ‹ f, f›=0, т. е. $\int_a^b f^2(x)\,\mathrm{d}x = 0$ и допустим, что $f \neq 0$ (функция $f(x)$ не равна тождественно нулю на $[a,b]$). Тогда в силу непрерывности $f(x)$ найдется отрезок $[\alpha,\beta] \subset [a,b]$, на котором $f^2(x)>0$. Обозначим $m = \min\limits_{x\in[\alpha,\beta]} f^2(x)$, $m>0$. Теперь можно получить оценку

$$\int_a^b f^2(x)\,\mathrm{d}x \geq \int_\alpha^\beta f^2(x)\,\mathrm{d}x \geq m(\beta-\alpha) > 0,$$

которая противоречит допущению. Следовательно, $f(x)=0$.

Отметим, что всякое евклидово пространство всегда является линейным нормированным пространством с нормой

$$\|f\| = \sqrt{\langle f, f\rangle} \quad (1.9)$$

и, следовательно, метрическим пространством с расстоянием

$$\rho(f,g) = \|f-g\| = \sqrt{\langle f-g, f-g\rangle}. \quad (1.10)$$

Для нормы, заданной по формуле (1.9) через скалярное произведение, выполнены все три аксиомы нормы. Проверка первых двух аксиом не вызывает затруднений. Для того, чтобы убедиться в выполнении неравенства треугольника необходимы предварительные рассуждения. Любое скалярное произведение удовлетворяет соотношению

$$\langle f,g\rangle \leq \sqrt{\langle f,f\rangle\cdot\langle g,g\rangle}, \quad (1.11)$$

которое следует из положительности. Действительно, рассмотрим элемент $f+\alpha g$ с произвольным числом α и вычислим

$$\langle f+\alpha g, f+\alpha g\rangle = \langle f,f\rangle + 2\alpha\langle f,g\rangle + \alpha^2\langle g,g\rangle. \quad (1.12)$$

Получившееся выражение не может быть отрицательным ни при каких α; следовательно, если рассматривать (1.12) как квадратичный трехчлен по α, его дискриминант должен быть отрицательным

$$\langle f,g\rangle^2 - \langle f,f\rangle\cdot\langle g,g\rangle < 0,$$

откуда (1.11) немедленно следует. Теперь можно непосредственным вычислением проверить неравенство треугольника:

$$\|f+g\| = \sqrt{\langle f+g, f+g\rangle} = \sqrt{\langle f, f\rangle + 2\langle f, g\rangle + \langle g, g\rangle} \le$$
$$\le \sqrt{\|f\|^2 + 2\|f\|\cdot\|g\| + \|g\|^2} = \sqrt{(\|f\|+\|g\|)^2} = \|f\|+\|g\|.$$

Таким образом, (1.9) действительно задает норму в пространстве со скалярным произведением.

1.6 Полнота метрических пространств

При решении многих задач численный ответ ищется итерационными способами, когда искомый результат x (элемент некоторого метрического пространства M) представляется в виде предела последовательных приближений x_n. Поскольку осуществить явно предельный переход, как правило, не удается, вычисления прерывают при достижении требуемой точности, когда $\rho(x,x_n)<\varepsilon$. При таком методе решения необходимо быть уверенным, что, во-первых, последовательность x_n действительно сходится к некоторому элементу x и, во-вторых, что этот элемент x принадлежит исходному пространству M, в котором ищется решение. Будем называть последовательность элементов $\{x_n\}$ метрического пространства M сходящейся к элементу x, если $x \in M$ и (как в обычном анализе) $\rho(x_n, x) \underset{n\to\infty}{\to} 0$. Последовательность $\{x_n\}$, удовлетворяющую условию

$$\rho(x_n, x_m) \underset{n,m\to\infty}{\to} 0,$$

будем называть последовательностью, сходящейся в себе, или последовательностью Коши. Как известно из курса высшей математики, всякая числовая последовательность Коши является сходящейся. К сожалению, последовательность Коши элементов произвольного метрического пространства не всегда является сходящейся. Это связано с тем, что предельный элемент, к которому сходится последовательность, может не принадлежать исходному пространству M. Так, в пространстве непрерывных

функций $C_{[-1,1]}$ со среднеквадратичной метрикой $\rho_2(x,y)=\int\limits_{-1}^{1}|x(t)-y(t)|^2\,\mathrm{d}t$ сходящаяся в себе последовательность

$$x_n(t)=\begin{cases} 0 & , \quad -1\le t\le -\dfrac{1}{n} \\ 1+nt & , \quad -\dfrac{1}{n}<t\le 0 \\ 1 & , \quad 0<t\le 1 \end{cases}$$

стремится к функции, имеющей разрыв в точке t=0, т. е. не являющейся непрерывной.

Определение. Метрическое пространство, в котором всякая последовательность Коши имеет предел, называется полным метрическим пространством.

Как ясно из приведенного выше примера пространство $C_{[a,b]}$ с метрикой ρ_2 не является полным метрическим пространством. Чтобы можно было рассматривать всевозможные сходящиеся последовательности непрерывных функций, пространство $C_{[a,b]}$ необходимо дополнить всеми функциями, которые являются пределами сходящихся в себе последовательностей. Такое полное пространство функций обозначается $L_2(a,b)$ и состоит из всех функций (не обязательно непрерывных), для которых конечен интеграл

$$\int\limits_a^b |f(x)|^2\,\mathrm{d}x<+\infty. \quad (1.13)$$

В пространстве L_2 функции $f_1(x)$ и $f_2(x)$ не различаются, если

$$\int\limits_a^b |f_1(x)-f_2(x)|^2\,\mathrm{d}x=0, \quad (1.14)$$

тем самым элемент пространства L_2 – это класс эквивалентных в смысле (1.14) функций, из которого можно выбирать любого представителя, т. е. некоторую функцию. Отметим, что пространство непрерывных функций $C_{[a,b]}$ с метрикой $\rho_c=\max\limits_t|x(t)-y(t)|$ является полным пространством. Действительно, сходимость в пространстве (C,ρ_c) представляет собой равномерную сходимость:

$\lim\limits_{n\to\infty}\max\limits_t|x(t)-x_n(t)|=0$ означает $\forall\varepsilon>0\quad \exists N_\varepsilon:\forall n>N_\varepsilon,\quad \forall t\in[a,b]\Rightarrow\quad |x(t)-x_n(t)|<\varepsilon$;

а равномерно сходящаяся последовательность непрерывных функций имеет своим пределом непрерывную функцию.

Полнота функционального пространства особенно важна для сходимости вычислительной процедуры. Основным инструментом доказательства сходимости во многих случаях является следующая теорема.

Принцип сжимающих отображений. (*Терема Банаха*).

Пусть M – полное метрическое пространство; φ – отображение M в себя и, кроме того, φ – сжимающее отображение с показателем $\alpha<1$:

$$\rho(\varphi(x), \varphi(y)) \le \alpha\, \rho(x, y). \quad (1.15)$$

Тогда у отображения $\varphi(x)$ есть единственная неподвижная точка x^*: $x^*=\varphi(x^*)$, к которой сходятся последовательные приближения $x_{k+1}= \varphi(x_k)$, начиная с любого $x_0 \in M$, и выполнены следующие оценки:

$$\rho(x_k, x^*) \le \alpha^k\, \rho(x_0, x^*), \quad (1.16)$$

$$\rho(x_k, x^*) \le \frac{\alpha}{1-\alpha} \rho(x_k, x_{k-1}). \quad (1.17)$$

Доказательство теоремы Банаха проведем в несколько этапов. В начале убедимся в единственности неподвижной точки. Предположим, что есть две неподвижные точки $x=\varphi(x)$ и $y=\varphi(y)$. Тогда $\rho(x,y)=\rho(\varphi(x),\varphi(y))\le\alpha\rho(x,y)$. Учитывая условия $\alpha<1$ и $\rho(x,y)\ge0$, заключаем, что $\rho(x,y)=0$. Таким образом, $x=y$. Для доказательства существования неподвижной точки покажем, что $\{x_k\}_{k=0}^{\infty}$, $x_k= \varphi(x_{k-1})$ – последовательность Коши:

$$\rho(x_k, x_{k+1}) = \rho(\varphi(x_{k-1}), \varphi(x_k)) \le \alpha\, \rho(x_{k-1}, x_k) \le \alpha^2 \rho(x_{k-2}, x_{k-1}) \le \ldots \le \alpha^k \rho(x_0, x_1).$$

Таким образом, при $n>m$ и $m\to\infty$

$$\rho(x_n, x_m) \le \sum_{j=m+1}^{n} \rho(x_j, x_{j-1}) \le \frac{\alpha^m}{1-\alpha} \rho(x_0, x_1) \to 0.$$

Поскольку M – полное пространство, последовательность Коши $\{x_n\}$ имеет предел x^*, для которого выполнено соотношение

$$x^* = \lim_{n\to\infty} x_n = \lim_{n\to\infty} \varphi(x_{n-1}) = \varphi(\lim_{n\to\infty} x_n) = \varphi(x^*),$$

т. е. $x^*=\varphi(x^*)$ – неподвижная точка отображения φ.

Первое из написанных неравенств (1.16) получается из условия сжимаемости отображения φ с учетом неподвижности точки x^*:

$$\rho(x_k, x^*) = \rho\big(\varphi(x_{k-1}), \varphi(x^*)\big) \le \alpha\,\rho(x_{k-1}, x^*) \le \alpha^2 \rho(x_{k-2}, x^*) \le \ldots \le \alpha^k \rho(x_0, x^*).$$

Для проверки неравенства (1.17) воспользуемся третьей аксиомой нормы

$$\rho(x_k, x^*) \le \rho(x_k, x_{k+1}) + \rho(x_{k+1}, x^*) \le \alpha\rho(x_k, x_{k-1}) + \alpha\,\rho(x_k, x^*).$$

Окончательно получаем

$$(1-\alpha)\rho(x_k, x^*) \le \alpha\rho(x_k, x_{k-1}),$$

откуда (1.17) немедленно следует.

Замечания к теореме Банаха.

1. Для применения теоремы следует учитывать, что M – именно метрическое (не обязательно линейное) пространство. В ряде случаев M может быть замкнутым множеством, например, шаром $B_r(a)$.

2. Для получения оценки погрешности в процессе вычислений отдают предпочтение неравенству (1.16), правая часть которого выражается только через известные уже на k – м шаге величины. Оно является достаточно точным, поскольку автоматически учитывает возможность убывания погрешности на некоторых промежуточных итерациях быстрее, чем в α раз.

3. Даже в тех случаях, когда отображение является сжимающим во всем линейном пространстве, полезно выделить замкнутое множество (например, шар радиуса r), которое переходит в себя после отображения φ. Тогда можно оценить расстояние от нулевого приближения до искомого решения

$$\rho(x_0, x^*) \le 2r$$

и сделать эффективной оценку (1.16):

$$\rho(x_k, x^*) \le \alpha^k \cdot 2r;$$

это позволяет приближенно оценить число итераций, необходимых для достижения требуемой точности решения.

2. ЧИСЛЕННЫЕ МЕТОДЫ ЛИНЕЙНОЙ АЛГЕБРЫ

Задачи линейной алгебры являются наиболее распространенными вычислительными задачами. Во-первых, к таким задачам напрямую сводится анализ многих вычислительных систем в линейном приближении. Во-вторых, численное решение других собственно математических задач, таких как численное интегрирование уравнений в частных производных или задач приближения функций, включает в себя решение алгебраических задач.

К численным методам линейной алгебры относятся численные методы решения систем линейных алгебраических уравнений вида $\mathbf{Ax}=\mathbf{b}$; обращения матриц, вычисления определителей $det\mathbf{A}$ и нахождения всех или отдельных собственных значений λ_k и собственных векторов $\mathbf{e}_k$ симметричных матриц $\mathbf{Ae}_k=\lambda_k\mathbf{e}_k$.

Методы, применяемые при решении задач линейной алгебры, можно разделить на две группы. К первой группе принадлежат так называемые точные или прямые методы. Алгоритмы прямых методов позволяют найти решение системы за конечное число арифметических действий. При условии идеально точных вычислений и начальных данных найденное решение будет точным, но реально, разумеется, даже «точный» метод дает приближенное решение, поэтому правильнее называть его прямым. Из прямых методов мы рассмотрим метод Гаусса (метод LU – разложений) и метод прогонки.

Вторую группу методов составляют приближенные методы, в частности, итерационные методы решения систем, когда результат получается в виде последовательных приближений, сходящихся в пределе к точному решению. Решение, найденное таким способом, заведомо не является точным, но за счет увеличения числа итераций можно достичь достаточно хорошего приближения. Наиболее распространенным приближенными методами являются метод простой итерации и метод Зейделя.

При выборе того или иного метода следует обязательно учитывать специфику конкретной задачи. Так, помимо общих методов для произвольных матриц, существует большое число разнообразных методов для матриц специального вида. Например, для ленточных матриц целесообразно применять

метод прогонки; специальные методы разработаны для матриц с теплицевой структурой.

Требования, предъявляемые к алгоритмам численного решения задач линейной алгебры, разумеется такие же, как и для любых других вычислительных процедур. Но при работе с матрицами, особенно больших размеров, необходимо уделять внимание числу выполняемых арифметических операций и размеру необходимой памяти ЭВМ, а также оценке погрешности, возникающей при округлении вычислений. Так, в ЭВМ никогда не применяют правило Крамера, поскольку, во-первых, оно требует значительно большего числа операций по сравнению со всеми другими методами, и, во-вторых, вычисление определителя по формуле Крамера содержит вычитания очень больших по абсолютной величине, но близких чисел, что приводит к недопустимой погрешности.

Оценка числа необходимых арифметических операций получается, как правило, простым вычислением и будет приведена во всех рассматриваемых методах. Несколько сложнее дело обстоит с определением погрешности. Оценку влияния неустранимой погрешности на конечный результат мы получим в следующем подразделе, где рассматривается число обусловленности – мера чувствительности системы к возмущению начальных данных. Что же касается вычислительной погрешности, то строгий учет предельных абсолютных погрешностей на каждом шаге дает заведомо завышенную грубую оценку. Мы лишь упомянем существование вероятностных методов определения погрешности при матричных вычислениях, поскольку их подробное изложение требует применения аппарата математической статистики.

2.1 Норма и число обусловленности матрицы

В линейном пространстве R^n векторов $\mathbf{x}=(x_1, x_2,\ldots, x_n)$ можно вводить различные нормы (см. раздел 1). Наиболее употребительны из них две:

$$\|\mathbf{x}\|_1 = \max_{1\le j\le n}|x_j|, \quad (2.1)$$

$$\|\mathbf{x}\|_2 = \sqrt{\langle \mathbf{x},\mathbf{x}\rangle} = \sqrt{\sum_{i=1}^{n} x_i^2}. \quad (2.2)$$

Нормы (2.1) и (2.2) являются эквивалентными:

$$\|\mathbf{x}\|_1 \le \|\mathbf{x}\|_2 \le \sqrt{n}\|\mathbf{x}\|_1.$$

В пространстве квадратных матриц размером $n\times n$ также можно различными способами определить норму, удовлетворяющую требуемым аксиомам. Остановимся на одном из способов, когда норма матрицы вводится так называемым согласованным образом. А именно, определим норму $\|\mathbf{A}\|$:

$$\|\mathbf{A}\| = \underset{\mathbf{x}\ne 0}{Sup}\frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}, \quad (2.3)$$

где $\|\mathbf{x}\|$, $\|\mathbf{Ax}\|$ – одна из введенных норм (2.1, 2.2) в пространстве векторов. Пусть **A**, **B** – две квадратные числовые матрицы размером $n\times n$, **A+B** – их сумма. Тогда

$$\|\mathbf{A}+\mathbf{B}\| = \underset{\mathbf{x}\ne 0}{Sup}\frac{\|(\mathbf{A}+\mathbf{B})\mathbf{x}\|}{\|\mathbf{x}\|} \le \underset{x\ne 0}{Sup}\frac{\|\mathbf{Ax}\|+\|\mathbf{Bx}\|}{\|\mathbf{x}\|} \le$$

$$\le \underset{x\ne 0}{Sup}\frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} + \underset{x\ne 0}{Sup}\frac{\|\mathbf{Bx}\|}{\|\mathbf{x}\|} = \|\mathbf{A}\|+\|\mathbf{B}\|.$$

Таким образом, неравенство треугольника для согласованной матричной нормы (2.3) выполнено. Справедливость остальных матричных норм очевидна.

Рассмотрим первую из введенных норм $\|\mathbf{A}\|_1 = \underset{x\ne 0}{Sup}\|\mathbf{Ax}\|_1/\|\mathbf{x}\|_1$. Легко вычислить, что

$$\|\mathbf{A}\|_1 = \underset{x\ne 0}{Sup}\left(\max_i\left|\sum_{k=1}^{n} a_{ik}x_k\right|\right)\Big/\max_i|x_i| \le \max_k\left(\sum_{k=1}^{n}|a_{ik}|\right)\cdot\max_k|x_k|\Big/\max_i|x_i| = \max_i\left(\sum_{k=1}^{n}|a_{ik}|\right). \quad (2.4)$$

С другой стороны, если в качестве вектора **x** взять вектор с компонентами $x_k=Sign(a_{ik})$ (т.е. с компонентами, равными ±1 в зависимости от знака a_{ik}), то (2.4) обратится в равенство. Тем самым доказано, что

$$\|\mathbf{A}\|_1 = \max_i\left(\sum_{k=1}^{n}|a_{ik}|\right). \quad (2.5)$$

Вторая из введенных норм также допускает оценку

$$\|\mathbf{A}\|_2 \le \left(\sum_{i=1}^{n}\sum_{k=1}^{n} a_{ik}^2\right)^{1/2}, \quad (2.6)$$

но вектора **x**, на котором (2.6) обращалось бы в равенство, не существует, поэтому явного выражения для нормы $\|\mathbf{A}\|_2$ в случае произвольной матрицы нет. Лишь в случае, когда матрица **A** симметричная ($\mathbf{A}^T=\mathbf{A}$), норма $\|\mathbf{A}\|_2$ совпадает с максимальным по модулю собственным числом:

$$\|\mathbf{A}\|_2 = |\lambda|_{\max}(\mathbf{A}). \quad (2.7)$$

По определению нормы для любого **x** имеем

$$\|\mathbf{Ax}\| \le \|\mathbf{A}\| \cdot \|\mathbf{x}\|, \quad (2.8)$$

поэтому для любых матриц **A** и **B** выполнено

$$\|\mathbf{ABx}\| \le \|\mathbf{A}\| \cdot \|\mathbf{Bx}\| \le \|\mathbf{A}\| \cdot \|\mathbf{B}\| \cdot \|\mathbf{x}\|$$

и, следовательно,

$$\|\mathbf{A}^2\mathbf{x}\| \le \|\mathbf{A}\|^2 \cdot \|\mathbf{x}\|, \ldots, \|\mathbf{A}^k\mathbf{x}\| \le \|\mathbf{A}\|^k \cdot \|\mathbf{x}\|,$$

т.е.

$$\|\mathbf{A}^k\| \le \|\mathbf{A}\|^k. \quad (2.9)$$

Перейдем к анализу влияния погрешности начальных данных на погрешность решения. Рассмотрим систему линейных алгебраических уравнений с невырожденной матрицей

$$\mathbf{Ax} = \mathbf{b}, \quad (2.10)$$

где $det\mathbf{A}\neq 0$, $\mathbf{b}\neq 0$. Система (2.10) имеет единственное решение. Попробуем оценить, как погрешность правой части $\Delta\mathbf{b}$ повлияет на погрешность решения $\Delta\mathbf{x}$ в предположении, что матрица **A** известна точно, т.е. наряду с (2.10) рассмотрим систему:

$$\mathbf{A}(\mathbf{x}+\Delta\mathbf{x}) = \mathbf{b} + \Delta\mathbf{b}. \quad (2.11)$$

Поскольку $\mathbf{A}\Delta\mathbf{x}=\Delta\mathbf{b}$ или $\Delta\mathbf{x}= \mathbf{A}^{-1}\Delta\mathbf{b}$, имеем

$$\frac{\delta(\mathbf{x})}{\delta(\mathbf{b})} = \frac{\|\Delta\mathbf{x}\|/\|\mathbf{x}\|}{\|\Delta\mathbf{b}\|/\|\mathbf{b}\|} = \frac{\|\mathbf{b}\|}{\|\mathbf{x}\|} \cdot \frac{\|\Delta\mathbf{x}\|}{\|\Delta\mathbf{b}\|} = \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} \cdot \frac{\|\mathbf{A}^{-1}\Delta\mathbf{b}\|}{\|\Delta\mathbf{b}\|} \le$$

$$\le \frac{\|\mathbf{A}\| \cdot \|\mathbf{x}\|}{\|\mathbf{x}\|} \cdot \frac{\|\mathbf{A}^{-1}\|\|\Delta\mathbf{b}\|}{\|\Delta\mathbf{b}\|} = \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\| = \nu(\mathbf{A}).$$

Таким образом, отношение относительной погрешности решения к относительной погрешности правой части оценивается через число

$$\nu(\mathbf{A})=\|\mathbf{A}\|\cdot\|\mathbf{A}^{-1}\|,$$

которое называется числом обусловленности матрицы **A**. Число обусловленности есть максимально возможный коэффициент усиления относительной погрешности от правой части к решению системы:

$$\delta(\mathbf{x})\le\nu(\mathbf{A})\cdot\delta(\mathbf{b}).$$

Отметим основные свойства числа обусловленности:

1) $\nu(\mathbf{E})=1$, где **E**- единичная матрица;

2) $\nu(\mathbf{A})\ge 1$;

3) $\nu(\mathbf{A})=\nu(\mathbf{A}^{-1})$;

4) $\nu(\mathbf{AB})\le\nu(\mathbf{A})\nu(\mathbf{B})$;

5) $\nu(\alpha\mathbf{A})=\nu(\mathbf{A}),\ \alpha\ne 0$.

Доказательство первого свойства очевидно:

$$\nu(\mathbf{E})=\|\mathbf{E}\|\cdot\|\mathbf{E}^{-1}\|=\|\mathbf{E}\|\cdot\|\mathbf{E}\|=1;$$

при проверке второго воспользуемся неравенством для нормы матриц

$$1=\|\mathbf{E}\|=\|\mathbf{A}\cdot\mathbf{A}^{-1}\|\le\|\mathbf{A}\|\cdot\|\mathbf{A}^{-1}\|=\nu(\mathbf{A}).$$

Третье свойство следует непосредственно из определения числа обусловленности. Четвертое есть вновь следствие неравенства для норм

$$\nu(\mathbf{AB})=\|\mathbf{AB}\|\cdot\|(\mathbf{AB})^{-1}\|\le\|\mathbf{A}\|\cdot\|\mathbf{B}\|\cdot\|\mathbf{B}^{-1}\|\cdot\|\mathbf{A}^{-1}\|=\nu(\mathbf{A})\cdot\nu(\mathbf{B}).$$

И, наконец, пятое справедливо из-за однородности нормы:

$$\nu(\alpha\mathbf{A})=\|\alpha\mathbf{A}\|\cdot\|(\alpha\mathbf{A})^{-1}\|=|\alpha|\cdot\|\mathbf{A}\|\cdot|\alpha^{-1}|\cdot\|\mathbf{A}^{-1}\|=\nu(\mathbf{A}).$$

Точное значение числа обусловленности зависит, вообще говоря, от того, какая выбрана норма матриц, первая или вторая, но качественный вывод о поведении погрешности можно сделать при любом способе определения нормы.

Насколько важно заранее оценить меру близости матрицы показывает следующий пример плохо обусловленной системы уравнений. Рассмотрим систему

$$\begin{pmatrix} 1 & -1 & \dots & -1 \\ 0 & 1 & \dots & -1 \\ . & . & . & . \\ 0 & 0 & \dots & -1 \end{pmatrix} \cdot \mathbf{x} = \begin{pmatrix} -1 \\ -1 \\ \vdots \\ -1 \end{pmatrix}. \quad (2.12)$$

Решение такой системы очевидно и находится без труда:

$$\mathbf{x} = \begin{pmatrix} 0 & 0 & \dots & 1 \end{pmatrix}^T.$$

Но если допустить, что правая часть системы (2.12) имела погрешность $\Delta\mathbf{b}=(0\ 0\ \dots\ \varepsilon)^T$, даже достаточно малую, окажется, что погрешность решения будет весьма существенной при больших размерностях задачи (когда $n>>1$):

$$\Delta\mathbf{x} = \begin{pmatrix} 2^{n-2}\varepsilon & 2^{n-3}\varepsilon & \dots & \varepsilon \end{pmatrix}^T.$$

Например, при $n=100$ максимальное отклонение будет $2^{98}\cdot|\varepsilon|>10^{29}\cdot|\varepsilon|$. Число обусловленности такой системы очень велико:

$$\nu(\mathbf{A}) \geq \frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \cdot \frac{\|\mathbf{b}\|}{\|\Delta\mathbf{b}\|} = \frac{2^{n-2}|\varepsilon|}{1} \cdot \frac{1}{|\varepsilon|} = 2^{n-2},$$

с чем и связана неустойчивость решения.

Для дальнейших рассуждений нам понадобится следующее утверждение, которое не только носит вспомогательный характер, но и представляет самостоятельный интерес.

Лемма. Пусть матрица $\mathbf{B}$ ограничена и имеет норму $\|\mathbf{B}\|\leq\alpha<1$, тогда у матрицы $(\mathbf{E}-\mathbf{B})$ существует обратная матрица $(\mathbf{E}-\mathbf{B})^{-1}$ с ограниченной нормой

$$\left\|(\mathbf{E}-\mathbf{B})^{-1}\right\| \leq \frac{1}{1-\alpha}.$$

Доказательство сводится к представлению обратной матрицы в виде сходящегося ряда

$$(\mathbf{E}-\mathbf{B})^{-1} = \mathbf{E} + \mathbf{B} + \mathbf{B}^2 + \ldots + \mathbf{B}^n + \ldots.$$

Оценка нормы тогда получается при использовании соответствующих неравенств для норм:

$$\left\|(\mathbf{E}-\mathbf{B})^{-1}\right\| = \left\|\mathbf{E}+\mathbf{B}+\mathbf{B}^2+\ldots+\mathbf{B}^n+\ldots\right\| \le \|\mathbf{E}\|+\|\mathbf{B}\|+\|\mathbf{B}\|^2+\ldots \le 1+\alpha+\alpha^2+\ldots = \frac{1}{1-\alpha}.$$

Из этой оценки немедленно следует сходимость ряда и, следовательно, существование обратной матрицы $(\mathbf{E}-\mathbf{B})^{-1}$. Для матрицы $(\mathbf{E}+\mathbf{B})^{-1}$ лемма также справедлива и доказывается полностью аналогично.

Оценка влияния погрешности всех начальных данных на погрешность решения также может быть сделана при помощи числа обусловленности. А именно, пусть матрица $\mathbf{A}$, также как и правая часть $\mathbf{b}$, известна с некоторой погрешностью $\Delta\mathbf{A}$. В такой ситуации эффективная оценка погрешности решения возможна только при условии

$$1-\nu(\mathbf{A})\cdot\delta(\mathbf{A})>0, \quad (2.13)$$

которое мы будем предполагать выполненным. Система уравнений, которая реально решается вместо системы (2.10) имеет вид

$$(\mathbf{A}+\Delta\mathbf{A})(\mathbf{x}+\Delta\mathbf{x}) = \mathbf{b}+\Delta\mathbf{b}. \quad (2.14)$$

С учетом (2.10) она превращается в уравнение относительно $\Delta\mathbf{x}$:

$$(\mathbf{A}+\Delta\mathbf{A})\Delta\mathbf{x} = \Delta\mathbf{b}-\Delta\mathbf{A}\mathbf{x}. \quad (2.15)$$

Как следует из только что доказано леммы, при выполнении условия (2.13) матрица системы (2.15) имеет обратную $(\mathbf{E}+\mathbf{A}^{-1}\Delta\mathbf{A})^{-1}\mathbf{A}^{-1}$, норма которой допускает оценку

$$\left\|\left(\mathbf{E}+\mathbf{A}^{-1}\Delta\mathbf{A}\right)^{-1}\mathbf{A}^{-1}\right\| \le \frac{\left\|\mathbf{A}^{-1}\right\|}{1-\left\|\mathbf{A}^{-1}\Delta\mathbf{A}\right\|} \le \frac{\left\|\mathbf{A}^{-1}\right\|}{1-\nu(\mathbf{A})\cdot\delta(\mathbf{A})}.$$

Тогда можно записать

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \le \left\|\left(\mathbf{E}+\mathbf{A}^{-1}\Delta\mathbf{A}\right)^{-1}\mathbf{A}^{-1}\right\|\cdot\left(\frac{\|\Delta\mathbf{b}\|}{\|\mathbf{x}\|}+\frac{\|\Delta\mathbf{A}\|\cdot\|\mathbf{x}\|}{\|\mathbf{x}\|}\right) \le \frac{\left\|\mathbf{A}^{-1}\right\|\cdot\|\mathbf{A}\|}{1-\nu(\mathbf{A})\cdot\delta(\mathbf{A})}\cdot\left(\frac{\|\Delta\mathbf{b}\|}{\|\mathbf{x}\|\cdot\|\mathbf{A}\|}+\frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|}\right).$$

С учетом очевидного неравенства $\|\mathbf{b}\|\le\|\mathbf{A}\|\cdot\|\mathbf{x}\|$ окончательно получаем

$$\delta(\mathbf{x}) = \frac{\nu(\mathbf{A})}{1-\nu(\mathbf{A})\cdot\delta(\mathbf{A})}\cdot(\delta(\mathbf{b})+\delta(\mathbf{A})). \quad (2.16)$$

Таким образом, мы получили формулу для оценивания влияния неустранимой погрешности начальных данных, в которую входят лишь число обусловленности матрицы и относительные погрешности матрицы $\mathbf{A}$ и правой

части **b**. Формула (2.16) является также полезной и при определении вычислительной погрешности, поскольку погрешность округлений при арифметических операциях с матричными элементами часто можно пересчитать в погрешность начальных данных.

В заключение отметим, что иногда можно найти число обусловленности $\nu(\mathbf{A})$ не вычисляя обратной матрицы и ее нормы. Так для симметричных матриц число обусловленности, определенное по норме $\|\mathbf{A}\|_2$ есть отношение максимального к минимальному по модулю собственному числу матрицы **A**:

$$\nu(\mathbf{A}) = \frac{|\lambda_{\max}(\mathbf{A})|}{|\lambda_{\min}(\mathbf{A})|}.$$

Способ определения только этих двух чисел будет изложен в разделе, посвященном решению частичной проблемы собственных значений. Численно оценить меру обусловленности можно, решая несколько систем с близкими правыми частями и сравнивая полученные решения. Такой способ, разумеется, является не строгим.

2.2 Прямые методы решения систем алгебраических уравнений

Способы решения систем линейных уравнений в основном разделяются на две группы. К первой группе относятся точные методы, представляющие собой конечные алгоритмы для вычисления корней системы (таковы, например, правило Крамера, метод Гаусса, метод главных элементов, разложение и др.). Ко второй – итерационные методы, позволяющие получать корни системы с заданной точностью путем сходящихся бесконечных процессов (к их числу относятся метод простых итераций, метод Зейделя и др.). Вследствие неизбежных округлений результаты даже точных методов являются приближенными, причем оценка погрешностей корней в общем случае затруднительна.

Точные (прямые) методы решения систем алгебраических уравнений используются обычно для сравнительно небольших (n<200) систем с плотно

заполненной матрицей и неблизким к нулю определителем. Эффективность прямого метода зависит от числа арифметических операций, необходимых для решения поставленных задач. Так в общем случае вычисление определителя порядка n (без использования специальных приемов) требует $(n-1)n!$ умножений и $n!-1$ сложений, т.е. общее число арифметических операций равно

$$n \cdot n! - 1.$$

Общее число операций для вычисления обратной матрицы равно

$$n^2 \cdot n! - 1.$$

Рассмотрим задачу нахождения решения системы алгебраических уравнений общего вида; т.е. нахождение x_1, $x_2,\ldots,x_n$ по заданным a_{ij} и b_i ($i, j = \overline{1,n}$):

$$\left.\begin{array}{l} a_{11}x_1 + a_{12}x_2 + \ldots + a_{1n}x_n = b_1, \\ a_{21}x_1 + a_{22}x_2 + \ldots + a_{2n}x_n = b_2, \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ a_{n1}x_1 + a_{n2}x_2 + \ldots + a_{nn}x_n = b_n. \end{array}\right\}. \quad (2.17)$$

Систему (2.17) запишем в матричном виде

$$\mathbf{Ax} = \mathbf{b}, \quad (2.18)$$

где $\mathbf{A} = \{a_{ij}\}_{i,j=\overline{1,n}} \in R^{n\times n}$ – данная матица; $\mathbf{x}$ – искомый вектор $(x_1, x_2, \ldots, x_n)^T$; $\mathbf{b}=(b_1, b_2, \ldots, b_n)^T$ – вектор с компонентами b_i.

Рассмотрим векторы в пространстве R^n:

$$\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \\ \vdots \\ 0 \\ 0 \end{pmatrix}, \quad \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 0 \\ \vdots \\ 0 \\ 0 \end{pmatrix}, \quad \cdots, \quad \mathbf{e}_k = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \\ 0 \end{pmatrix} - k - я\ строка, \quad \mathbf{e}_n = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ \vdots \\ 0 \\ 1 \end{pmatrix}.$$

Система векторов $\{\mathbf{e}_k\} \in R^n$ образуют базис в пространстве R^n, так как это ортонормированная система линейно независимых векторов. Действительно, из равенства $0 = \sum_{i=1}^{n} \gamma_i \mathbf{e}_i = (\gamma_1, \ldots, \gamma_n)^T$ следует тотчас $\gamma_i \equiv 0$ для любого $i = \overline{1,n}$. Любой

вектор **x** может быть представлен в виде линейной комбинации базисных векторов $\mathbf{e}_k$:

$$\mathbf{x} = \sum_{k=1}^{n} x_k \mathbf{e}_k = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}.$$

Прежде, чем применить прямые методы к матрице общего вида, рассмотрим решение уравнения **Ax**=**b** с матрицей специального вида: с нижней и верхней треугольной матрицами.

Прямая подстановка. Рассмотрим уравнение вида (2.18) **Lx**=**b**, но матрица $\mathbf{L}=\{l_{ij}\}$; $l_{ij}=0$, $j>i$ – нижняя треугольная, т.е.

$$\left.\begin{array}{ccccccccc} l_{11}x_1 & & & & & & & = & b_1 \\ l_{21}x_1 & + & l_{22}x_2 & & & & & = & b_2 \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ l_{n1}x_1 & + & l_{n2}x_2 & + & \dots & + & l_{nn}x_n & = & b_n \end{array}\right\}. \quad (2.19)$$

Для того, чтобы решить систему **Lx**=**b** с произвольной правой частью необходимо и достаточно, чтобы определитель матрицы **L**, $det\mathbf{L}\neq 0$, т. е. $l_{ii}\neq 0$, $i=\overline{1,n}$.

Итак, решение системы (2.19) имеет вид:

$$\left.\begin{array}{c} x_1 = \dfrac{b_1}{l_{11}}, \quad x_2 = \dfrac{b_2 - l_{21}x_1}{l_{22}} \\ \dots\dots\dots\dots\dots\dots \\ x_i = \dfrac{b_i - \sum\limits_{j=1}^{i-1} l_{ij}x_j}{l_{ii}} \\ \dots\dots\dots\dots\dots\dots \\ x_n = \dfrac{b_n - \sum\limits_{j=1}^{n-1} l_{nj}x_j}{l_{nn}} \end{array}\right\}. \quad (2.20)$$

Обратная подстановка. Аналогично решается система с верхней диагональной матрицей $\mathbf{U}=\{u_{ij}\}$; $u_{ij}=0$, $j>i$

$$\mathbf{Ux}=\mathbf{b}.$$

Решение может быть записано в виде $\mathbf{x}=\mathbf{U}^{-1}\mathbf{b}$ или

$$x_n = \frac{b_n}{u_{nn}}, \quad x_{n-1} = \frac{b_{n-1} - u_{n-1,1}\, x_n}{u_{n-1,n-1}}, \ldots\ldots\ldots\ldots, \quad x_1 = \frac{b_1 - \sum_{j=2}^{n} u_{1j}\, x_j}{u_{11}}. \quad (2.21)$$

Перейдем непосредственно к методу LU – разложений матрицы **A**.

LU – разложение матрицы. Рассмотрим матрицу

$$\mathbf{E} - \boldsymbol{\alpha}\,\mathbf{e}_k^T = \begin{pmatrix} 1 & 0 & \ldots & 0 \\ 0 & 1 & \ldots & 0 \\ \ldots & \ldots & \ldots & \ldots \\ 0 & 0 & \ldots & 1 \end{pmatrix} - \begin{pmatrix} \alpha_1 \\ \vdots \\ \vdots \\ \alpha_n \end{pmatrix} \begin{pmatrix} 0, & 0, & \ldots, & 1, & \ldots, & 0 \end{pmatrix} = \begin{array}{c} \begin{pmatrix} 1 & 0 & \ldots & -\alpha_1 & \ldots & 0 \\ 0 & 1 & \ldots & -\alpha_2 & \ldots & 0 \\ \vdots & \vdots & & \vdots & & \vdots \\ 0 & 0 & \ldots & 1-\alpha_k & \ldots & 0 \\ \vdots & \vdots & & \vdots & & \vdots \\ 0 & 0 & \ldots & -\alpha_n & \ldots & 1 \end{pmatrix} \\ \uparrow \\ k-\text{й столбец} \end{array}.$$

Если вместо $\boldsymbol{\alpha}$ выбрать вектор $\boldsymbol{\alpha}^{(k)}$:

$$\boldsymbol{\alpha}^{(k)} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ l_{k+1,k} \\ \vdots \\ l_{n,k} \end{pmatrix},$$

то матрица $\mathbf{E} - \boldsymbol{\alpha}^{(k)}\,\mathbf{e}_k^T$ станет единичной нижней треугольной матрицей вида:

$$\mathbf{M}_k = \begin{array}{c} \begin{pmatrix} 1 & \ldots & 0 & \ldots & 0 \\ \vdots & & \vdots & & \vdots \\ 0 & \ldots & 1 & \vdots & 0 \\ 0 & \ldots & -l_{k+1,k} & \ldots & 0 \\ \vdots & & \vdots & & \vdots \\ 0 & \ldots & -l_{nk} & \ldots & 1 \end{pmatrix} \\ \uparrow \\ k-\text{й столбец} \end{array}. \qquad (2.22)$$

Матрица $\mathbf{M}_k$ называется матрицей Гаусса; вектор $\boldsymbol{\alpha}^{(k)}$ – вектором Гаусса; коэффициенты $l_{k+1,k}, \ldots, l_{nk}$ – множителями Гаусса. Отметим, что определитель $det\mathbf{M}_k=1$ и

$$\mathbf{M}_k^{-1} = \mathbf{E} + \boldsymbol{\alpha}^{(k)}\mathbf{e}_k^T.$$

Теорема. Пусть $\mathbf{M}_1, \mathbf{M}_2, \ldots, \mathbf{M}_k$ – матрицы Гаусса (2.22), $k \le n$, тогда

$$\prod_{i=1}^{k}\mathbf{M}_i^{-1}=\mathbf{M}_1^{-1}\cdot\mathbf{M}_2^{-1}\cdot\ldots\cdot\mathbf{M}_k^{-1}=\mathbf{E}+\sum_{i=1}^{k}\boldsymbol{\alpha}^{(i)}\mathbf{e}_i^T=\begin{pmatrix}1 & 0 & \ldots & 0 & \ldots & 0\\ l_{21} & 1 & \ldots & 0 & \ldots & 0\\ \ldots & \ldots & \ldots & \ldots & \ldots & \ldots\\ l_{k1} & l_{k2} & \ldots & 1 & \ldots & 0\\ \ldots & \ldots & \ldots & \ldots & \ldots & \ldots\\ l_{n1} & l_{n2} & \ldots & l_{nk} & \ldots & 1\end{pmatrix}.$$

Доказательство теоремы проверяется непосредственным перемножением $\mathbf{M}_i^{-1}, i=1,\ 2,\ \ldots,\ k.$

Рассмотрим далее вектор

$$\mathbf{M}_k\mathbf{x}=\left(\mathbf{E}-\boldsymbol{\alpha}^{(k)}\mathbf{e}_k^T\right)\mathbf{x}=\mathbf{x}-\boldsymbol{\alpha}^{(k)}\mathbf{e}_k^T\mathbf{x}=\mathbf{x}-x_k\boldsymbol{\alpha}^{(k)}=\begin{pmatrix}x_1\\ \vdots\\ x_k\\ x_{k+1}-x_k\cdot l_{k+1,k}\\ \vdots\\ x_n-x_k\cdot l_{nk}\end{pmatrix}.$$

Нетрудно увидеть, что если $x_k\neq 0$, то можно подобрать l_{ij} ($j>i,\ j\neq k$) так, чтобы,

$$\mathbf{M}_k\mathbf{x}=\begin{pmatrix}x_1\\ \vdots\\ x_k\\ 0\\ \vdots\\ 0\end{pmatrix},\quad l_{ik}=\frac{x_i}{x_k},\quad i=k+1,\ldots,n. \qquad (2.23)$$

Итак, мы доказали следующее утверждение.

Пусть $\mathbf{x}\in R^n$, тогда если

1. $\mathbf{x}_k=0$, то $\mathbf{M}_k\mathbf{x}=\mathbf{x}$,
2. $x_k\neq 0$, то существует матрица $\mathbf{M}_k$ (т.е. коэффициенты l_{ik}) такая, что справедливо (2.23).

Пусть теперь матрица $\mathbf{A}=\{a_{ij}\}=(\mathbf{a}_1,\mathbf{a}_2,\ldots,\mathbf{a}_q)\in R^{n\times q}$, $\mathbf{M}_k$ – матрица Гаусса. Тогда произведение матриц

$$\mathbf{M}_k\mathbf{A} = \left(\mathbf{M}_k\mathbf{a}_1, \mathbf{M}_k\mathbf{a}_2, \ldots, \mathbf{M}_k\mathbf{a}_q\right) = \begin{pmatrix} a_{11} & \ldots & a_{1q} \\ \vdots & & \vdots \\ a_{k1} & \ldots & a_{kq} \\ a_{k+1,1} - a_{k1}l_{k+1,1} & \ldots & a_{k+1,q} - a_{kq}l_{k+1,k} \\ \vdots & & \vdots \\ a_{n,1} - a_{k1}l_{nk} & \ldots & a_{nq} - a_{kq}l_{nk} \end{pmatrix}.$$

Перейдем непосредственно к самому LU – разложению. Пусть матрица $\mathbf{A} = \mathbf{A}^{(0)} = \left(\mathbf{a}_1^{(0)}, \ldots, \mathbf{a}_n^{(0)}\right)$. Если $a_{11}^{(0)} \neq 0$, то выберем матрицу $\mathbf{M}_1$ так, чтобы

$$\mathbf{M}_1\mathbf{a}_1^{(0)} = \begin{pmatrix} a_{11}^{(0)} \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad l_{i1} = \frac{a_{i1}^{(0)}}{a_{11}^{(0)}}, \quad i > 1. \ (2.24)_1$$

Умножая матрицу $\mathbf{M}_1$ на матрицу $\mathbf{A}^{(0)}$, получим матрицу $\mathbf{A}^{(1)}=\mathbf{M}_1\mathbf{A}^{(0)}=\mathbf{M}_1\mathbf{A}$ вида

$$\mathbf{A}^{(1)} = \left(\mathbf{a}_1^{(1)}, \ldots, \mathbf{a}_n^{(1)}\right) = \mathbf{M}_1\mathbf{A} = \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \ldots & a_{1n}^{(0)} \\ 0 & a_{11}^{(1)} & \ldots & a_{2n}^{(1)} \\ \vdots & \vdots & & \vdots \\ 0 & a_{n2}^{(1)} & \ldots & a_{nn}^{(1)} \end{pmatrix}.$$

Коэффициенты матрицы $\mathbf{A}^{(1)}$ вычисляются по формулам:

$$a_{ij}^{(1)} = a_{ij}^{(0)} - l_{i1}a_{ij}^{(0)}, \quad j > 1. \ (2.25)_1$$

Далее, если $a_{22}^{(1)} \neq 0$, то $\mathbf{M}_1$ выбираем так, чтобы

$$\mathbf{M}_2\mathbf{a}_2^{(1)} = \begin{pmatrix} a_{12}^{(0)} \\ a_{22}^{(1)} \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad l_{i2} = \frac{a_{i2}^{(1)}}{a_{22}^{(1)}}, \quad i > 2. \ (2.24)_2$$

Поскольку $a_{12}^{(1)} = 0$, то $\mathbf{a}_1^{(2)} = \mathbf{M}_2\mathbf{a}_1^{(1)} = \mathbf{a}_1^{(1)}$. Следовательно,

$$\mathbf{A}^{(2)} = \left(\mathbf{a}_1^{(2)}, \ldots, \mathbf{a}_n^{(2)}\right) = \mathbf{M}_2\mathbf{M}_1\mathbf{A} = \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & a_{13}^{(0)} & \ldots & a_{1n}^{(0)} \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & \ldots & a_{2n}^{(1)} \\ 0 & 0 & a_{33}^{(2)} & \ldots & a_{3n}^{(2)} \\ \vdots & \vdots & \vdots & & \vdots \\ 0 & 0 & a_{n3}^{(2)} & \ldots & a_{nn}^{(2)} \end{pmatrix}.$$

Элементы матрицы $\mathbf{A}^{(2)}$ вычисляются аналогично коэффициентам матрицы $\mathbf{A}^{(1)}$

$$a_{ij}^{(2)} = a_{ij}^{(1)} - l_{i2} a_{2j}^{(1)}, \quad j > 2. \ (2.25)_2$$

Последний шаг в этой схеме: матрица $\mathbf{A}^{(n-1)}=\mathbf{M}_{n-1}\mathbf{M}_n\ldots\mathbf{M}_1\mathbf{A}$ – это верхняя треугольная матрица, коэффициенты которой вычисляются так:

$$a_{ij}^{(n-1)} = a_{ij}^{(n-1)} - l_{i,n-1} a_{n-1,j}^{(n-2)}, \quad j > n-1, \ (2.25)_{n-1}$$

$$l_{i,n-1} = \frac{a_{i,n-1}^{(n-2)}}{a_{n-1,n-1}^{(n-2)}}, \quad i > n-1. \ (2.24)_{n-1}$$

Обозначим матрицу $\mathbf{A}^{(n-1)}$ через $\mathbf{U}=\mathbf{M}_{n-1}\mathbf{M}_n\ldots\mathbf{M}_1\mathbf{A}$ с коэффициентами $u_{ij} = a_{ij}^{(i-1)}, i = 1,\ldots,n-1; j > i.$ Умножая слева $\mathbf{U}$ на матрицу $\mathbf{L} = \mathbf{M}_1^{-1} \cdot \mathbf{M}_2^{-1} \ldots \mathbf{M}_{n-1}^{-1}$ получим

$$\mathbf{L} \cdot \mathbf{U} = \mathbf{M}_1^{-1} \cdot \mathbf{M}_2^{-1} \ldots \mathbf{M}_{n-1}^{-1} \cdot \mathbf{M}_{n-1} \cdot \mathbf{M}_n \ldots \mathbf{M}_1 \cdot \mathbf{A} = \mathbf{A}.$$

Окончательно мы имеем: $\mathbf{M}_1^{-1} \cdot \mathbf{M}_2^{-1} \ldots \mathbf{M}_{n-1}^{-1} \cdot \mathbf{U} = \mathbf{L} \cdot \mathbf{M}_{n-1} \cdot \mathbf{M}_n \ldots \mathbf{M}_1 \cdot \mathbf{A} = \mathbf{A}$. Таким образом

$$\mathbf{A} = \mathbf{LU},$$

где матрицы $\mathbf{L}=\{l_{ij}\}$ и $\mathbf{U}=\{u_{ij}\}$ имеют, соответственно, вид нижней и верхней треугольной матриц:

$$\mathbf{L} = \begin{pmatrix} 1 & 0 & \ldots & 0 \\ l_{21} & 1 & \ldots & 0 \\ \vdots & \vdots & & \vdots \\ l_{n1} & l_{n2} & \ldots & 1 \end{pmatrix}; \qquad \mathbf{U} = \begin{pmatrix} u_{11} & u_{12} & \ldots & u_{1n} \\ 0 & u_{11} & \ldots & u_{2n} \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \ldots & u_{nn} \end{pmatrix}.$$

Коэффициенты матрицы $\mathbf{L} = \{l_{ij}\}, \ l_{ij} = 0, \ j > i$ вычисляются по формулам (2.24), $l_{ii} = 1$, а $u_{ij} \neq 0, \ j \geq i$ определяются по формулам (2.25), если $u_{ij} = a_{ij}^{(i-1)}$, $i = 1, \ldots, n-1; \ j > i$.

Итак, если на каждом шаге $a_{kk}^{(k-1)} \neq 0, k = \overline{1,n},$ то можно получить такие верхнюю **U** и нижнюю **L** треугольные матрицы, что **A=LU**, причем

$$\det(\mathbf{A}) = u_{11} \cdot u_{22} \cdot \ldots \cdot u_{nn} = a_{11}^{(0)} \cdot a_{22}^{(1)} \cdot \ldots \cdot a_{nn}^{(n-1)}. \quad (2.26)$$

Решение системы линейных алгебраических уравнений методом LU – разложений.

Рассмотрим решение уравнения (2.18) методом LU – разложений.

Первый этап: находим LU – разложение матрицы **A** по схеме (2.24), (2.25).

Второй этап: запишем уравнение (2.18) в виде **Ax=LUx=b**; обозначим **Ux=y**, тогда решение (2.18) эквивалентно решению системы

$$\begin{cases} \mathbf{Ly} = \mathbf{b} \\ \mathbf{Ux} = \mathbf{y} \end{cases}, \quad (2.27)$$

с треугольными матрицами **L** и **U**. По формулам (2.21) мы найдем вектор **y**, а затем вектор **x** по формулам (2.20).

Итак, методом LU – разложений получено решение линейной системы уравнений **Ax=b** за число арифметических операций порядка $O(n^3)$. Одновременно вычислен определитель *det* матрицы **A** (см. формулу (2.26)).

Метод Гаусса с выбором главного (*ведущего*) *элемента.*

Пусть дана система линейных уравнений **Ax=b**, причем у матрицы **A** некоторые диагональные элементы либо малы, либо равны нулю. Тогда метод LU–разложений неприменим в том виде, который изложен выше, и следует подправить схему вычислений так, чтобы все оставалось законным. Рассмотрим расширенную прямоугольную матрицу (**A**,**b**). Выберем ненулевой, как правило, наибольший по модулю, не принадлежащий столбцу свободных членов элемент a_{pq}. Выбор максимального по модулю элемента можно проводить несколькими способами: построчным, постолбцовым выбором, либо поэлементно. Такой элемент a_{pq} матрицы $\mathbf{A}=(\mathbf{A},\mathbf{b})=(a_{ij},a_{i,n+1})$, $1 \le i, j \le n$ называется главным элементом.

Вычислим множители Гаусса

$$l_{ip} = \frac{a_{iq}}{a_{pq}}, \quad i \neq p. \quad (2.28)$$

Строка с номером p называется главной. Далее произведем операцию: от каждой неглавной строки вычтем главную, умноженную на соответствующий множитель l_{ip} для этой строки. В результате мы получим новую матрицу, у которой q – столбец состоит из нулей. Отбрасывая этот столбец и главную p – строку, мы получим матрицу с меньшим числом строк и столбцов на единицу.

Над матрицей производим те же операции с выбором главного элемента и строим матрицу $\mathbf{A}^{(2)}$ и т.д.

$$\mathbf{A},\ \mathbf{A}^{(1)},\ldots,\ \mathbf{A}^{(n-1)}.$$

Последняя из этой последовательности матриц представляет собой двучленную матрицу–строку; ее также считаем главной строкой. Для определения неизвестного x_i объединяем в систему все главные строки, начиная с последней, входящей в матрицу $\mathbf{A}^{(n-1)}$. После надлежащего изменения нумерации неизвестных, получается система с треугольной матрицей, из которой легко шаг за шагом найти неизвестные данной системы **Ax=b**. Метод главных элементов всегда применим, если $det(\mathbf{A})\neq 0$. Сам метод Гаусса является частным случаем метода главных элементов, а схема метода Гаусса получается, если за главный элемент всегда выбирать левый верхний элемент соответствующей матрицы. Решение уравнения **Ax=b** сводится к решению уравнения $\mathbf{Ux}=\mathbf{U}_1\mathbf{b}$, где **U**– верхняя треугольная матрица

$$\mathbf{U}=\begin{pmatrix} u_{11} & u_{12} & \ldots & u_{1n} \\ 0 & u_{11} & \ldots & u_{2n} \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \ldots & u_{nn} \end{pmatrix},$$

а $\mathbf{U}_1\mathbf{b}=\left(b_1^{(0)},b_2^{(1)},\ldots,b_n^{(n-1)}\right)^T$, где $b_i^{(i-1)}=b_i^{(i-2)}-l_{i,i-1}b_{i-1}^{(i-2)},\ i=\overline{1,n}.$

Метод Гаусса вычисления обратной матрицы. Пусть дана неособая матрица $\mathbf{A}=\{a_{ij}\};\ i,j=\overline{1,n}$. Для нахождения ее обратной матрицы $\mathbf{A}^{-1}=\{x_{ij}\}$ используем основное соотношение

$$\mathbf{A}\cdot\mathbf{A}^{-1}=\mathbf{A}\cdot\{x_{ij}\}=\mathbf{E}. \quad (2.29)$$

Перемножая матрицы $\mathbf{A}\cdot\mathbf{A}^{-1}$ будем иметь n систем уравнений относительно n^2 неизвестных x_{ij}

$$\sum_{k=1}^{n} a_{ik}\,x_{kj}=\delta_{ij}, \qquad (i,j=1,2,\ldots,n), \quad (2.30)$$

где

$$\delta_{ij}=\begin{cases} 1 & ,\ когда\quad i=j, \\ 0 & ,\ когда\quad i\neq j. \end{cases}$$

Полученные n систем линейных уравнений для j=1, 2, …, n, имеющих одну и ту же матрицу **A** и различные свободные члены, одновременно можно решить методом Гаусса. Применяя метод Гаусса, мы получим, например, для компонент j – столбца матрицы $\mathbf{A}^{-1}$

$$\left.\begin{array}{rcl} a_{11}^{(0)}x_{1j}+a_{12}^{(0)}x_{2j}+\ldots+a_{1n}^{(0)}x_{nj} & = & \delta_{1j}^{(0)} \\ a_{22}^{(1)}x_{2j}+\ldots+a_{2n}^{(1)}x_{nj} & = & \delta_{2j}^{(1)} \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots & \ldots & \ldots \\ a_{nn}^{(n-1)}x_{nj} & = & \delta_{nj}^{(n-1)} \end{array}\right\}, \quad (2.31)$$

где $\delta_{ij}^{(i-1)}$ вычислены по формулам $(2.25)_i$. Количество операций порядка O(n^3).

2.3 Итерационные методы решения систем линейных алгебраических уравнений.

Решения, получаемые с помощью прямых методов, обычно содержат погрешности, вызванные округлениями при выполнении операций над числами. Рассмотрим в связи с этим методы, позволяющие уточнить решение, полученное с помощью прямого метода, либо самостоятельно получить это решение.

Метод простой итерации. Найдем решение системы линейных уравнений (2.17), предполагая, что все диагональные коэффициенты матрицы $a_{ii}\neq 0$.

Приведем систему **Ax=b** к виду

$$\mathbf{x}=\mathbf{C}\mathbf{x}+\mathbf{f}, \qquad (2.32)$$

где **C**- некоторая матрица, **f** – вектор–столбец.

Исходя из произвольного вектора $\mathbf{x}^{(0)}$, строим итерационный процесс

$$\mathbf{x}^{(k+1)}=\mathbf{C}\mathbf{x}^{(k)}+\mathbf{f}, \quad k=0,1,\ldots$$

или в развернутом виде

$$\begin{array}{l} x_1^{(k+1)}=c_{11}x_1^{(k)}+c_{12}x_2^{(k)}+\ldots+c_{1n}x_n^{(k)}+f_1, \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ x_n^{(k+1)}=c_{n1}x_1^{(k)}+c_{n2}x_2^{(k)}+\ldots+c_{nn}x_n^{(k)}+f_n. \end{array} \qquad (2.33)$$

Произведя итерации, получим последовательность векторов $\mathbf{x}^{(1)}$, $\mathbf{x}^{(2)}$,…, $\mathbf{x}^{(n)}$. Можно доказать, что если элементы матрицы **C** удовлетворяют одному из условий

$$\sum_{j=1}^{n}\left|c_{ij}\right| \le \alpha < 1, \quad (i = 1, 2, \ldots, n) \qquad (2.34)$$

или

$$\sum_{i=1}^{n}\left|c_{ij}\right| \le \beta < 1, \quad (i = 1, 2, \ldots, n), \qquad (2.35)$$

то процесс итерации сходится к точному решению системы **x** при любом $\mathbf{x}^{(0)}$, т.е. $\mathbf{x} = \lim\limits_{k\to\infty} \mathbf{x}^{(k)}$.

Оценка погрешности этого приближенного решения $\mathbf{x}^{(k)}$ дается одной из следующих формул:

$$\left|x_i - x_i^{(k)}\right| \le \frac{\alpha}{1-\alpha} \cdot \max_{j=\overline{1,n}}\left|x_j^{(k)} - x_j^{(k-1)}\right| \qquad (2.36)$$

либо

$$\left|x_i - x_i^{(k)}\right| \le \frac{\beta}{1-\beta} \cdot \sum_{j=1}^{n}\left|x_j^{(k)} - x_j^{(k-1)}\right|. \qquad (2.37)$$

Иногда за $\mathbf{x}^{(0)}$ берут **f**, хотя наиболее целесообразно в качестве компонент $\mathbf{x}^{(0)}$ взять приближенные значения неизвестных, полученные грубой прикидкой либо прямыми методами.

Приведение системы (2.18) к виду (2.32) можно осуществить различными способами. Если диагональные элементы матрицы **A** не равны нулю, т.е. $a_{ii} \ne 0, \quad i = \overline{1,n}$, то систему **Ax=b** можно записать в виде

$$\begin{aligned}
x_1 &= \frac{1}{a_{11}}\left(b_1 - a_{12}x_2 - \ldots - a_{1n}x_n\right) \\
x_2 &= \frac{1}{a_{22}}\left(b_2 - a_{21}x_1 - \ldots - a_{2n}x_n\right) \\
&\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\
x_n &= \frac{1}{a_{nn}}\left(b_n - a_{n1}x_1 - a_{n2}x_2 \ldots - a_{nn-1}x_n\right)
\end{aligned} \qquad (2.36)$$

В этом случае элементы матрицы **C** определяются следующим образом:

$$c_{ij} = -\frac{a_{ij}}{a_{ii}}\ (i \ne j),\ c_{ii} = 0$$

и тогда условия (2.34), (2.35) соответственно приобретают вид

$$\sum_{j=1}^{n}\left|\frac{a_{ij}}{a_{ii}}\right| \le \alpha < 1, \quad (i = 1,2,\ldots,n),$$

$$\sum_{i=1}^{n}\left|\frac{a_{ij}}{a_{ii}}\right| \le \beta < 1, \quad (i = 1,2,\ldots,n),$$

Эти неравенства будут выполнены, если диагональные элементы матрицы **A** удовлетворяют условию

$$|a_{ii}| > \sum_{j \ne i}|a_{ij}|, \quad \left(i = \overline{1,n}\right),$$

т.е. если модули диагональных коэффициентов для каждого уравнения системы больше суммы модулей всех остальных коэффициентов (не считая свободных членов).

Метод итераций, если он сходится, дает преимущества по сравнению с прямыми методами.

1. Если итерации сходятся достаточно быстро, т.е. если для решения системы требуется менее n итераций, то получаем выигрыш во времени, так как число арифметических операций, необходимых для одной итерации, пропорционально n^2 , а общее число арифметических действий в методе Гаусса, например, пропорционально n^3.

2. Погрешности округления в методе итераций сказываются значительно меньше, чем в методе Гаусса. Кроме того, метод итераций является самоисправляющимся, т.е. отдельная ошибка, допущенная в вычислениях, не отражается на окончательном результате, т.к. ошибочное приближение можно рассматривать как новый начальный вектор.

Последнее обстоятельство часто используется для уточнения значений неизвестных, полученных методом Гаусса.

3. Метод итераций становится особенно выгодным при решении систем, у которых значительное число коэффициентов равно нулю.

4. Процесс итераций приводит к выполнению однообразных операций и сравнительно легко программируется на ЭВМ.

Метод итераций Зейделя. Метод Зейделя является модификацией метода простой итерации. Он заключается в том, что при вычислении ($k+1$) – го приближения неизвестного x_i при $i>1$используются уже вычисленные ранее соответствующие приближения неизвестных x_1, x_2,…, x_{i-1}. Таким образом, для системы (2.32) вычисления по методу Зейделя ведутся по формулам:

$$\begin{aligned} x_1^{(k+1)} &= c_{11}x_1^{(k)} + c_{12}x_2^{(k)} + \ldots + c_{1n}x_n^{(k)} + f_1, \\ x_2^{(k+1)} &= c_{21}x_1^{(k+1)} + c_{22}x_2^{(k)} + \ldots + c_{2n}x_n^{(k)} + f_2, \\ &\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ x_n^{(k+1)} &= c_{n1}x_1^{(k+1)} + c_{n2}x_2^{(k+1)} + \ldots + c_{nn}x_n^{(k)} + f_n. \end{aligned} \qquad (2.37)$$

Условия сходимости для метода простой итерации остаются верными и для метода Зейделя. Обычно метод Зейделя дает лучшую сходимость, чем метод простой итерации. Кроме того, метод Зейделя может оказаться более удобным при программировании, так как при вычислении $x_i^{(k+1)}$ нет необходимости хранить значения $x_1^{(k)}, x_2^{(k)}, \ldots, x_i^{(k)}$.

2.4 Решение систем уравнений с матрицами специального вида (трехдиагональные матрицы)

Рассмотрим частный случай «разреженной» матрицы – трехдиагональную матрицу.

Определение. Квадратная матрица **A** размера $n \times n$ называется k–диагональной (k – конкретное, нечетное, целое, положительное число), если ее элементы удовлетворяют соотношениям:

$$a_{ij} = 0, \quad |i - j| > (k-1)/2.$$

В соответствии с этим определением обычная диагональная матрица является однодиагональной, у трехдиагоналольной матрицы отличны от нуля элементы, стоящие на главной диагонали и на двух прилежащих к главной диагоналях.

Метод прогонки решения систем алгебраических уравнений. Метод прогонки является модификацией прямого метода Гаусса для частного случая разреженной матрицы – трехдиагональной матрицы. Такие системы уравнений возникают при построении сплайн–функций (см.4.4), при конечно–разностных аппроксимациях краевых задач для обыкновенных дифференциальных уравнений и в уравнениях с частными производными.

Рассмотрим систему n линейных алгебраических уравнений с n неизвестными, имеющую следующий специальный вид:

$$\begin{array}{ccccccccccccccc}
b_1x_1 & + & c_1x_2 & & & & & & & & & & & = & d_1 \\
a_2x_1 & + & b_2x_2 & + & c_2x_3 & & & & & & & & & = & d_2 \\
 & & a_3x_2 & + & b_3x_3 & + & c_3x_4 & & & & & & & = & d_3 \\
\cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\
 & & & & & & & & a_{n-1}x_{n-1} & + & b_{n-1}x_{n-1} & + & c_{n-1}x_n & = & d_{n-1} \\
 & & & & & & & & & & a_nx_{n-1} & + & b_nx_n & = & d_n
\end{array} \qquad (2.38)$$

На главной диагонали матрицы этой системы стоят элементы b_1, b_2,…, b_n, над ней – элементы c_1, c_2,…, c_n, под ней – a_1, a_2,…, a_n. При этом обычно все коэффициенты b_i не равны нулю.

Метод прогонки состоит из двух этапов – прямой прогонки (аналога прямого хода метода LU – разложений) и обратной прогонки (аналога обратного хода). Прямая прогонка состоит в том, что каждое неизвестное x_i выражается через x_{i+1} с помощью прогоночных коэффициентов A_i, B_i:

$$x_i = A_i x_{i+1} + B_i, \quad i = 1,2,\ldots,n-1. \qquad (2.39)$$

Из первого уравнения системы (2.37) найдем

$$x_1 = -\frac{c_1}{b_1}x_2 + \frac{d_1}{b_1}.$$

С другой стороны, по формуле (2.39) $x_1=A_1x_2+B_1$. Приравнивая коэффициенты в обоих выражениях для x_1, получим

$$A_1 = -\frac{c_1}{b_1}, \quad B_1 = \frac{d_1}{b_1}. \qquad (2.40)$$

Из второго уравнения системы (2.38) выразим x_2 через x_3, заменяя x_1 по формуле (2.39):

$$a_2\left(A_1x_2 + B_1\right) + b_2x_2 + c_2x_3 = d_2.$$

Отсюда

$$x_2 = \frac{-c_2 x_3 + d_2 - a_2 B_1}{a_2 A_1 + b_2} = A_2 x_3 + B_2,$$

где

$$A_2 = -\frac{c_2}{e_2}, \quad B_2 = \frac{d_2 - a_2 B_1}{e_2}, \quad e_2 = a_2 A_1 + b_2.$$

Аналогично можно вычислить прогоночные коэффициенты для любого номера

$$A_i = -\frac{c_i}{e_i}, \quad B_i = \frac{d_i - a_i B_{i-1}}{e_i}, \quad e_i = a_i A_{i-1} + b_i, \quad i = 2,3,\ldots,n-1 \quad (2.41)$$

Обратная прогонка состоит в последовательном вычислении неизвестных x_i. Сначала нужно найти x_n. Для этого воспользуемся выражением (2.39) при $i=n-1$ и последним уравнением системы (2.38). Запишем их:

$$x_{n-1} = A_{n-1} x_n + B_{n-1},$$
$$a_n x_{n-1} + b_n x_n = d_n.$$

Откуда, исключая x_{n-1}, находим:

$$x_n = \frac{d_n - a_n B_{n-1}}{b_n + a_n A_{n-1}} = B_n.$$

Далее, используя формулу (2.39) и выражения для прогоночных коэффициентов (2.40), (2.41) последовательно вычисляем все неизвестные $x_{n-1}, x_{n-2}, \ldots, x_1$.

При анализе алгоритма метода прогонки надо учитывать возможность деления на нуль в формулах (2.41). Можно показать, что при выполнении условий

$$|b_j| \geq |a_j| + |c_j|,$$

причем хотя бы для одного значения j имеет место строгое неравенство, деления на нуль не возникает и система (2.39) имеет единственное решение. Приведенное условие преобладания диагональных элементов обеспечивает также устойчивость метода прогонки относительно погрешности округления. Последнее обстоятельство позволяет использовать метод прогонки для решения больших систем уравнений. Заметим, что данное условие устойчивости прогонки является достаточным, но не необходимым. В ряде

случаев для хорошо обусловленных систем (2.39) метод прогонки оказывается устойчивым при нарушении условия преобладания диагональных элементов.

2.5 Методы решения проблемы собственных значений и собственных векторов матриц

Собственные значения и вектора матриц. Пусть матрица **A** – симметричная (**A**=**A**^{T}) квадратная матрица $\in R^{n\times n}$. Если для некоторого ненулевого вектора **q** и некоторого числа λ выполнено равенство

$$\mathbf{Aq} = \lambda\mathbf{q}, \quad (2.42)$$

то λ и **q** называются соответственно собственным значением (или числом) и собственным вектором матрицы **A**. В равенстве (2.42) неизвестны и число λ и вектор **q**. Чтобы найти их, перепишем равенство (2.42) в виде однородной системы линейных уравнений

$$(\mathbf{A} - \lambda\mathbf{E}_n)\mathbf{q} = \mathbf{O}_n, \quad (2.43)$$

где $\mathbf{E}_n = diag\{1, \ldots, 1\}$, $\mathbf{O}_n$ – нулевой элемент–матрица $\in R^{n\times n}$. Система (2.43) имеет нетривиальное (отличное от нуля) решение лишь в том случае, если

$$\det(\mathbf{A} - \lambda\mathbf{E}_n) = 0. \quad (2.44)$$

Уравнение (2.44) называется *характеристическим* уравнением матрицы **A** и может быть расписано в виде

$$\begin{aligned}
&(a_{11} - \lambda)x_1 + a_{12}x_2 + \ldots + a_{1n}x_n = 0\\
&a_{21}x_1 + (a_{22} - \lambda)x_2 + \ldots + a_{2n}x_n = 0\\
&\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\\
&a_{n1}x_1 + a_{n2}x_2 + \ldots + (a_{nn} - \lambda)x_n = 0.
\end{aligned}$$

Определитель системы (2.44) является многочленом степени *n* относительно λ

$$\mathrm{P}_n(\lambda) = \lambda^n + c_1\lambda^{n-1} + \ldots + c_{n-1}\lambda + c_n \quad (2.45)$$

и называется *характеристическим* многочленом матрицы **A**. Таким образом, собственные значения матрицы **A** – корни характеристического многочлена:

$\mathrm{P}_n(\lambda_i)=0, \quad i=\overline{1,n}.$ Подставляя последовательно собственные числа λ_1, λ_2, …, λ_n в однородную систему (2.43), находим собственные векторы $\mathbf{q}_i$ матрицы **A**:

$$\mathbf{A}\mathbf{q}_i=\lambda_i\mathbf{q}_i, \quad i=\overline{1,n}. \quad (2.46)$$

Считаем для простоты, что все $\lambda_i, i=\overline{1,n}.$ различны. Совокупность n векторных равенств (2.46) можно записать в виде одного матричного равенства. Введем для этого матрицу **Q**, столбцы которой есть собственные векторы матрицы **A**: $\mathbf{Q}=\{\mathbf{q}_1, \mathbf{q}_2, \ldots, \mathbf{q}_n\}$ и диагональную матрицу $\mathbf{\Lambda}$ с собственными значениями $\{\lambda_i\}_{i=1}^n$ матрицы **A** на диагонали: $\mathbf{\Lambda}=diag\{\lambda_1, \lambda_2, \ldots, \lambda_n\}$. Тогда n равенств (2.46) эквивалентны одному матричному $\mathbf{A}(\mathbf{q}_1,\mathbf{q}_2,\ldots,\mathbf{q}_n)=(\lambda_1\mathbf{q}_1,\lambda\mathbf{q}_2,\ldots,\lambda_n\mathbf{q}_n)$ или

$$\mathbf{A}\mathbf{Q}=\mathbf{Q}\mathbf{\Lambda}. \quad (2.47)$$

Если матрица **A** вещественная симметричная, т.е. $\mathbf{A}^T=\mathbf{A}$, то собственные векторы, отвечающие собственным числам, ортогональны:

$$(\mathbf{q}_i,\mathbf{q}_j)=\delta_{ij}\|\mathbf{q}_i\|^2.$$

Поскольку собственные векторы $\mathbf{q}_i$ определены с точностью до произвольного множителя (уравнение (2.42) и слева, и справа можно умножить на произвольное число α и переобозначить $\alpha\mathbf{q}$ через **q**), то выберем длину каждого собственного вектора равной единице. Тогда матрицу **Q**, имеющую ортогональные столбцы, длины которых равны единице, называют ортогональной, ($\mathbf{Q}^{-1}=\mathbf{Q}^T$). Домножив обе части матричного равенства (2.47) слева на $\mathbf{Q}^T=\mathbf{Q}^{-1}$, получим так называемую диагональную форму матрицы **A**

$$\mathbf{\Lambda}=\mathbf{Q}^T\mathbf{A}\mathbf{Q}. \quad (2.48)$$

С другой стороны, домножив (2.47) справа на $\mathbf{Q}^T$, находим

$$\mathbf{A}=\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T \quad (2.49)$$

что позволяет вернуться от диагональной формы матрицы к самой матрице **A**.

Для невырожденных матриц $(\mathbf{ABC})^{-1}=\mathbf{C}^{-1}\mathbf{B}^{-1}\mathbf{A}^{-1}$ и тогда линейную систему **Ax=b** перепишем

$$\mathbf{x}=\left(\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T\right)^{-1}\mathbf{b}=\left(\mathbf{Q}^T\right)^{-1}\mathbf{\Lambda}^{-1}\mathbf{Q}^{-1}\mathbf{b}=\mathbf{Q}\mathbf{\Lambda}^{-1}\mathbf{Q}^T\mathbf{b}$$

и так как

$$\mathbf{x}=\mathbf{A}^{-1}\mathbf{b},$$

мы тотчас получаем

$$\mathbf{A}^{-1}=\mathbf{Q}\mathbf{\Lambda}^{-1}\mathbf{Q}^{T} \quad (2.50)$$

(сравним с формулой (2.49)).

Формула (2.50) является частным случаем формулы

$$\varphi(\mathbf{A})=\mathbf{Q}\varphi(\mathbf{\Lambda})\mathbf{Q}^{T}, \quad (2.51)$$

определяющей любую функцию φ от квадратной матрицы **A**

$$\varphi(\mathbf{\Lambda})=diag\{\varphi(\lambda_1), \varphi(\lambda_2), \ldots, \varphi(\lambda_n)\}.$$

Подытоживая результаты для симметричных матриц с различными ненулевыми собственными значениями, можно сформулировать следующий теоретический факт о *спектральном разложении* матрицы.

Справедливо следующее утверждение: для матрицы **A**, симметричной и имеющей n различных собственных значений λ_i, имеет место равенство

$$\mathbf{A}=\lambda_1\mathbf{q}_1\mathbf{q}_1^T+\lambda_2\mathbf{q}_2\mathbf{q}_2^T+\ldots+\lambda_n\mathbf{q}_n\mathbf{q}_n^T. \quad (2.52)$$

По существу это иная форма записи равенства (2.49)

$$\mathbf{A}=\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{T}.$$

Задача нахождения всех собственных значений и собственных векторов числовой матрицы называется *полной проблемой собственных значений*. Эта задача в общем случае достаточно сложная. Мы остановимся только на некоторых важных частных задачах.

Нахождение максимального по модулю собственного значения.

Для решения *частичной проблемы собственных значений*, состоящей в определении одного или нескольких собственных значений и соответствующих им собственных векторов, обычно используются итерационные методы.

Предположим, что квадратная матрица **A** порядка n имеет полную систему нормированных собственных векторов $\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_n$, т.е.

$$\mathbf{A}\mathbf{e}_i=\lambda_i\mathbf{e}_i,\ \|\mathbf{e}_i\|=\|\mathbf{e}_i\|_2=\langle\mathbf{e}_i, \mathbf{e}_i\rangle^{1/2}=1, \quad (2.53)$$

где $\langle x, y\rangle$ – скалярное произведение в n – мерном векторном пространстве; λ_i – собственные значения матрицы **A,** отвечающие собственному вектору $\mathbf{e}_i$, $i=1,2,\ldots,n$. Такая полная система собственных векторов существует у симметричных матриц. Допустим, что

$$|\lambda_1| > |\lambda_2| > |\lambda_3| > \ldots > |\lambda_n|. \qquad (2.54)$$

Выберем произвольный вектор $\mathbf{x}^{(0)} \neq 0$. Имеем

$$\mathbf{x}^{(0)} = c_1\mathbf{e}_1 + c_2\mathbf{e}_2 + \ldots + c_n\mathbf{e}_n,$$

где $c_1, c_2, \ldots, c_n$ – координаты вектора $\mathbf{x}^{(0)}$ в базисе $\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_n$.

Предположим, что

$$c_1 \neq 0.$$

Последовательно находим векторы

$$\mathbf{x}^{(k)} = \mathbf{A}\mathbf{x}^{(k-1)},\ k=1,2,\ldots \quad (2.55)$$

Тогда согласно (2.53)

$$\mathbf{x}^{(1)} = \mathbf{A}\mathbf{x}^{(0)} = \mathbf{A}\left(c_1\mathbf{e}_1 + c_2\mathbf{e}_2 + \ldots + c_n\mathbf{e}_n\right) =$$
$$= \sum_{i=1}^{n} c_i\lambda_i\mathbf{e}_i = \lambda_1\left(c_1\mathbf{e}_1 + \boldsymbol{\eta}^{(1)}\right)$$

и вообще,

$$\mathbf{x}^{(k)} = \lambda_1^{(k)}\left(c_1\mathbf{e}_1 + \boldsymbol{\eta}^{(k)}\right), \quad (2.56)$$

где $\boldsymbol{\eta}^{(k)} = c_2\left(\frac{\lambda_2}{\lambda_1}\right)^k \mathbf{e}_2 + \ldots + c_n\left(\frac{\lambda_n}{\lambda_1}\right)^k \mathbf{e}_n$, причем из (2.54) имеем

$$\left\|\boldsymbol{\eta}^{(k)}\right\| = \mathrm{O}\left(\left|\frac{\lambda_2}{\lambda_1}\right|^k\right) \underset{k\to\infty}{\to} 0.$$

Здесь и ниже в данном параграфе верхний индекс у векторов, например, $\mathbf{x}^{(k)}$ указывает номер приближения, у скаляров, например, λ^k верхний индекс означает степень, а в качестве нормы векторов принята вторая норма, т.е. $\|\mathbf{x}\| = \|\mathbf{x}\|_2 = \langle\mathbf{x},\mathbf{x}\rangle^{1/2}$. Далее ограничимся рассмотрением класса симметричных матриц. Учитывая, что собственные вектора симметричной матрицы ортогональны, из формулы (2.56) получим следующее выражение для скалярного произведения:

$$\left\langle \mathbf{x}^{(k)}, \mathbf{x}^{(k-1)} \right\rangle = \lambda_1^{2k-1} \left\langle c_1 \mathbf{e}_1 + \boldsymbol{\eta}^{(k)}, c_1 \mathbf{e}_1 + \boldsymbol{\eta}^{(k-1)} \right\rangle =$$
$$= \lambda_1^{2k-1} \left[c_1^2 \left\langle \mathbf{e}_1, \mathbf{e}_1 \right\rangle + c_1 \left\langle \mathbf{e}_1, \boldsymbol{\eta}^{(k-1)} \right\rangle + c_1 \left\langle \boldsymbol{\eta}^{(k)}, \mathbf{e}_1 \right\rangle + \left\langle \boldsymbol{\eta}^{(k)}, \boldsymbol{\eta}^{(k-1)} \right\rangle \right] =$$
$$= \lambda_1^{2k-1} \left[c_1^2 + \left\langle \boldsymbol{\eta}^{(k)}, \boldsymbol{\eta}^{(k-1)} \right\rangle \right] = \lambda_1^{2k-1} \left[c_1^2 + \mathrm{O}\left(\left| \frac{\lambda_2}{\lambda_1} \right|^{2k-1} \right) \right],$$

поскольку $\|\mathbf{e}_1\|=1$, вектор $\boldsymbol{\eta}^{(k)}$ ортогонален вектору $\mathbf{e}_1$ при любом $k=1, 2,\ldots$ и

$$\left\langle \boldsymbol{\eta}^{(k)}, \boldsymbol{\eta}^{(k-1)} \right\rangle = c_2^2 \left(\frac{\lambda_2}{\lambda_1} \right)^{2k-1} + \ldots + c_n^2 \left(\frac{\lambda_n}{\lambda_1} \right)^{2k-1}.$$

Аналогично получаем

$$\left\langle \mathbf{x}^{(k-1)}, \mathbf{x}^{(k-1)} \right\rangle = \lambda_1^{2k-2} \left[c_1^2 + \mathrm{O}\left(\left| \frac{\lambda_2}{\lambda_1} \right|^{2k-2} \right) \right].$$

Следовательно,

$$\lambda_1^{(k)} = \frac{\left\langle \mathbf{x}^{(k)}, \mathbf{x}^{(k-1)} \right\rangle}{\left\langle \mathbf{x}^{(k-1)}, \mathbf{x}^{(k-1)} \right\rangle} = \lambda_1 + \mathrm{O}\left(\left| \frac{\lambda_2}{\lambda_1} \right|^{2k-1} \right),$$
$$\left\| \mathbf{x}^{(k)} \right\| = \left\langle \mathbf{x}^{(k)}, \mathbf{x}^{(k)} \right\rangle^{1/2} = \left| \lambda_1 \right|^k \left(c_1 + \mathrm{O}\left(\left| \frac{\lambda_2}{\lambda_1} \right|^k \right) \right), \quad (2.57)$$
$$\mathbf{e}_1^{(k)} = \frac{\mathbf{x}^{(k)}}{\left\| \mathbf{x}^{(k)} \right\|} = \left(sign \lambda_1 \right)^k \mathbf{e}_1^1 + \mathbf{r}^{(k)},$$

где $\mathbf{e}_1^1 = \left(sign c_1 \right) \mathbf{e}_1$, $\left\| \mathbf{r}^{(k)} \right\| = \mathbf{O}\left(\left| \frac{\lambda_2}{\lambda_1} \right|^k \right)$, $sign \mathrm{x} = \begin{cases} -1, \mathrm{x} < 0, \\ 1, \mathrm{x} > 0. \end{cases}$

Таким образом, при условии (2.54) итерационный процесс (2.55) позволяет найти с любой точностью максимальное по модулю собственное значение λ_1 (ибо $\lambda_1^{(k)} \to \lambda_1$ при $k \to \infty$) и соответствующий ему собственный вектор $\mathbf{e}_1$, так как $\|\mathbf{r}^{(k)}\| \to 0$ при $k \to \infty$.

Рассмотрим некоторые замечания:

1. Если $|\lambda_1|>1$, то $\|\mathbf{x}^{(k)}\| \to \infty$, а если $|\lambda_1|<1$, то $\|\mathbf{x}^{(k)}\| \to 0$ при $k \to \infty$. То и другое явление при счете на машине нежелательно (в одном случае произойдет переполнение, в другом – появляется машинный ноль). Поэтому следует итерации вести по формулам

$$\mathbf{e}_1^{(0)} = \frac{\mathbf{x}^{(0)}}{\left\|\mathbf{x}^{(0)}\right\|},$$

$$\mathbf{x}^{(k)} = \mathbf{A}\mathbf{e}_1^{(k-1)}, \quad \lambda_1^{(k)} = \left\langle \mathbf{x}^{(k)}, \mathbf{e}_1^{(k-1)} \right\rangle, \quad \mathbf{e}_1^{(k)} = \frac{\mathbf{x}^{(k)}}{\left\|\mathbf{x}^{(k)}\right\|},$$

не имеющим указанного недостатка и дающим тот же результат (те же $\mathbf{e}_1^{(k)}, \lambda_1^{(k)}$), что и формулы (2.55), (2.56).

2. Если при выборе $\mathbf{x}^{(0)}$ будет выполнено c_1=0, то за счет ошибок округлений через несколько итераций появится ненулевая компонента, отвечающая $\mathbf{e}_1$. Тогда с некоторым запаздыванием итерационный процесс выйдет на первое собственное значение.

Рассмотрим теперь задачи, решение которых сводится к отысканию максимального по модулю собственного значения некоторой матрицы **B=*g*(A),** такой, что это собственное значение соответствует отыскиваемому собственному значению матрицы **A**. В качестве такой матрицы **B** часто берется матрица вида

$$\mathbf{B}=a_0\mathbf{E}+a_1\mathbf{A}+a_2\mathbf{A}^2+\ldots+a_m\mathbf{A}^m, \qquad (2.58)$$

собственные числа $\lambda_i(\mathbf{B})$ которой, согласно (2.51), связаны с собственными числами $\lambda_i(\mathbf{A})$ матрицы **A** соотношением

$$\lambda_i(\mathbf{B}) = a_0 + a_1\lambda_i(\mathbf{A}) + a_2\lambda_i^2(\mathbf{A}) + \ldots + a_m\lambda_i^m(\mathbf{A}), \quad i = 1, 2, \ldots, n. \quad (2.59)$$

Перейдем к решению конкретных задач.

Нахождение минимального и максимального собственного значения

Пусть найдено наибольшее по модулю собственное значение λ_1 матрицы **A.** Возможны два случая:

1. $\lambda_1>0$, т. е. $\lambda_1=\lambda_{max}(\mathbf{A})$. Для нахождения $\lambda_{min}(\mathbf{A})$ возьмем матрицу

$$\mathbf{B}= \lambda_1\mathbf{E} - \mathbf{A},$$

собственными значениями которой являются числа $\lambda_i(\mathbf{B}) = \lambda_1 - \lambda_i(\mathbf{A}) \geq 0$ для любого i=1, 2, …, n. Тогда $\lambda_{max}(\mathbf{B}) = \lambda_1 - \lambda_{min}(\mathbf{A})$. Причем $\lambda_{\max}(\mathbf{B}) = \max\limits_{1\le i\le n}|\lambda_i(\mathbf{B})|$ в силу неотрицательности спектра матрицы **B.** Определив максимальное по модулю значение $\lambda_{max}(\mathbf{B})$ итерационным методом (2.57), находим минимальное собственное значение матрицы **A**:

$$\lambda_{min}(\mathbf{A}) = \lambda_1 - \lambda_{max}(\mathbf{B}).$$

2. $\lambda_1<0$, т. е. $\lambda_1 = \lambda_{min}(\mathbf{A})$. В этом случае, проведя аналогичные рассуждения для матрицы $\mathbf{B}=\mathbf{A} - \lambda_1\mathbf{E}$, максимальное собственное значение матрицы $\mathbf{A}$ находим по формуле

$$\lambda_{max}(\mathbf{A}) = \lambda_1 + \lambda_{max}(\mathbf{B}).$$

Нахождение расстояния ρ_0 *от заданной точки* $\lambda=\lambda^0$ *до ближайшего собственного значения матрицы.* Рассмотрим случай, представляющий наибольший интерес:

$$\min_{1\le i\le n} \lambda_i(\mathbf{A}) \le \lambda^0 \le \max_{1\le i\le n} \lambda_i(\mathbf{A}).$$

Обозначим

$$\begin{aligned} \rho_0 &= \min_{1\le i\le n} \left|\lambda_i(\mathbf{A}) - \lambda^0\right|, \\ l &= \max\left\{\max_{1\le i\le n} \lambda_i(\mathbf{A}) - \lambda^0, \lambda^0 - \min_{1\le i\le n} \lambda_i(\mathbf{A})\right\}. \end{aligned} \qquad (2.60)$$

Докажем, что

$$\rho_0 = l\sqrt{1-\bar{\lambda}(\mathbf{B})},$$

где $\bar{\lambda}(\mathbf{B})$ – максимальное по модулю собственное значение матрицы

$$\mathbf{B} = \mathbf{E} - \frac{1}{l^2}\left(\mathbf{A} - \lambda^0\mathbf{E}\right)^2,$$

где $\mathbf{E}$ – единичная матрица. Поскольку матрица $\mathbf{B}$ – матрица вида (2.58), то, учитывая (2.59) и (2.60), имеем для любого $i=1, 2, \ldots, n$

$$\lambda_i(\mathbf{B}) = 1 - \frac{1}{l^2}\left(\lambda_i(\mathbf{A}) - \lambda^0\right)^2 \ge 0.$$

Отсюда

$$\bar{\lambda}(\mathbf{B}) = 1 - \frac{1}{l^2}\left(\lambda^*(\mathbf{A}) - \lambda^0\right)^2 = 1 - \frac{\rho_0^2}{l^2},$$

где $\lambda^*(\mathbf{A})$ – ближайшее к λ^0 собственное значение матрицы $\mathbf{A}$. Следовательно, расстояние ρ_0 от произвольной точки λ^0 спектра матрицы $\mathbf{A}$ до ближайшего собственного значения матрицы равно

$$\rho_0 = l\sqrt{1-\bar{\lambda}(\mathbf{B})}.$$

Замечание. Если $\lambda^0=0$, то ρ_0 – это расстояние от нуля до ближайшего собственного значения матрицы **A**, т.е. $\rho_0=|\lambda_n|$, где λ_n - *минимальное по модулю собственное значение матрицы* **A**.

3. ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ АЛГЕБРАИЧЕСКИХ УРАВНЕНИЙ ВЫСШИХ ПОРЯДКОВ И ТРАНСЦЕНДЕНТНЫХ УРАВНЕНИЙ.

В этом разделе мы рассмотрим некоторые методы численного решения нелинейного скалярного уравнения вида

$$f(x)=0, \quad (3.1)$$

где $f(x)$ – заданная функция действительного аргумента x, в частности, $f(x)$ может быть многочленом степени n от x.

Будем считать $f(x)$ непрерывной функцией на отрезке $[a,b]\subseteq D$ (a, b – могут быть $\pm\infty$). Всякое число x^* из D такое, что

$$f(x^*)=0,$$

называется корнем уравнения (3.1) или нулем функции $f(x)$. Пусть $f(x)$ – гладкая функция (т.е. функция, имеющая достаточное число производных). Число x^* называется корнем k–кратности, если при $x=x^*$ вместе с функцией $f(x)$ в нуль обращаются все ее производные до (k–1) – й включительно:

$$f(x^*)=f'(x^*)=\ldots=f^{(k-1)}(x^*)=0,\ f^{(k)}(x^*)\neq 0.$$

Однократный корень называется простым.

Алгебраическим уравнением с одним неизвестным называется уравнение вида:

$$x^n+a_{n-1}x^{n-1}+\ldots+a_1x+a_0=0, \quad (3.2)$$

где n – целое неотрицательное число, называемое степенью уравнения; a_0, a_1, … ,a_{n-1} – коэффициенты уравнения; x – неизвестное, которое следует определить.

Известно, что алгебраическое уравнение (3.2) степени n имеет ровно n корней, если любой k – кратный корень считать столько раз, какова его кратность.

Для нелинейного уравнения справедливы утверждения:

Пусть $f(x)\in C_{[a,b]}$. Если $f(a)\cdot f(b)<0$, то между a и b имеется нечетное число корней. Если $f(a)\cdot f(b)>0$, то между a и b существует четное число корней или их нет вовсе.

Если $f(x) \in C^1_{[a,b]}$, $f(a)\cdot f(b)<0$ и $f'(x)$ не меняет знака на $[a,b]$, то между a и b содержится ровно один корень уравнения.

Если уравнение $f(x)=0$ не является алгебраическим, то уравнение (3.1) называется трансцендентным. Например,

$$f(x) \equiv tg(x) - \frac{1}{x} = 0.$$

Трансцендентное уравнение иногда можно свести к алгебраическому нелинейному уравнению.

При отыскании корня уравнения (3.1) решаем две задачи.

Задача 1. Отделение корней, т.е. отыскание достаточно малых областей, в каждой из которых заключен один и только один корень уравнения.

Задача 2. Вычисление корней с заданной точностью.

3.1 Устойчивые решения, число обусловленности функции одной переменой.

Решение прикладных задач, как правило, начинается с создания приемлемых физических и математических моделей. Пусть есть точно поставленная задача: найти на промежутке $[a,b]$ корень уравнения

$$\overline{f}(x) = 0, \quad a \le x \le b. \quad (3.3)$$

И пусть ищутся корни приближенного уравнения

$$f(x) = 0, \quad a \le x \le b, \quad (3.4)$$

с указанием погрешности в исходных данных:

$$\left|\overline{f}(x) - f(x)\right| < \varepsilon, \quad \varepsilon > 0, \quad a \le x \le b. \quad (3.5)$$

Рассмотрим некоторые трудности, возникающие при решении задач (3.3)–(3.5).

1. Пусть имеется уравнение

$$e^x = \varepsilon,$$

с решением $x = ln\varepsilon$,где ε –малое число. Ошибка в исходных данных может привести к уравнению $e^x=0$, не имеющему конечного решения, так как не существует конечного значения x, для которого выполнено равенство $e^x=0$.

2. Нетрудно убедиться, что уравнение

$$x^2-2x+1=0$$

имеет корни $x_1^*=1, x_2^*=1,$ а уравнение

$$x^2-2x+1.01=0$$

обладает корнями $x_1^*=1+0.1i, x_2^*=1-0.1i.$ В этом случае погрешность (ε=0.01) в исходных данных вывела корни уравнения $x^2-2x+1=0$ из области действительных чисел и перевела их в область комплексных чисел.

3. Уравнение

$$x^{1/3}-2x^{1/6}+1=0$$

имеет действительный корень $x^*=1$, а уравнение

$$x^{1/3}-2x^{1/6}+0.99=0,$$

отличающееся от предыдущего лишь погрешностью в свободном члене $\varepsilon=10^{-2}$ имеет действительные корни $x_1^*=1.771561, x_2^*=0.531441.$

Решение уравнения (3.2) называется *устойчивым*, если малым изменениям в исходных данных соответствуют малые изменения в решении. Иными словами, если $\left|\overline{f}(x)-f(x)\right|<\varepsilon$ при всех $x\in[a,b]$, то и

$$\left|\bar{x}^*-x^*\right|\le\delta(\varepsilon),$$

где $\bar{x}^*$ – точное решение уравнения $\overline{f}(\bar{x}^*)=0$, x^* – точное решение уравнения $f(x^*)=0$; ε, δ(ε) – сколь угодно малые числа.

Рассмотрим условия, при которых за решение исходной математической модели (уравнение (3.3)) можно принять решение задачи (3.4)–(3.5). Для этого оценим разность уравнений через погрешность в исходных данных и функцию (3.4). Справедливо равенство:

$$f(\bar{x}^*)=f(x^*)-f'(\theta)(x^*-\bar{x}^*),\text{ где } \theta\in[\bar{x}^*,x^*]\subset[a,b]$$

или, так как $f(x^*)\equiv 0$

$$x^*-\bar{x}^*=-\frac{f(\bar{x}^*)}{f'(\theta)}\text{ при } f'(\theta)\ne 0.$$

Обозначим через δf разность в точке $\bar{x}^*$ функций $\bar{f}(\bar{x}^*) - f(\bar{x}^*) = \delta f$, т.е. δf – вариация функций точной и приближенной в точке $\bar{x}^*$. Получим сразу, учтя то обстоятельство, что $\bar{f}(\bar{x}^*) \equiv 0$,

$$x^* - \bar{x}^* = \frac{\delta f}{f'(\theta)}.$$

Тогда

$$\left|x^* - \bar{x}^*\right| \le \delta f \cdot \left(\min_{a \le x \le b} \left|f'(x)\right|\right)^{-1}.$$

Назовем величину

$$M = \frac{1}{\min\limits_{a \le x \le b} \left|f'(x)\right|} = \left(\min_{a \le x \le b} \left|f'(x)\right|\right)^{-1} \quad (3.6)$$

локальным *числом обусловленности* функции $f(x)$. При этом величина, которая будет определять характер обусловленности задачи (3.4)–(3.5) есть следующая величина:

$$m = \left|\delta f\right| \cdot \left(\min_{a \le x \le b} \left|f'(x)\right|\right)^{-1} = M \cdot \left|\delta f\right|. \quad (3.7)$$

Чем больше (меньше) m на отрезке $[a, b]$, где находится корень уравнения, тем хуже (лучше) обусловленность задачи. Так в нелинейном уравнении (п.3):

$$x^{1/3} - 2x^{1/6} + 0.99 = 0, \quad \delta f = 0.01;$$

$$f'(x) = \frac{1}{3}\left(x^{-2/3} - x^{-5/6}\right);$$

$\min f'(x) = 0$ при $x=1$. Следовательно, эта функция $f(x) \equiv x^{1/3} - 2x^{1/6} + 0.99$ плохо обусловлена для функции $\bar{f}(x) \equiv x^{1/3} - 2x^{1/6} + 1$, а оценка $\left|x^* - \bar{x}^*\right| \le \infty$. Хотя эта оценка носит мажорантный (оценочный) характер, она должна настораживать.

Каждый корень обладает своим числом обусловленности, зная которое можно оценить наследственную погрешность решения.

Займемся первой из поставленных задач при нахождении корней уравнения $f(x)=0$.

3.2 Отделение корней

Существуют несколько различных способов отделения корней уравнения: теорема Штурма, теорема о перемене знака функции $f(x)$ и ее производной на

промежутке изменения $f(x)$, графический способ и т.п. Часто для отыскания грубых значений корней можно построить график функции $y=f(x)$ и найти абсциссы точек пересечения графика с осью x. Иногда удобней представить уравнение $f(x)=0$ в виде $\varphi(x)=\psi(x)$, а затем построить графики функций $y=\varphi(x)$, $y=\psi(x)$ и найти абсциссы их точек пересечения, которые приближенно равны значениям корней. Опишем один из способов отделения корней (графический) на примере.

Пример. Найти корни уравнения

$$x\sin x = 1 \quad \text{или} \quad f(x) \equiv x\sin x - 1 = 0.$$

Решение.

Представим функцию $f(x)$ в виде $\sin x = x^{-1}$ и применим графический способ нахождения корней этого уравнения (рис. 3.1).

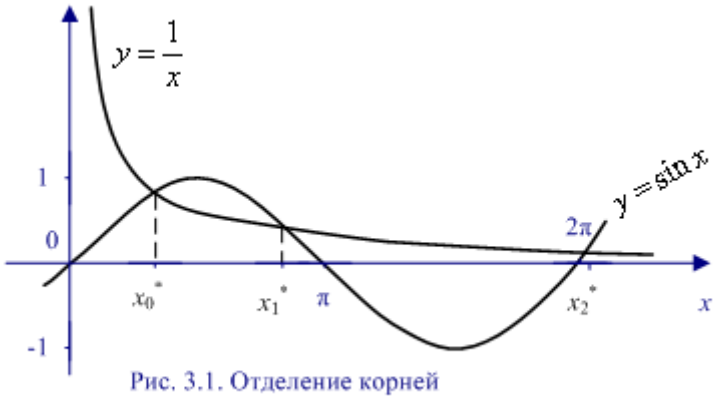

Рис. 3.1. Отделение корней

Корни уравнения симметричны относительно оси $0y$, поэтому мы можем рассмотреть только положительные корни. Значения $x_0^*, x_1^*, \ldots$ могут быть определены довольно точно, но $x_n^*, n \to \infty$, мы определить не сможем. Тем не менее по графику ясно, что x_n^* при n>>1 близки к $n\pi$. Все эти полученные приближения к корням уравнения мы можем взять за начальное значения $(x_0^*)^0, (x_1^*)^0, (x_2^*)^0, \ldots$ и приступить к задаче 2 уточнения корней.

3.3 Методы уточнения корней уравнения

После того, как корни отделены или для них получены хорошие начальные приближения $\left(x_n^*\right)^0$, появляется возможность вычислить их с заданной точностью. Методы, используемые для уточнения корней уравнения $f(x)=0$ при заданном $\left(x_n^*\right)^0$ на промежутке $[a, b]$, в котором находится один единственный корень, разнообразны. Это может быть метод половинного деления; метод секущих; метод Ньютона и другие итерационные методы; метод наискорейшего спуска и т.д. Рассмотрим некоторые из перечисленных выше методов.

Метод простых итераций. Для нахождения изолированного корня x^* уравнения $f(x)=0$, $a \le x \le b$ заменим исходное уравнение равносильным

$$x=\varphi(x) \quad (3.8)$$

и организуем итерационный процесс вида

$$x_{n+1}=\varphi(x_n),\ n=0,\ 1,\ 2,\ldots, \quad (3.9)$$

где x_0 – заданное начальное приближение.

Можно показать что, если

1) $|\varphi'(x)| \le \alpha < 1$ при $|x - x_0| \le r$,
2) $|\varphi(x_0) - x_0| \le r(1 - \alpha)$,

то начатый с x_0 метод простых итераций сходится к единственному на отрезке $[x_0 - r,\ x_0+r]$ корню уравнения (3.8). Причем справедливы оценки погрешности $(\forall n = 1, 2, \ldots,)$:

$$\left|x^* - x_n\right| \le \frac{\alpha}{1-\alpha}\left|x_n - x_{n-1}\right|,$$

$$\left|x^* - x_n\right| \le \frac{\alpha^n}{1-\alpha}\left|x_1 - x_0\right|.$$

Выбор функции $\varphi(x)$ в итерационном процессе имеет большое значение и может быть осуществлен не единственным образом.

Предположим, что итерационным методом следует найти корни уравнения $x^2 - 1 = 0$ на отрезке [0.1; 1.1].

Если итерационную схему записать в виде $x_{n+1} = x_n + x_n^2 - 1$, то $\varphi(x)=x^2-1+x$. При этом $\varphi'(x)=2x+1$. Очевидно, что $\varphi'(x) \ge \varphi'(0.1)=1.2$ на промежутке [0.1; 1.1].

Следовательно, α>1 и итерационный процесс с такой функцией φ(x) не сходится.

Если вести итерационный процесс по формуле

$$x_{n+1} = x_n - \frac{1}{3}\left[x_n^2 - 1\right],$$

т.е. с $\varphi(x) = x - \frac{1}{3}\left[x^2 - 1\right]$, то $\varphi'(x) = 1 - \frac{2}{3}x$ и $\alpha = \max\limits_{0.1 \le x \le 1.1} |\varphi'(x)| = \frac{14}{15} < 1$, следовательно процесс сходится.

Итерационный метод Ньютона.

Пусть нужно найти изолированный корень $x^* \in [a,b]$ уравнения $f(x)=0$. Предположим, что $f(x) \in C^1_{[a,b]}$. Тогда функцию $f(x)$ в любой точке отрезка $[a,b]$, в том числе и в точке $x=x^*$ можно представить через формулу Тейлора

$$f(x^*) = f(x_0) + (x^* - x_0) f'(x_0) + O((x^* - x_0)^2),$$

где $x_0 \in [a,b]$ – заданное начальное приближение. Но $f(x^*)=0$, и корень x^* удовлетворяет уравнению

$$f(x_0) + (x^* - x_0) f'(x_0) + O((x^* - x_0)^2) = 0,$$

решить которое точно нельзя, т. к. неизвестно $O((x^* - x_0)^2)$. Отбросив в предыдущем равенстве последнее слагаемое, приходим к линейному уравнению, решив которое получим

$$x^* \approx x_0 - \frac{f(x_0)}{f'(x_0)}.$$

Это приближенное значение корня обозначим за x_1 и найдем следующее приближение x_2 по формуле $x_2 = x_1 - \frac{f(x_1)}{f'(x_1)}$ и т.д. Таким образом, метод Ньютона дает следующий итерационный процесс

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}, \quad n = 0, 1, 2, \ldots \quad (3.10)$$

На рис.3.2 показана геометрическая интерпретация метода Ньютона. Уравнение касательной к графику функции $y=f(x)$, проходящей через точку с координатами (x_n, $f(x_n)$), имеет вид $y=f'(x_n)(x-x_n)+f(x_n)$. Преобразованием формулы (3.10) легко убедиться, что x_{n+1} является абсциссой точки

пересечения этой касательной с осью *0x*. Отсюда другое название метода Ньютона – метод касательных.

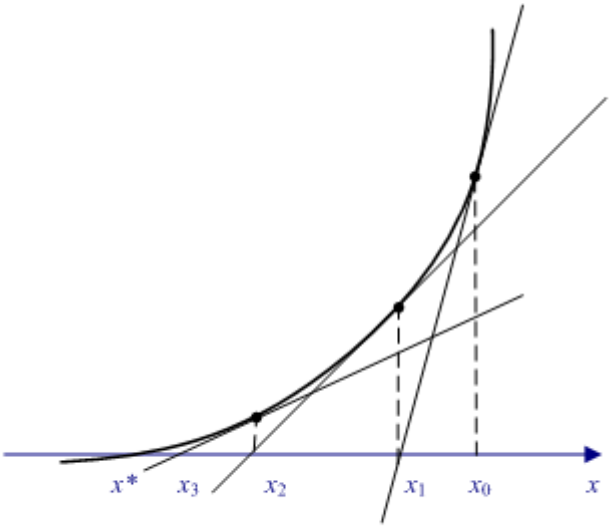

Рис.3.2. Приближения к корню нелинейного уравнения методом касательных

Пусть выполнены следующие условия:

1) $f(a)\cdot f(b)<0$,

2) Производные $f'(x)$ и $f''(x)$ сохраняют знак на $[a, b]$,

Тогда, если в качестве x_0 выбран один из концов отрезка $[a, b]$ так, что $f(x_0)\cdot f''(x_0)>0$, метод Ньютона сходится.

Пример. Применим метод Ньютона для приближенного вычисления квадратного корня из числа $a>0$. В этом случае речь идет о приближенном решении уравнения $x^2 - a=0$, т.е. формулу (3.10) следует применить к функции $f(x)=x^2 - a$.

Поскольку $f'(x)=2x$, то для последовательных приближенных значений x_n корня $\sqrt{x}$ имеем рекуррентную формулу

$$x_{n+1} = x_n - \frac{x_n^2 - a}{2x_n},$$

или

$$x_{n+1} = \frac{1}{2}\left(x_n + \frac{a}{x_n}\right).$$

В качестве начального приближения можно взять положительное число x_0, такое что $x_0^2 > a$. При этом выполняется условие $f(x_0)\cdot f''(x_0)>0$, т.к. $f''(x)=2$ и

обеспечивается знакопостоянство $f'(x)$, т. е метод Ньютона будет сходиться. Например, для a=4 и начальной точки x_0=4 в вычислительных экспериментах получены значения x_1=2.5, x_2≈2.05, x_3≈2.0006 и x_4=2 с погрешностью менее 10^{-15}. Отметим, что в различных языках программирования именно эта процедура используется в качестве стандартной функции извлечения квадратного корня.

Замечание. Кроме сходимости итерационного процесса необходима и эффективность. Чаще всего в качестве критерия эффективности итерационного процесса выбирают скорость сходимости.

Так, начиная с некоторого n_0, скорость сходимости метода Ньютона становится квадратичной, т.е. для всех $n>n_0$ выполняется неравенство

$$\left|x^* - x_{n+1}\right| \le c \cdot \left|x^* - x_n\right|^2, \quad (3.11)$$

где c>0 – некоторая постоянная. (На порядок скорости сходимости указывает показатель степени в правой части неравенства (3.11). В данном случае его значение равно 2).

4. ЧИСЛЕННЫЕ МЕТОДЫ ПРИБЛИЖЕНИЯ ФУНКЦИЙ

Приближением функции называется процедура замены по определенному правилу функции f близкой к ней в том или ином смысле функцией g из некоторого фиксированного множества. В качестве приближающего множества часто берут подпространство алгебраических или тригонометрических многочленов (полиномов). Более гибкий и мощный аппарат приближения получают, рассматривая обобщенные полиномы

$$g(x, a_0, a_1, \ldots, a_n) = \sum_{i=0}^{n} a_i \varphi_i(x), \quad (4.1)$$

где φ_0, φ_1,…, φ_n – некоторая система линейно независимых функций, выбираемая с учетом конкретных условий задачи и требований, предъявляемых к функции g. В дальнейшем будем считать, что функция g есть полином вида (4.1).

Мерой погрешности приближения является, как правило, расстояние (метрика) $\rho(f,g)$ между приближаемой и приближающей функциями. Способ оценки расстояния определяется конкретными условиями задачи и имеющейся информацией о приближаемой функции f. Наиболее часто погрешность приближения на интервале $[a,b]$ оценивается в равномерной

$$\rho(f,g)_C = \max_{[a,b]} |f(x) - g(x)| \quad (4.2)$$

и среднеквадратичной

$$\rho(f,g)_{L_2} = \left\{ \int_a^b [f(x) - g(x)]^2 \, \mathrm{d}x \right\}^{1/2} \quad (4.3)$$

метриках, где $[a,b]$ – интервал, на котором строится приближение.

При выборе метода приближения естественно стремление обеспечить более высокую точность приближения и одновременно простоту процедуры построения g. Первое требование связано с вопросом существования полинома наилучшего приближения, т.е. полинома g^* удовлетворяющего условию

$$\rho(f,g^*) \le \rho(f,g), \quad \forall g \quad (4.4)$$

(Знак $\forall$ – означает «любой», для «любого»).

Для метрик (4.2) и (4.3) сформулированы и доказаны необходимые и достаточные условия существования таких полиномов. В данном пособии рассматривается процедура построения полинома наилучшего приближения в среднеквадратичной метрике.

Рассмотрим две постановки задачи приближения.

Пусть в отдельных точках $x_0, x_1, \ldots, x_n$ интервала $[a,b]$ заданы значения функции $f(x_j)$; требуется восстановить ее значения при других $x \in [a,b]$. Если параметры $a_0, a_1, \ldots, a_n$ определяются из условий совпадения значений приближаемой и приближающей функций в точках x_j:

$$g(x_j)=f(x_j), \quad j=0, 1, \ldots, n, \quad (4.5)$$

то такой способ приближения называют *интерполяцией,* а точки x_j, $j=0, 1, \ldots, n$ – узлами интерполяции. Условия (4.5) носят названия условий интерполяции. (Первоначально задачей интерполяции называли задачу вычисления значения

функции f в некоторой внутренней точке x^* интервала $[a,b]$ с использованием значений функции $f(x_j)$, вычисленных в точках x_j, $j=0, 1, \ldots, n$ этого интервала. До сих пор задачей экстраполяции называют задачу вычисления значения функции f в точке x^*, находящейся вне интервала $[a,b]$).

Предположим, что алгоритм построения приближающей функции не требует выполнения условия (4.5), и значения функции вычисляются в произвольных точках, тогда говорят об аппроксимации функции.

2. Пусть функция f задана таблично по результатам измерений, т.е. значения функции $f(x_j)$, вычисленные в точках $j=0, 1, \ldots, n$, содержат ошибки ε_j. Построение приближающего полинома интерполяционным методом с использованием условий совпадения значений приближаемой и приближающей функций в узлах привело бы к повторению имеющихся ошибок.

Практика показала, что полином g^*, минимизирующий погрешность приближения в среднеквадратичной метрике, значительно лучше представляет функцию f. Таким образом, аппроксимирующий полином g^* строится из условия

$$\rho\left(f, g^*\left(a_0^*, a_1^*, \ldots, a_n^*, x\right)\right)_{L_2} = \min_{a_0, a_1, \ldots, a_n} \rho\left(f, g\left(a_0, a_1, \ldots, a_n, x\right)\right)_{L_2}.$$

Процедура построения таких приближений носит название метода наименьших квадратов.

Прежде чем перейти к изложению численных методов приближения функций необходимо сказать несколько слов о характере погрешности, возникающей в ходе приближения. Наибольший вклад в погрешность приближения вносит, как правило, неустранимая погрешность. Обычно она обусловлена неполной и неточной информацией о приближаемой функции (неточность значений функции, недостаточная информация о гладкости, т.е. о поведении между узлами сетки и т.д.). Уточнение информации о приближаемой функции служат основой для выбора численного метода, дающего более точное приближение. Помимо этого анализ неустранимой погрешности часто приводит к существенному упрощению процедуры вычислений. Например, если значения функции получаются в результате измерений, то нецелесообразно выполнять

приближения с точностью более высокой, чем относительная погрешность измерений.

4.1 Интерполяция функций

Интерполяционный многочлен Лагранжа. Пусть на интервале $[a,b]$ задана система интерполяционных узлов, в которых известны значения функции $f(x_j)$. Задача интерполяции алгебраическими многочленами состоит в построении многочлена

$$L_n(x) = a_0 + a_1 x + a_2 x^2 + \ldots a_n x^n$$

степени n, значения которого в заданных узлах интерполяции совпадают со значениями функции f в этих узлах:

$$L_n(x_j) = f(x_j), \quad j = 0,1,\ldots,n. \quad (4.6)$$

Покажем, что поставленная задача имеет единственное решение. Для вычисления коэффициентов a_i, $i=0,1,\ldots,n$, составим систему линейных уравнений

$$a_0 + a_1 x_j + a_2 x_j^2 + \ldots a_n x_j^n = f(x_j), \quad j = 0,1,\ldots,n. \quad (4.7)$$

Определитель системы (4.7) имеет вид

$$\begin{vmatrix} 1 & x_0 & x_0^2 & \ldots & x_0^n \\ 1 & x_1 & x_1^2 & \ldots & x_1^n \\ \ldots & \ldots & \ldots & \ldots & \ldots \\ 1 & x_n & x_n^2 & \ldots & x_n^n \end{vmatrix}$$

и называется определителем Вандермонда. Такой определитель отличен от нуля, если $x_i \neq x_j$ при $i \neq j$. В этом случае система (4.6) имеет единственное решение.

Интерполяционный многочлен естественно искать в виде линейной комбинации $L_n(x) = \sum_{i=0}^{n} P_i(x) f(x_i)$ многочленов n – й степени $P_i(x)$ $(i=0,1,\ldots,n)$. Удовлетворяя условиям интерполяции (4.6), получаем соотношения

$$\sum_{i=0}^{n} P_i(x_j) f(x_i) = f(x_j), \quad j = 0,1,\ldots,n,$$

которые выполняются, если на функции $P_i(x)$ наложить ограничения

$$P_i(x_j)=\begin{cases}0, & i\neq j\\ 1, & i=j,\quad i,j=0,1,\ldots,n.\end{cases}$$

Последние условия означают, что каждый из многочленов $P_i(x)$ (i=0, 1, …, n) имеет не менее n нулей на интервале $[a,b]$. Поэтому $P_i(x)$ можно записать в виде

$$P_i(x)=A_i(x-x_0)(x-x_1)\ldots(x-x_{i-1})(x-x_{i+1})\ldots(x-x_n),$$

где коэффициент A_i находится из условия $P_i(x_i)=1$, т.е.

$$1=A_i(x_i-x_0)(x_i-x_1)\ldots(x_i-x_{i-1})(x_i-x_{i+1})\ldots(x_i-x_n),$$

Следовательно, искомые функции $P_i(x)$ вычисляются по формулам

$$P_i(x)=\frac{\prod\limits_{j\neq i}(x-x_j)}{\prod\limits_{j\neq i}(x_i-x_j)}.$$

Отсюда интерполяционный многочлен имеет вид

$$L_n(x)=\sum_{i=0}^{n}\frac{\prod\limits_{j\neq i}(x-x_j)}{\prod\limits_{j\neq i}(x_i-x_j)}f(x_i). \quad (4.8)$$

Форма представления интерполяционного многочлена в виде (4.8) называется формой Лагранжа. Если ввести обозначение

$$\omega_n(x)=(x-x_0)(x-x_1)\ldots(x-x_n),$$

то многочлен Лагранжа можно записать в виде

$$L_n(x)=\sum_{i=0}^{n}f(x_i)\frac{\omega_n(x)}{(x-x_i)\omega_n'(x)}.$$

Схема Эйткена. Для вычисления значений $L_n(x)$ в заданной точке x^* обычно используют алгоритм Эйткена. Обозначим $f(x_j)=y_j$. Построим многочлен первой степени $L_{01}(x)$ по формуле

$$L_{01}(x)=\frac{(x_1-x)y_0-(x_0-x)y_1}{x_1-x_0}.$$

Очевидно, что $L_{01}(x)$ является интерполяционным многочленом для узлов x_0 и x_1: $L_{01}(x_0)=y_0$; $L_{01}(x_1)=y_1$. Аналогично вычисляются многочлены первой

степени $L_{i(i+1)}(x)$, i=1, 2,…, n–1. Далее построим интерполяционный многочлен $L_{012}(x)$ второй степени по правилу

$$L_{012}(x)=\frac{(x_2-x)L_{01}(x)-(x_0-x)L_{12}(x)}{x_2-x_0}.$$

Нетрудно проверить, что $L_{012}(x)$ удовлетворяет условиям интерполяции в узлах x_0, x_1, x_2. Аналогично вычисляются остальные многочлены второй степени $L_{i(i+1)(i+2)}(x)$, i=1, 2,…, n–2 и т.д.

Для всей системы узлов имеем интерполяционный многочлен

$$L_{01..n}(x)=\frac{(x_n-x)L_{01..n-1}(x)-(x_0-x)L_{12..n}(x)}{x_n-x_0}.$$

В общем случае для интерполяционного многочлена на узлах i, i+1,…, $i+m$ имеет место рекуррентное соотношение

$$L_{i(i+1)..(i+m)}(x)=\frac{(x_{i+m}-x)L_{i(i+1)..(i+m-1)}(x)-(x_i-x)L_{(i+1)..(i+m)}(x)}{x_{i+m}-x_i}.$$

В целом для вычисления значений $L_n(x)$ в точке x^* можно выписать следующую вычислительную схему:

x_i	y_i	x_i–x^*	$L_{(i-1)i}$	$L_{(i-2)(i-1)i}$	$L_{(i-3)(i-2)(i-1)i}$	$L_{(i-4)(i-3)(i-2)(i-1)i}$	…
x_0	y_0	x_0–x^*					
x_1	y_1	x_1–x^*	$L_{01}(x^*)$				
x_2	y_2	x_2–x^*	$L_{12}(x^*)$	$L_{012}(x^*)$			
x_3	y_3	x_3–x^*	$L_{23}(x^*)$	$L_{123}(x^*)$	$L_{0123}(x^*)$		
x_4	y_4	x_4–x^*	$L_{34}(x^*)$	$L_{234}(x^*)$	$L_{1234}(x^*)$	$L_{01234}(x^*)$	
…	…	…	……..	…….	……..	……	…

Форма записи (4.8) интерполяционного многочлена Лагранжа удобна тем, что явно выражена зависимость от каждого значения приближаемой функции в узлах интерполяции. Однако с вычислительной точки зрения она менее эффективна по сравнению с другими формами. Число операций при расчете $L_n(x)$ составляет 4n–1, в то время как для интерполяционного многочлена в форме Ньютона, который будет обсуждаться ниже, оно равно 3n–2. Важно также, что при изменении числа интерполяционных узлов x_i все коэффициенты $P_i(x)$ многочлена Лагранжа должны пересчитываться заново.

Прежде, чем перейти к выводу интерполяционной формулы Ньютона, введем понятие конечных и разделенных разностей.

Конечные разности. Рассмотрим равномерную сетку узлов $x_k=x_0+kh$, $h>0$, $k=0, 1, \ldots, n$, в которых вычисляются значения функции f: $f(x_k)=y_k$. Величина

$$\Delta y_k = y_{k+1} - y_k$$

называется конечной разностью первого порядка функции f в точке x_k (с шагом h). Далее

$$\Delta^2 y_k = \Delta(\Delta y_k) = \Delta y_{k+1} - \Delta y_k = y_{k+2} - 2y_{k+1} + y_k$$

есть конечная разность второго порядка в точке x_k. В общем случае конечная разность n–го порядка функции f в точке x_k определяется по рекуррентной формуле

$$\Delta^n y_k = \Delta^{n-1}(\Delta y_k) = \Delta^{n-1} y_{k+1} - \Delta^{n-1} y_k.$$

Свойство конечных разностей. Предположим, что функция $f \in C^n_{[x_k, x_{k+n}]}$, тогда существует такая точка $\xi \in (x_k, x_{k+n})$, что

$$\Delta^n y_k = h^n f^{(n)}(\xi). \quad (4.9)$$

Доказательство свойства проводится с использованием формулы конечных приращениий Лагранжа [1]. Имеют место два важных на практике следствия.

1. Если $f \in C^{n+1}_{[x_0, x_{n+1}]}$, то при достаточно малом шаге имеет место приближенное равенство

$$f^{(n+1)}(\xi) \approx \frac{\Delta^{n+1} y_0}{h^{n+1}}, \text{ где } \xi \in [x_0, x_{n+1}].$$

Эта конечно–разностная оценка используется на практике, если выражение производной $f^{(n+1)}(x)$ сложно для вычислений или $(n+1)$ раз дифференцируемая функция задана таблично.

2. Конечные разности n – го порядка от многочлена степени n постоянны и не зависят от k, а конечные разности более высоких порядков равны нулю.

Это обстоятельство используется при выборе степени интерполяционного многочлена Ньютона для равномерной сетки узлов, поскольку приблизительное равенство значений конечных разностей порядка n некоторой константе

указывает соответственно на близость приближаемой функции на заданном участке к многочлену этой степени.

Разделенные разности. Пусть x_0, x_1, …, x_n – произвольная система попарно несовпадающих узлов. Значения $f(x_j)$ называются разделенными разностями нулевого порядка. Величины

$$f(x_i;x_k)=\frac{f(x_k)-f(x_i)}{x_k-x_i}$$

называются разделенными разностями первого порядка функции $f(x)$. Очевидно,

$$f(x_i;x_k)=f(x_k;x_i)=\frac{f(x_i)}{x_i-x_k}+\frac{f(x_k)}{x_k-x_i}.$$

Разделенная разность n – го порядка определяется через разделенные разности (n–1) – го порядка по рекуррентной формуле

$$f(x_0;x_1;\ldots;x_n)=\frac{f(x_1;x_2;\ldots;x_n)-f(x_0;x_2;\ldots;x_{n-1})}{x_n-x_0}.$$

Свойства разделенных разностей.

1. Разделенная разность n–го порядка выражается через узловые значения функции по формуле

$$f(x_0;x_1;\ldots;x_n)=\sum_{i=0}^{n}\frac{f(x_i)}{(x_i-x_0)(x_i-x_1)\ldots(x_i-x_{i-1})(x_i-x_{i+1})\ldots(x_i-x_n)}.$$

Доказательство проводится по индукции.

2. На равномерной сетке узлов $x_k=x_0+kh$, $h>0$, $k=0, 1,\ldots, n$, для разделенной разности n – го порядка и конечной разности n – го порядка имеет место соотношение

$$f(x_0;x_1;\ldots;x_n)=\frac{\Delta^n y_0}{n!h^n}. \quad (4.10)$$

Пусть $[a,b]$– минимальный интервал, содержащий узлы x_0, $x_1,\ldots$, x_n, $f\in C^n_{[a,b]}$. Тогда существует такая точка $\xi\in[a,b]$, что

$$f(x_0;x_1;\ldots;x_n)=\frac{f^{(n)}(\xi)}{n!}.$$

Это следует из соотношений (4.9) и (4.10).

Интерполяционный многочлен в форме Ньютона. Пусть узлы x_0, x_1,…, x_n произвольны и попарно не совпадают. Тогда алгебраический многочлен

$$l_n(x) = f(x_0) + (x - x_0) f(x_0; x_1) + (x - x_0)(x - x_1) f(x_0; x_1; x_2) + \\ \ldots + (x - x_0)(x - x_1)\ldots(x - x_{n-1}) f(x_0; x_1; \ldots; x_n) \quad (4.11)$$

является интерполяционным, т.е.

$$l_n(x_j) = f(x_j), \quad j = 0, 1, \ldots, n. \quad (4.12)$$

Покажем, что равенства (4.12) выполняются для n=1:

$$l_n(x_0) = f(x_0)$$

$$l_n(x_1) = f(x_0) + (x_1 - x_0) \cdot \frac{f(x_1) - f(x_0)}{x_1 - x_0} = f(x_1).$$

Для n>1 доказательство проводится по индукции.

Многочлен (4.11) называется интерполяционным многочленом в форме Ньютона. Он тождественно совпадает с интерполяционным многочленом в форме Лагранжа, т.е.

$$l_n(x) \equiv L_n(x).$$

Случай равноотстоящих узлов. Пусть $x_k = x_0 + kh$, h>0, k=0, 1, …, n; $f(x_k) = y_k$. Тогда, учитывая соотношение (4.10) для конечной и разделенной разности и вводя безразмерную переменную $t = \frac{x - x_0}{h}$, перепишем многочлен (4.11) в виде

$$l_n(x) = l_n(x_0 + th) = y_0 + t \cdot \frac{\Delta y_0}{1!} + t \cdot (t-1) \cdot \frac{\Delta^2 y_0}{2!} + \ldots + t \cdot (t-1)\ldots(t-n+1) \cdot \frac{\Delta^n y_0}{n!}. \quad (4.13)$$

Этот многочлен называется интерполяционным многочленом Ньютона интерполирования «вперед». Здесь начальное значение t=0 расположено в крайнем слева узле x_0. Многочлен (4.13) используется при вычислениях в начале таблиц и для экстраполяции значений $f(x)$ в точках, лежащих левее x_0 (при t<0).

Интерполяционный многочлен с узлами x_{-n}, $x_{-(n-1)}$,…, x_{-1}, x_0, где $x_{-k} = x_0 - kh$, имеет вид

$$l_n(x) = l_n(x_0 + th) = y_0 + t \cdot \frac{\Delta y_{-1}}{1!} + t \cdot (t+1) \cdot \frac{\Delta^2 y_{-2}}{2!} + \ldots + t \cdot (t+1)\ldots(t+n-1) \cdot \frac{\Delta^n y_{-n}}{n!}. \quad (4.14)$$

и называется интерполяционным многочленом Ньютона для интерполяции «назад». Для этого многочлена начало отсчета $t=0$ расположено в крайнем правом узле x_0. Он используется при интерполяции в конце таблицы ($t<0$) и для экстраполяции правее точки x_0 ($t>0$). Чаще всего интерполяционные формулы (4.13) и (4.14) для равномерной сетки узлов применяют при $t \in [-1,1]$.

Отметим, что для одной и той же системы интерполяционных узлов формулы (4.11), (4.13), (4.14) описывают один и тот же интерполяционный многочлен, ранее записанный в форме Лагранжа.

Оценка погрешности интерполяции. Погрешность приближения функции интерполяционным многочленом Лагранжа (4.8) описывается разностью

$$f(x)-L_n(x).$$

Оценим погрешность интерполяции в точке x^*. Будем предполагать, что $f \in C^{n+1}_{[a,b]}$. Рассмотрим вспомогательную функцию

$$\varphi(x) = f(x) - L_n(x) - K\omega_n(x), \quad (4.15)$$

где $\omega_n(x)=(x-x_0)\ldots(x-x_n)$; K – постоянная. Очевидно, что $\varphi(x_k)=0$, $k=0, 1, \ldots, n$. Выберем K так, чтобы $\varphi(x^*)=0$, $x^* \neq x_k$, $k=0,1,\ldots,n$. Имеем

$$K = \frac{f(x^*) - L_n(x^*)}{\omega_n(x^*)}.$$

Тогда функция $\varphi(x)$ обращается в нуль по крайней мере в $(n+2)$ точках интервала $[a,b]$: x^*, x_0, x_1, …, x_n. Согласно теореме Ролля [1] $\varphi'(x)$ имеет не менее $(n+1)$ нулей на $[a,b]$, $\varphi''(x)$ – не менее n нулей и т.д. Для функции $\varphi^{(n+1)}(x)$ существует по крайней мере одна точка $\xi \in [a,b]$, в которой $\varphi^{(n+1)}(\xi)=0$. Дифференцируя равенство (4.15) $(n+1)$ раз, получаем

$$\varphi^{(n+1)}(x) = f^{(n+1)}(x) - K(n+1)!.$$

Полагая $x=\xi$, имеем $K = -\dfrac{f^{(n+1)}(\xi)}{(n+1)!}$. Из (4.15) следует, что погрешность приближения в точке x^* можно представить в виде

$$f(x^*) - L_n(x^*) = -\frac{f^{(n+1)}(\xi)}{(n+1)!}\omega_n(x^*).$$

Отсюда получаем выражение для оценки погрешности приближения в точке x^*

$$\left| f\left(x^*\right) - L_n\left(x^*\right) \right| \le \max_{[a,b]} \frac{\left| f^{(n+1)}(x) \right|}{(n+1)!} \left| \omega_n\left(x^*\right) \right|$$

и оценки погрешности интерполяции на интервале

$$\max_{[a,b]} \left| f(x) - L_n(x) \right| \le \max_{[a,b]} \frac{\left| f^{(n+1)}(x) \right|}{(n+1)!} \cdot \max_{[a,b]} \left| \omega_n(x) \right|. \quad (4.16)$$

Поскольку многочлены Лагранжа и Ньютона отличаются только формой записи, оценка погрешности (4.16) верна для всех формул.

Величину $|\omega_n(x)|$, входящую в оценку погрешности (4.16), можно минимизировать за счет выбора узлов интерполяции. Эта задача решается с помощью многочленов Чебышева: в качестве узлов интерполяции на интервале $[a,b]$ выбираются корни многочлена Чебышева степени $(n+1)$ [2], т.е. узлы

$$x_k = \frac{a+b}{2} + \frac{b-a}{2} \cos \frac{(2k+1)}{2(n+1)} \pi, \quad k = 0,1,\ldots,n.$$

При таком выборе узлов интерполяции оценка (4.16) принимает вид

$$\max_{[a,b]} \left| f(x) - L_n(x) \right| \le \max_{[a,b]} \frac{\left| f^{(n+1)}(x) \right|}{(n+1)!} \cdot \frac{(b-a)^{n+1}}{2^{2n+1}}.$$

О сходимости интерполяционного процесса. На практике часто возникает вопрос: можно ли, выбрав достаточное количество узлов интерполяции, приблизить интерполируемую функцию с заданной степенью точности? Ответ, вообще говоря, отрицателен.

Рассмотрим на интервале $[a,b]$ последовательность систем узлов интерполяции

$$\left\{x_0^{(0)}\right\}, \left\{x_0^{(1)}, x_1^{(1)}\right\}, \ldots, \left\{x_0^{(n)}, x_1^{(n)}, \ldots, x_n^{(n)}\right\}, \ldots \quad (4.17)$$

Сопоставим последовательности (4.17) последовательность интерполяционных многочленов функции $f(x)$

$$L_0(x), L_1(x), \ldots, L_n(x)$$

такую, что многочлен $L_i(x)$ соответствует системе узлов $\left\{x_0^{(i)}, x_1^{(i)}, \ldots, x_i^{(i)}\right\}$. Интерполяционный процесс для функции $f(x)$ называется сходящимся, если

$$L_n(x) - f(x) \underset{n\to\infty}{\to} 0.$$

Процесс сходится равномерно, если

$$\max_{[a,b]} |L_n(x) - f(x)| \underset{n\to\infty}{\to} 0.$$

Сходимость и расходимость интерполяционного процесса зависит как от выбора последовательности систем узлов (4.17), так и от гладкости функции $f(x)$. Например, для функции $f(x)=|x|$, рассматриваемой на интервале [–1,1], процесс интерполяции не сходится. На рис.4. 1 представлен график многочлена $L_9(x)$ при $x \in [0,1]$, построенного на интервале [–1,1] по равноотстоящим узлам.

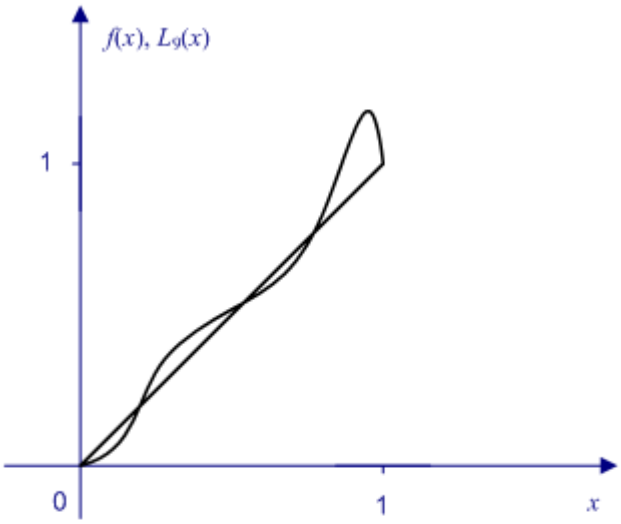

Рис. 4.1. Интерполяция функции |x| многочленом 9-й степени

Интерполяция сплайнами. С увеличением числа узлов интерполяции и, соответственно, вычисленных в них значениях функции $f(x)$ естественно желание использовать дополнительную информацию о поведении приближаемой функции и получить более качественное приближение. Если число узлов превышает 5 – 7, то решение поставленной задачи посредством интерполяционных многочленов, как правило, не приводит к успеху. Это объясняется как сильным накоплением ошибок при вычислении интерполяционных многочленов высоких степеней, так и отсутствием сходимости интерполяционного процесса в целом. В этом случае целесообразно применять кусочно–многочленную интерполяцию, используя

многочлены невысоких степеней (первой, второй, третьей). Наиболее часто применяют интерполяцию сплайнами.

Пусть на интервале $[a,b]$ задана непрерывная функция $f(x)$. Рассмотрим набор узлов $a<x_0<x_1<\ldots<x_N=b$ и обозначим $f(x_i)=f_i$, $i=0, 1, \ldots, N$. Сплайном $S_{n,\nu}(x)$ порядка n дефекта ν, соответствующим данной функции $f(x)$ и узлам $x_0, x_1, \ldots, x_N$, называется функция, удовлетворяющая следующим условиям:

а) на произвольном подынтервале $[x_{i-1},x_i]$, $i=1,\ldots, N$, функция $S_{n,\nu}(x)$ является многочленом степени не выше n;

б) функция $S_{n,\nu}(x)$ имеет m непрерывных производных на $[a,b]$ ($\nu=n-m$);

в) $S_{n,\nu}(x_i)= f(x_i)$, $i=0,1,\ldots,N$.

Последнее условие является условием интерполирования и определяет название сплайна: интерполяционный сплайн (рис. 4.2). Примером простейшего сплайна является ломанная. Степень такого сплайна равна единице, дефект также равен единице. Наиболее широко применяются сплайны третьей степени, имеющие на интервале $[a,b]$ одну или две непрерывные производные (дефекта 2 или 1, соответственно). Сплайн дефекта 1 называют кубическим.

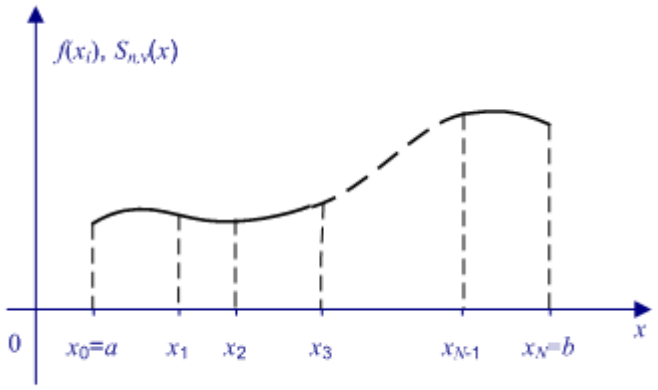

Рис. 4.2. Интерполяционный сплайн $S_{n,\nu}(x)$

Рассмотрим процедуру построения интерполяционного кубического сплайна, удовлетворяющего условиям а) – в), и докажем его существование и единственность.

На каждом из отрезков $[x_{i-1},x_i]$, $i=1,\ldots, N$ будем искать сплайн $S_{3,1}(x)=S_i(x)$ в виде многочлена третьей степени

$$S_i(x)=a_i+b_i(x-x_{i-1})+c_i(x-x_{i-1})^2+d_i(x-x_{i-1})^3 \quad (4.18)$$

Где a_i, b_i, c_i, d_i – коэффициенты, подлежащие определению (i=1, …, N).

Построим систему алгебраических уравнений для вычисления искомых коэффициентов. Из выражения (4.18) для i–го звена сплайна получаем

$$a_i = S_i(x_{i-1}), \quad b_i = S_i'(x_{i-1}),$$
$$2c_i = S_i''(x_{i-1}), \quad 6d_i = S_i'''(x_{i-1}).$$

Учитывая условия интерполирования в), имеем

$$a_i=f_{i-1},\ i=0,\ 1,\ \ldots,\ N, \quad (4.19)$$

$$a_i+b_i(x_i-x_{i-1})+c_i(x_i-x_{i-1})^2+d_i(x_i-x_{i-1})^3 =f_i. \quad (4.20)$$

Далее требования непрерывности первой и второй производных сплайна $S_{3,1}(x)$ приводят к соотношениям

$$S_i'(x_i) = S_{i+1}'(x_i),$$
$$S_i''(x_i) = S_{i+1}''(x_i), \quad i = 1,2,..,N-1.$$

Подставляя выражение (4.18) для сплайна и обозначая $x_i-x_{i-1}=h_i$, получаем

$$2h_ic_i + 3h_i^2 d_i = b_{i+1} - b_i, \quad i = 1,2,\ldots,N-1, \quad (4.21)$$

$$3h_i d_i = c_{i+1} - c_i, \quad i = 1,2,\ldots,N-1. \quad (4.22)$$

Соотношения (4.19) – (4.22) составляют систему $4N$–2 алгебраических уравнений относительно $4N$ неизвестных a_i, b_i, c_i, d_i, i=0, 1, …, N. Два недостающих уравнения обычно задаются в виде ограничений на значения сплайна и его производных на концах интервала и называются граничными условиями. Наиболее употребительными являются следующие три условия.

1. Если известны значения f' в точках x_0 и x_N, то естественно положить

$$S_1'(x_0) = f_0', \quad S_N'(x_N) = f_N'$$

Подставляя выражение для сплайна, получаем два уравнения

$$\begin{aligned} &b_1 = f_0', \\ &b_N + 2c_N h_N + 3d_N h_N^2 = f_N'. \end{aligned} \quad (4.23)$$

Полученный в результате решения системы уравнений (4.19)–(4.23) сплайн называют *фундаментальным интерполяционным кубическим сплайном*.

2. Если в граничных точках интервала известно значение f'', то можно задать граничные условия вида

$$S_1''(x_0) = f_0'', \quad S_N''(x_N) = f_N''$$

или

$$2c_1 = f_0'',$$
$$2c_N + 6d_N h_N = f_N''.$$

5. Так называемая интерполяция естественными сплайнами получается из нулевых граничных условий

$$f_0'' = f_N'' = 0,$$

т.е.

$$2c_1 = 0, \quad (4.24)$$

$$2c_N + 6d_N h_N = 0. \quad (4.25)$$

Такие граничные условия приводят к простейшей системе уравнений для искомых коэффициентов. Однако следует заметить, что искусственное наложение этих условий на значения сплайна в граничных точках дает погрешность приближения порядка h^2 и замедляет сходимость процесса интерполяции сплайнами на концах интервала.

Покажем, что получаемые системы уравнений имеют единственное решение. Выберем для простоты граничные условия (4.24) и (4.25). Из соотношений (4.19) определяются все коэффициенты a_i, i=1, … , N. Исключим последовательно из уравнений (4.21), (4.22) и (4.25) переменные d_i, b_i, i=1, …, N–1 и получим систему N уравнений относительно коэффициентов c_i, i=1, … , N.

Из (4.22) и (4.25) имеем

$$d_i = \frac{(c_{i+1} - c_i)}{3h_i}, \quad i = 1, 2, \ldots, N-1,$$

$$d_N = -\frac{c_N}{3h_N}.$$

Подставляя значения a_i и d_i в соотношения (4.20), можем выразить коэффициенты b_i:

$$b_i = \frac{f_i - f_{i-1}}{h_i} - \frac{h_i}{3}\left(c_{i+1} + 2c_i\right), \quad i = 1,2,\ldots,N-1,$$

$$b_N = \frac{f_N - f_{N-1}}{h_N} - \frac{2h_N c_N}{3}.$$

Подстановка полученных выражений для d_i и b_i в (4.21) дают искомую систему уравнений:

$$h_{i-1}c_{i-1} + 2\left(h_{i-1} + h_i\right)c_i + h_i c_{i+1} = 3\left(\frac{f_i - f_{i-1}}{h_i} - \frac{f_{i-1} - f_{i-2}}{h_{i-1}}\right), \quad i = 2,3,\ldots,N-1, \quad (4.26)$$

$$c_1 = 0, \quad (4.27)$$

$$h_{N-1}c_{N-1} + 2\left(h_{N-1} + h_N\right)c_N = 3\left(\frac{f_N - f_{N-1}}{h_N} - \frac{f_{N-1} - f_{N-2}}{h_{N-1}}\right). \quad (4.28)$$

Соотношения (4.26)–(4.28) определяют трехдиагональную систему N линейных алгебраических уравнений для N неизвестных. Матрица системы имеет диагональное преобладание, т.е. в каждой строке модуль диагонального элемента превосходит сумму модулей остальных элементов. Из теории матриц известно, что матрица такого вида невырождена, т.е. система (4.26)–(4.28) имеет единственное решение.

Это доказывает единственность интерполяционного сплайна.

О сходимости процесса интерполяции кубическими сплайнами.

Оценки погрешности интерполяции

$$f(x) - S_{n,\nu}(x)$$

зависят от сетки интерполяционных узлов. Для простоты ограничимся рассмотрением случая равномерной сетки $x_i = x_0 + ih$, $h>0$, $i=0,1,\ldots,N$. Обозначим через $S_{1,3}(x,N)$ сплайн для $f(x)$, построенный на этой сетке узлов. Приведем без доказательства следующую теорему [3].

Теорема. Пусть функция $f \in C^4_{[a,b]}$ и в качестве граничных условий выбраны условия 1 или 2. Тогда имеют место оценки

$$\max_{[a,b]}\left|f^{(k)}(x) - S^{(k)}_{3,1}(x,N)\right| \le h^{4-k}\max_{[a,b]}\left|f^{(IV)}(x)\right|, \quad (4.29)$$

где $k=0,1,2$.

Из оценок (4.29) следует, что при $h \to 0$ (т.е. при $N \to \infty$) соответствующие последовательности сплайнов и их производных $S_{3,1}^{(k)}(x, N)$ сходятся соответственно к функциям $f^{(k)}(x)$, $k=0, 1, 2$.

4.2 Аппроксимация функций в среднеквадратичной метрике.

При построении среднеквадратичных приближений обычно рассматривают три пространства: пространство E_{n+1} функций, заданных своими табличными значениями на множестве точек $x_0, x_1, \ldots, x_n$, пространство $C_{[a,b]}$ непрерывных функций, заданных на интервале $[a,b]$ и пространство $L_2(a,b)$ интегрируемых с квадратом функций на интервале (a,b), т.е. функций, для которых выполняется неравенство (1.12). Способы введения соответствующих скалярных произведений, норм и метрик описаны в пунктах 1.2, 1.3, 1.5.

Линейно независимые системы в пространстве со скалярным произведением. Пусть F – пространство со скалярным произведением. Линейная независимость системы элементов $f_1, f_2, \ldots, f_n$ пространства F устанавливается при помощи определителя Грама, который имеет вид

$$G(f_1, f_2, \ldots, f_n) = \begin{vmatrix} \langle f_1, f_1 \rangle & \langle f_1, f_2 \rangle & \ldots & \langle f_1, f_n \rangle \\ \langle f_2, f_1 \rangle & \langle f_2, f_2 \rangle & \ldots & \langle f_2, f_n \rangle \\ \ldots & \ldots & \ldots & \ldots \\ \langle f_n, f_1 \rangle & \langle f_n, f_2 \rangle & \ldots & \langle f_n, f_n \rangle \end{vmatrix}. \quad (4.30)$$

Имеет место следующее утверждение.

Теорема. Система элементов $f_1, f_2, \ldots, f_n$ из пространства F линейно зависима тогда и только тогда, когда определитель Грама этой системы равен нулю.

Доказательство. Необходимость. Пусть система элементов $f_1, f_2, \ldots, f_n$ линейно зависима. Покажем, что определитель $G(f_1, f_2, \ldots, f_n)$ равен нулю. Из линейной зависимости элементов $f_1, f_2, \ldots, f_n$ следует, что существуют такие числа $\alpha_1, \alpha_2, \ldots, \alpha_n$, среди которых есть отличные от нуля, что

$$\alpha_1 f_1 + \alpha_2 f_2 + \ldots + \alpha_n f_n = 0. \quad (4.31)$$

Умножая равенство (4.31) справа последовательно на f_k, k=1, 2, …, n, получаем

$$\alpha_1\langle f_1, f_k\rangle + \alpha_2 \langle f_2, f_k\rangle + \ldots + \alpha_n \langle f_n, f_k\rangle = 0,\ k=1, 2, \ldots, n. \quad (4.32)$$

Рассмотрим соотношение (4.32) как систему линейных уравнений относительно неизвестных α_i, i=1, 2, …, n. Учитывая предположение относительно α_i, заключаем, что система уравнений (4.32) имеет нетривиальное (ненулевое) решение. Следовательно, определитель системы (4.32), являющийся определителем Грама $G(f_1, f_2,\ldots, f_n)$ равен нулю.

Достаточность. Пусть определитель $G(f_1, f_2,\ldots, f_n)=0$. Покажем, что система элементов f_1, f_2,…, f_n линейно зависима. Рассмотрим систему линейных уравнений

$$\langle f_1, f_k\rangle\beta_1 + \langle f_2, f_k\rangle\beta_2 + \ldots + \langle f_n, f_k\rangle\beta_n = 0,\ k=1,2,\ldots,n, \quad (4.33)$$

относительно β_1, β_2,…, β_n. Поскольку определитель этой системы равен нулю, то она имеет ненулевое решение, т.е. среди чисел β_i, i=1, 2, …, n, имеются отличные от нуля. Умножим каждое k – е уравнение системы (4.33) на β_k и сложим полученные соотношения. Имеем

$$\left\langle \sum_{i=1}^{n} \beta_i f_i, \sum_{k=1}^{n} \beta_k f_k \right\rangle = 0$$

или

$$\left\langle \sum_{k=1}^{n} \beta_k f_k, \sum_{k=1}^{n} \beta_k f_k \right\rangle = 0.$$

В силу аксиом скалярного произведения $\sum_{k=1}^{n} \beta_k f_k = 0.$ Учитывая, что среди чисел β_k, i=1, 2, …, k, имеются ненулевые, приходим к заключению о линейной зависимости системы элементов f_1, f_2, …, f_n.

Ортогональные и ортонормированные системы элементов. Два элемента f и g пространства со скалярным произведением называются ортогональными, если их скалярное произведение равно нулю, т.е. $\langle f,g\rangle=0$. Элемент f называется нормированным, если $\|f\|=1$. Конечную или бесконечную систему элементов называют ортонормированной, если любые два ее элемента ортогональны и

нормированы. Ортогональная система элементов линейно независима, так как ее определитель Грама отличен от нуля.

Из системы линейно независимых элементов всегда можно получить ортогональную систему такую, что ее элементы будут представляться в виде линейной комбинации элементов исходной системы и наоборот. Опишем метод ортогонализации Грама–Шмидта, который часто используют для получения ортогональных систем.

Пусть $f_1, f_2, \ldots, f_n$ – система линейно независимых элементов. Построим систему ортогональных элементов $g_1, g_2, \ldots, g_n$. В силу линейной независимости f_i имеем $\langle f_i, f_i \rangle \neq 0$, $i=1,2,\ldots,n$. Положим $g_1 = f_1$. Определим элемент $g_2 = f_2 + \alpha_1^{(2)} g_1$; подберем коэффициент $\alpha_1^{(2)}$ так, чтобы элемент g_2 был ортогонален элементу g_1:

$$\langle g_2, g_1 \rangle = \langle f_2 + \alpha_1^{(2)} g_1, g_1 \rangle = \langle f_2, g_1 \rangle + \alpha_1^{(2)} \langle g_1, g_1 \rangle = 0.$$

Следовательно, $\alpha_1^{(2)} = -\dfrac{\langle f_2, g_1 \rangle}{\langle g_1, g_1 \rangle}$. Следующий элемент g_3 представим также в виде линейной комбинации f_3, g_1 и g_2: $g_3 = f_3 + \alpha_1^{(3)} g_1 + \alpha_2^{(3)} g_2$. Из условий ортогональности $\langle g_3, g_1 \rangle = 0$ и $\langle g_3, g_2 \rangle = 0$ следует, что

$$\alpha_1^{(3)} = -\frac{\langle f_3, g_1 \rangle}{\langle g_1, g_1 \rangle}, \quad \alpha_2^{(3)} = -\frac{\langle f_3, g_2 \rangle}{\langle g_2, g_2 \rangle}.$$

Повторяя эту процедуру, можно получить всю ортогональную систему. На n – м шаге имеют место формулы

$$g_n = f_n + \sum_{k=1}^{n-1} \alpha_k^{(n)} g_k, \quad \alpha_k^{(n)} = -\frac{\langle f_n, g_k \rangle}{\langle g_k, g_k \rangle}.$$

Замечание. Используя процесс ортогонализации Грама–Шмидта можно получить ортонормированную систему элементов $h_1, h_2, \ldots, h_n$, если сначала положить $h_1 = \dfrac{g_1}{\|g_1\|} = \dfrac{f_1}{\|f_1\|}$ и далее, на каждом i – м шаге, после вычисления коэффициентов $\alpha_k^{(i)}, k = 1, 2, \ldots, i-1,$ нормировать g_i, т.е. выбирать $h_i = \dfrac{g_i}{\|g_i\|}$.

Ряд Фурье. Система ортогональных элементов называется полной, если ее нельзя пополнить никаким другим ненулевым элементом, ортогональным к элементам данной системы.

Пусть φ_1, φ_2, …, φ_n,… – бесконечная ортогональная система элементов функционального пространства со скалярным произведением. Числа $\alpha_i = \frac{\langle f, \varphi_i \rangle}{\langle \varphi_i, \varphi_i \rangle}$ называют коэффициентами Фурье функции f по ортогональной системе φ_1, φ_2, …, φ_n, … Функции f можно поставить в соответствие ряд

$$f \sim \alpha_1\varphi_1 + \alpha_2\varphi_2 + \ldots + \alpha_n\varphi_n + \ldots \quad (4.35)$$

Этот ряд называется рядом Фурье по ортогональной системе функций φ_1, φ_2, …, φ_n, …. Можно показать, что если система $\{\varphi_i\}$ полна, то конечные суммы ряда (4.35)

$$\Phi_n(x) = \sum_{k=1}^{n} \alpha_k \varphi_k(x)$$

сходятся к функции f в среднем, т.е.

$$\| f - \Phi_n \| \underset{n\to\infty}{\to} 0$$

или

$$\rho(f, \Phi_n)_{L_2} \underset{n\to\infty}{\to} 0.$$

Построение многочлена наилучшего приближения в среднеквадратичной метрике. Пусть функция задана на некотором множестве A, дискретном или непрерывном. Выберем систему линейно независимых функций φ_0, φ_1 ,…, φ_m, заданных на множестве A. Рассмотрим задачу приближения функции f на множестве A многочленом P_m вида

$$P_m(x) = \sum_{k=0}^{m} a_k \varphi_k(x).$$

При фиксированной системе функций φ_0, φ_1, …, φ_m многочлен P_m однозначно определяется коэффициентами a_0, a_1, …, a_m, т.е. $P_m(x)=P_m(x, a_0, \ldots, a_m)$. Многочлен P_m^* называется многочленом наилучшего среднеквадратичного приближения (МНСП) функции f на множестве A, если выполняется соотношение

$$\rho^2(f, P_m^*)_{L_2} = \min_{a_0,\ldots,a_m} \rho^2(f, P_m)_{L_2}. \quad (4.36)$$

Задача построения МНСП P_m^* сводится к задаче вычисления таких коэффициентов многочлена P_m, которые минимизируют квадрат погрешности

приближения (4.36). Обозначим эти коэффициенты через $a_0^*, a_1^*, \ldots, a_m^*$ и приведем процедуру их вычисления.

Квадрат погрешности приближения ρ^2 есть функция коэффициентов a_0, a_1, …, a_m многочлена P_m. Эта погрешность представляет собой квадратичную форму

$$\begin{aligned}\rho^2(f, P_m)_{L_2} &= \langle f - P_m, f - P_m \rangle = \langle f - \sum_{k=0}^{m} a_k \varphi_k, f - \sum_{k=0}^{m} a_k \varphi_k \rangle = \\ &= \langle f, f \rangle - 2\langle f, \sum_{k=0}^{m} a_k \varphi_k \rangle + \langle \sum_{k=0}^{m} a_k \varphi_k, \sum_{j=0}^{m} a_j \varphi_j \rangle = \\ &= \langle f, f \rangle - 2\sum_{k=0}^{m} a_k \langle f, \varphi_k \rangle + \sum_{k=0}^{m}\sum_{j=0}^{m} a_k a_j \langle \varphi_k, \varphi_j \rangle.\end{aligned} \tag{4.37}$$

В силу аксиом расстояния формула (4.37) является положительно определенной. Следовательно, она имеет единственный экстремум – минимум. Это означает, что искомые коэффициенты $a_0^*, a_1^*, \ldots, a_m^*$ существуют и единственны. Приравняем к нулю частные производные $\rho^2(f, P_m)_{L_2}$ по переменным a_0, a_1,…, a_m:

$$\begin{aligned}\frac{\partial}{\partial a_i}\rho^2(f, P_m)_{L_2} &= \frac{\partial}{\partial a_i}\left[\langle f, f \rangle - 2\sum_{k=0}^{m} a_k \langle f, \varphi_k \rangle + \sum_{k=0}^{m}\sum_{j=0}^{m} a_k a_j \langle \varphi_k, \varphi_j \rangle\right] = \\ &= -2\langle f, \varphi_i \rangle + 2\sum_{k=0}^{m} a_k \langle \varphi_k, \varphi_i \rangle = 0, \quad i = 0,1,\ldots,m.\end{aligned}$$

Получаем систему линейных алгебраических уравнений относительно искомых коэффициентов:

$$\begin{aligned}&a_0\langle \varphi_0, \varphi_0 \rangle + a_1\langle \varphi_0, \varphi_1 \rangle + \ldots + a_m\langle \varphi_0, \varphi_m \rangle = \langle f, \varphi_0 \rangle, \\ &a_0\langle \varphi_1, \varphi_0 \rangle + a_1\langle \varphi_1, \varphi_1 \rangle + \ldots + a_m\langle \varphi_1, \varphi_m \rangle = \langle f, \varphi_1 \rangle, \\ &\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ &a_0\langle \varphi_m, \varphi_0 \rangle + a_1\langle \varphi_m, \varphi_1 \rangle + \ldots + a_m\langle \varphi_m, \varphi_m \rangle = \langle f, \varphi_m \rangle.\end{aligned} \tag{4.38}$$

Эта система называется системой нормальных уравнений. Ее определитель является определителем Грама $G(f_1, f_2, \ldots, f_n)$. В силу линейной независимости системы функций $\{\varphi_i\}_0^m$ он отличен от нуля. Поэтому система (4.38) имеет единственное решение. Из теории функций нескольких переменных следует, что это решение дает минимум функции ρ^2, т.е. решение системы (4.38) – искомые коэффициенты $a_0^*, a_1^*, \ldots, a_m^*$.

Таким образом, если система функций φ_0, φ_1, …, φ_m линейно независима, то коэффициенты МНСП функции f могут быть вычислены как решение системы нормальных уравнений (4.38). Описанный метод построения МНСП называют методом наименьших квадратов.

Построение МНСП для функции f упрощается, если система функций φ_0, φ_1, …, φ_m ортогональна. В этом случае матрица системы уравнений (4.38) становится диагональной, и коэффициенты МНСП вычисляются по формулам

$$a_i = \frac{\langle f, \varphi_i \rangle}{\langle \varphi_i, \varphi_i \rangle}, \quad i = 0, 1, \ldots, m. \quad (4.39)$$

Коэффициенты a_i совпадают с коэффициентами Фурье для функции f по системе функций φ_0, φ_1, …, φ_m, а МНСП совпадает с отрезком ряда Фурье $\Phi_m(x)$ (4.35)

$$P_m(x) \equiv \Phi_m(x) = a_0\varphi_0(x) + a_1\varphi_1(x) + \ldots + a_m\varphi_m(x). \quad (4.40)$$

Квадрат погрешности приближения описывается формулой

$$\rho^2(f, P_m)_{L_2} = \langle f, f \rangle - a_0\langle f, \varphi_0 \rangle - \ldots - a_m\langle f, \varphi_m \rangle =$$
$$= \|f\|_{L_2}^2 - \sum_{i=0}^{m} a_i^2 \|\varphi_i\|_{L_2}.$$

Из последней формулы явно видно, что с расширением ортогональной системы функций (ростом m) погрешность, вообще говоря, не увеличивается.

Часто бывает удобнее при построении МНСП использовать ортонормированную систему функций h_0, h_1, …, h_m. В этом случае, соответственно, коэффициенты имеют вид

$$a_i = \langle f, h_i \rangle, \quad i = 0, 1, \ldots, m,$$

и квадрат погрешности вычисляется по формуле

$$\rho^2(f, P_m)_{L_2} = \|f\|_{L_2}^2 - \sum_{i=0}^{m} a_i^2.$$

Замечание. Следует иметь в виду, что близость двух непрерывных функций в смысле среднеквадратичного отклонения не гарантирует малости их отклонения на всем интервале приближения. Например, на рис.4.3 приведены графики функций $g(x) \equiv 2$ и функции $f(x)$, отличающейся от $g(x)$ одним пиком высоты $2+n$ и длиной основания, равной $1/n^3$.

В этом случае расстояние

$$\rho^2(f,g)_{L_2} = \left\{\int_a^b [f(x)-g(x)]^2 \mathrm{d}x\right\}^{1/2} = \frac{1}{\sqrt{3n}}.$$

Очевидно, $\rho^2(f,g)_{L_2} \underset{n\to\infty}{\to} 0$, т.е. функции могут быть сколь угодно близки в смысле среднеквадратичной метрики, однако сколь угодно далеки в смысле равномерной метрики: $\max\limits_{[a,b]}|f(x)-g(x)| = n \underset{n\to\infty}{\to} \infty$.

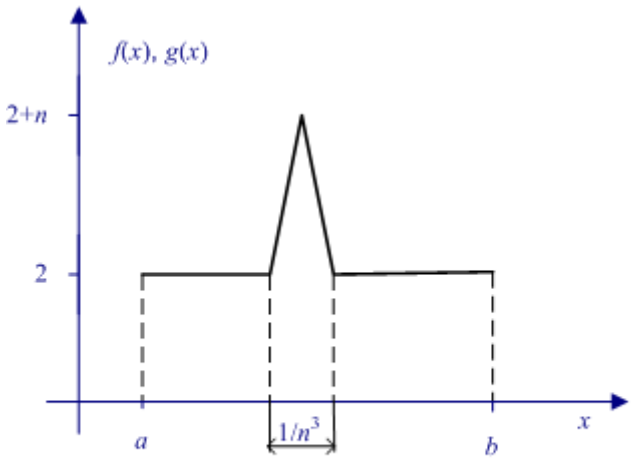

Рис. 4.3. Близкие в среднеквадратичной метрике на интервале [*a*, *b*] функции

Приближение функций алгебраическими многочленами. Часто для среднеквадратичных приближений используют системы алгебраических многочленов. Система степенных функций является простейшей и имеет вид

$$1,\ x,\ x^2,\ldots,\ x^m. \quad (4.41)$$

Такая система линейно независима в пространстве $C_{[a,b]}$ непрерывных на интервале $[a,b]$ функций. В пространстве E_{n+1} функций, таблично заданных на множестве точек $\{x_j\}_0^n$, система (4.41) линейно независима при $m \le n+1$ и зависима в противном случае.

Пример. Построить на интервале [0,1] линейный МНСП для функции $f(x)=e^x$.

Решение. Приближающий многочлен имеет вид $P_1(x)=a_0+a_1x$, т.е. $\varphi_0(x)=1$, $\varphi_1(x)=x$. Вычислим коэффициенты системы нормальных уравнений по формулам для скалярных произведений (1.6)

$$\langle\varphi_0,\varphi_0\rangle=1; \quad \langle\varphi_0,\varphi_1\rangle=\langle\varphi_1,\varphi_0\rangle=1/2; \quad \langle\varphi_1,\varphi_1\rangle=1/3;$$

$$\langle f,\varphi_0\rangle = e-1; \quad \langle f,\varphi_1\rangle = 1.$$

Запишем нормальную систему

$$\begin{cases} a_0 + \frac{1}{2}a_1 = e-1 \\ \frac{1}{2}a_0 + \frac{1}{3}a_1 = 1. \end{cases}$$

Решая систему, получаем коэффициенты

$$a_0 = 4e - 10 \approx 0{,}87; \qquad a_1 = 18 - 6e \approx 1{,}69.$$

Отсюда $e^x \approx 0{,}87 + 1{,}69x$ на интервале [0, 1].

Замечание. В общем случае при вычислении коэффициентов системы нормальных уравнений можно использовать формулу

$$\langle \varphi_k, \varphi_i \rangle = \int_a^b x^{k+i}\mathrm{d}x = \frac{b^{k+i+1} - a^{k+i+1}}{k+i+1}.$$

Эта формула достаточно проста. Однако при вычислении правых частей системы (4.36) интегралы

$$\langle f, \varphi_i \rangle = \int_a^b f(x)\cdot x^i \mathrm{d}x$$

могут оказаться очень сложными. Поэтому часто переходят к дискретному варианту метода наименьших квадратов. А именно: строят МНСП в пространстве E_{n+1} на множестве узлов $\{x_j\}_0^n$ на интервале $[a,b]$, полагая $n+1$ равным от $1{,}5\cdot m$ до $2\cdot m$. Построенный многочлен принимают за аппроксимирующий на всем интервале $[a,b]$. В этом случае коэффициенты системы нормальных уравнений вычисляют по формулам (1.7) и погрешность приближения подсчитывают в среднеквадратичной метрике (1.9).

Основным достоинством системы степенных функций является ее простота. Однако решение системы нормальных уравнений представляет самостоятельную задачу линейной алгебры. Проблема усложняется тем, что при больших n (n>50) матрица системы (4.38) становится плохо обусловленной. Чтобы избежать указанных трудностей, часто используют ортогональные системы многочленов. Рассмотрим некоторые из них.

Многочлены Лежандра описываются выражением

$$L_n(x) = \frac{1}{2^n n!}\frac{\mathrm{d}^n}{\mathrm{d}x^n}\left(x^2-1\right)^n \quad (4.42)$$

Можно показать [5], что степень многочлена L_n равна n.

Для многочленов Лежандра имеет место рекуррентное соотношение

$$(n+1)L_{n+1}(x) - (2n+1)\,x\,L_n(x) + n\,L_{n-1}(x) = 0.$$

Учитывая, что $L_0(x)=1$, $L_1(x)=x$ можно вычислить многочлен любой степени. Например, второй и третий, соответственно, имеют вид

$$L_2(x) = \tfrac{3}{2}x^2 - \tfrac{1}{2}; \quad L_3(x) = \tfrac{5}{2}x^3 - \tfrac{3}{2}x.$$

Покажем, что многочлены Лежандра образуют ортогональную систему на стандартном отрезке [–1,1], т.е. выполняется соотношение

$$\langle L_n, L_m\rangle = \int_{-1}^{1} L_n(x)\cdot L_m(x)\mathrm{d}x = 0, \quad n \neq m.$$

Прежде всего, покажем, что многочлены $L_n(x)$ ортогональны одночленам x^m при $m<n$. Записывая условие ортогональности и интегрируя по частям, получаем

$$\langle L_n(x), x^m\rangle = \frac{1}{2^n n!}\int_{-1}^{1}\frac{\mathrm{d}^n}{\mathrm{d}x^n}\left(x^2-1\right)^n\cdot x^m\mathrm{d}x =$$

$$= \frac{m}{2^n n!}\int_{-1}^{1} x^{m-1}\frac{\mathrm{d}^{n-1}}{\mathrm{d}x^{n-1}}\left(x^2-1\right)^n\mathrm{d}x.$$

Выполняя (m–1) раз интегрирование по частям и учитывая, что при $k<n$ выражение $\frac{\mathrm{d}^k}{\mathrm{d}x^k}\left(x^2-1\right)^n$ обращается в ноль на концах промежутка [–1,1], получаем $\langle L_n(x),\ x^m\rangle=0$. Отсюда следует, что многочлен $L_n(x)$ ортогонален каждому одночлену x^k из $L_m(x)$ ($k\leq m$) и, следовательно, всему многочлену $L_m(x)$.

Замечание. Многочлены Лежандра можно получить из системы степенных функций, если применить к ним процесс ортогонализации Грама-Шмидта.

Покажем, что система многочленов Лежандра не является ортонормированной на интервале [–1,1]. Для этого вычислим норму многочлена L_n:

$$\|L_n\|_{L_2}^2 = \langle L_n, L_n\rangle.$$

Интегрируя n раз по частям, имеем

$$\|L_n\|_{L_2}^2 = \frac{(-1)^n}{(2^n n!)^2}\int_{-1}^{1}(x^2-1)^n \frac{\mathrm{d}^{2n}}{\mathrm{d}x^{2n}}(x^2-1)^n \mathrm{d}x.$$

Вычисляя производную порядка $2n$ от $(x^2–1)^n$, получаем

$$\|L_n\|_{L_2}^2 = \frac{(-1)^n(2n!)}{(2^n n!)^2}\int_{-1}^{1}(x^2-1)^n \mathrm{d}x = \frac{2}{2n+1}$$

или

$$\|L_n\|_{L_2} = \sqrt{\frac{2}{2n+1}}. \quad (4.43)$$

Можно показать, что многочлены Лежандра образуют полную систему функций. Поэтому для произвольной функции f последовательность ее МНСП P_0, P_1, …, P_m,…, построенных для соответствующих подсистем многочленов $\{L_0\}$, $\{L_0, L_1\}$,…, $\{L_0,\ldots, L_m\}$ сходится в среднем при $m\to\infty$ к функции f, т.е. выполняются соотношения

$$\|f - P_m\|_{L_2} \underset{m\to\infty}{\to} 0.$$

Пример. Построить на интервале $[-\pi, \pi]$ МНСП для функции $f(x)=sin(x)$, используя первые три многочлена Лежандра.

Решение. Сделаем замену переменных $x=\pi t$, чтобы перевести отрезок $[-\pi,\pi]$ в отрезок $[-1,1]$. Тогда $\overline{f}(t) = \sin \pi t,\ t \in [-1,1]$. Обозначим через $\overline{P}_3(t)$ МНСП для $\overline{f}(t)$ на $[-1,1]$. Вычислим коэффициенты a_i многочлена $\overline{P}_3(t)$ по формулам $a_i = \dfrac{\langle \overline{f}, L_i\rangle}{\langle L_i, L_i\rangle}$ с учетом нормы (4.43).

$$a_0 = \frac{1}{2}\int_{-1}^{1}\sin\pi t\,\mathrm{d}t = 0; \quad a_1 = \frac{3}{2}\int_{-1}^{1} t\sin\pi t\,\mathrm{d}t = \frac{3}{\pi};$$

$$a_2 = \frac{5}{2}\int_{-1}^{1}\frac{1}{2}(3t^2-1)\sin\pi t\,\mathrm{d}t = 0; \quad a_3 = \frac{7}{2}\int_{-1}^{1}\frac{1}{2}(5t^3-3t)\sin\pi t\,\mathrm{d}t = \frac{7}{\pi} - \frac{105}{\pi^3}.$$

Следовательно,

$$\overline{P}_3(t) = \frac{3}{\pi}L_1(t) + \left(\frac{7}{\pi} - \frac{105}{\pi^3}\right)L_3(t) = \frac{15}{2\pi}\left(\frac{21}{\pi^2}-1\right)t + \frac{35}{2\pi}\left(1-\frac{15}{\pi^2}\right)t^3.$$

Переходя к отрезку $[-\pi, \pi]$ с помощью обратной замены переменных $t = \dfrac{x}{\pi}$, получаем

$$P_3(x)=\frac{15}{2\pi^2}\left(\frac{21}{\pi^2}-1\right)x+\frac{35}{2\pi^4}\left(1-\frac{15}{\pi^2}\right)x^3\approx 0{,}8x-0{,}09x^3.$$

Многочлены Чебышева определяются соотношением

$$T_n(x)=\cos[n\cdot\arccos x],\quad n=0,1,2,\ldots \quad (4.44)$$

Введя обозначение

$$t=\arccos x,\quad (\cos t=x),\ (4.45)$$

и используя метод математической индукции, можно показать, что $T_n(x)$ – многочлен степени n, а его старший коэффициент равен 2^{n-1} ($n\geq 1$).

Из тождества

$$\cos(n+1)t=2\cos t\cos nt-\cos(n-1)t,$$

где t определяется заменой (4.45), в соответствии с формулой (4.44) получаем рекуррентное соотношение для многочленов Чебышева:

$$T_{n+1}(x)=2xT_n(x)-T_{n-1}(x),\qquad n=1,\ 2,\ \ldots$$

Первые четыре многочлена Чебышева имеют вид

$$T_0(x)=1;\ \ T_1(x)=x;\ \ T_2(x)=2x^2-1;\ \ T_3(x)=4x^3-3x.$$

Покажем, что многочлены Чебышева образуют ортогональную систему на интервале [–1,1] со скалярным произведением

$$\langle T_n,T_m\rangle=\int_{-1}^{1}T_n(x)\cdot T_m(x)\frac{1}{\sqrt{1-x^2}}\,\mathrm{d}x,$$

где $\frac{1}{\sqrt{1-x^2}}$ – весовая функция. Вычислим это скалярное произведение

$$\langle T_n,T_m\rangle=\int_{-1`}^{1}\cos(n\arccoc x)\cdot\cos(m\arccoc x)\frac{1}{\sqrt{1-x^2}}\,\mathrm{d}x=\left|\begin{matrix}u=\arccos x\\ \mathrm{d}u=\dfrac{\mathrm{d}x}{\sqrt{1-x^2}}\end{matrix}\right|=$$

$$=\int_0^{\pi}\cos nu\cdot\cos mu\,\mathrm{d}u=\frac{1}{2}\int_0^{\pi}\cos(n+m)u\,\mathrm{d}u+\frac{1}{2}\int_0^{\pi}\cos(n-m)u\,\mathrm{d}u=0,\quad n\neq m.$$

Покажем, что система многочленов Чебышева не является нормированной на интервале [–1,1].

$$\|T_n\|_{L_2}^2 = \langle T_n, T_n \rangle = \int_{-1`}^{1} \cos^2(n \operatorname{arccoc} x) \frac{1}{\sqrt{1-x^2}} \mathrm{d}x = \left| \begin{matrix} u = \arccos x \\ \mathrm{d}u = \dfrac{\mathrm{d}x}{\sqrt{1-x^2}} \end{matrix} \right| =$$

$$= \int_0^{\pi} \cos^2 nu \, \mathrm{d}u = \frac{\pi}{2} \quad (n \geq 1), \quad \|T_0\|_{L_2}^2 = \pi.$$

Пример. Для функции $f(x) = \arccos x$ построить на интервале [–1,1] МНСП, используя первые четыре многочлена Чебышева.

Решение. МНСП ищем в виде

$$P_3(x) = a_0 T_0(x) + a_1 T_1(x) + a_2 T_2(x) + a_3 T_3(x).$$

Вычисляем коэффициенты a_k, k=0, 1, 2, 3, учитывая выражение для нормы $T_k(x)$.

$$a_0 = \frac{1}{\pi} \int_{-1}^{1} \frac{\arccos x}{\sqrt{1-x^2}} \mathrm{d}x = \frac{\pi}{2};$$

$$a_k = \frac{2}{\pi} \int_{-1}^{1} \frac{\arccos x \cdot \cos(k \arccos x)}{\sqrt{1-x^2}} \mathrm{d}x = \left| \begin{matrix} u = \arccos x \\ \mathrm{d}u = \dfrac{\mathrm{d}x}{\sqrt{1-x^2}} \end{matrix} \right| =$$

$$= \frac{2}{\pi} \int_0^{\pi} u \cos ku \, \mathrm{d}u = -\frac{2}{\pi k} \int_0^{\pi} \sin ku \, \mathrm{d}u = \frac{2}{\pi} \cdot \frac{(-1)^k - 1}{k^2}, \; k = 1, 2, 3.$$

Откуда получаем $a_1 = -\dfrac{4}{\pi}$; $a_2 = 0$; $a_3 = -\dfrac{4}{9\pi}$.

Таким образом,

$$P_3(x) = \frac{\pi}{2} - \frac{4}{\pi} T_1(x) - \frac{4}{9\pi} T_3(x) = \frac{\pi}{2} - \frac{4}{\pi}\left(\frac{2}{3}x + \frac{4}{9}x^3\right).$$

Приближение функций тригонометрическими многочленами. В ряде случаев для среднеквадратичных приближений используется система функций вида $1, \cos x, \sin x, \cos 2x, \sin 2x, \ldots$. Легко проверить, что такая система тригонометрических функций ортогональна на интервале [–π,π]. Соответствующая ортонормированная система получается из исходной умножением на множители $\dfrac{1}{\sqrt{2\pi}}$ и $\dfrac{1}{\sqrt{\pi}}$:

$$\frac{1}{\sqrt{2\pi}}, \frac{\cos x}{\sqrt{\pi}}, \frac{\sin x}{\sqrt{\pi}}, \frac{\cos 2x}{\sqrt{\pi}}, \frac{\sin 2x}{\sqrt{\pi}}, \ldots.$$

Из теории рядов Фурье [9] известно, что обе системы являются полными тригонометрическими системами в пространстве $L_2(-\pi, \pi)$. Следовательно, для заданной функции f из $L_2(-\pi, \pi)$ аппроксимирующий тригонометрический многочлен

$$P_n(x) = \frac{a_0}{2} + \sum_{k=1}^{n} (a_k \cos kx + b_k \sin kx), \quad (4.46)$$

коэффициенты которого вычисляются по формулам

$$\begin{aligned} a_k &= \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \cos kx \mathrm{d}x, \quad k = 0,1,2,\ldots, \\ b_k &= \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \sin kx \mathrm{d}x, \quad k = 1,2,\ldots, \end{aligned} \quad (4.47)$$

является МНСП, т.е. погрешность

$$\rho^2(f, P_n)_{L_2} = \int_{-\pi}^{\pi} [f(x) - P_n(x)]^2 \mathrm{d}x$$

минимальна. Многочлен (4.46) представляет собой часть известного тригонометрического ряда Фурье, формулы (4.47) находятся в полном соответствии с формулами (4.39).

Пример. Получить для функции $y=x+1$ на интервале [0,2] МНСП с использованием системы функций $1, \cos x, \sin x, \cos 2x, \sin 2x$.

Решение. Аппроксимирующий многочлен будем искать в виде

$$P_2(x) = \frac{a_0}{2} + \sum_{k=1}^{2} (a_k \cos kx + b_k \sin kx).$$

Посредством замены переменных

$$Y=(y-2)\pi, \; X=(x-1)\pi$$

приведем функцию $y=x+1$ к функции $Y=X$, заданной на интервале $[-\pi,\pi]$. Обозначим аппроксимирующий многочлен для функции $Y(X)$ через $\overline{P}_2(X)$. Вычислим по формулам (4.47) коэффициенты a_k, b_k, $k=0, 1, 2$.

$$a_0 = a_1 = a_2 = 0;$$

$$b_1 = \frac{1}{\pi} \int_{-\pi}^{\pi} x \sin x \mathrm{d}x = \frac{2}{\pi} \int_{0}^{\pi} x \sin x \mathrm{d}x = 2;$$

$$b_2 = \frac{1}{\pi} \int_{-\pi}^{\pi} x \sin 2x \mathrm{d}x = \frac{2}{\pi} \int_{0}^{\pi} x \sin 2x \mathrm{d}x = -1.$$

Следовательно, $\overline{P}_2(X) = 2\sin X - \sin 2X$. Выполняя обратную замену переменных, получим искомое приближение (рис. 4.6)

$$P_2(x) = 2 - \frac{2}{\pi}\left(\sin \pi x + \frac{1}{2}\sin 2\pi x\right).$$

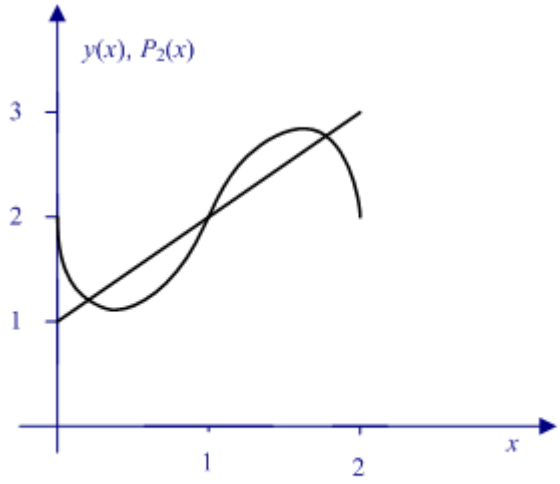

Рис. 4.4. Приближение функции $y=x+1$ многочленом $P_2(x)$

Библиографический список

1. Березин И.С., Жидков Н.П. Методы вычислений. Т.1 – М: Физматгиз, 1962. – 465 с.

2. Бахвалов Н.С., Жидков Н.П., Кобельков Г. М. Численные методы. – М: Лаборатория Базовых Знаний, 2001. – 632 с.

3. Волков Е.А. Численные методы. – М: Наука, 2006. – 256 с.

4. Фарафонов В.Г. Численные методы решения систем линейных и нелинейных уравнений: Текст лекций/СЛИАП. Л., 1992. – 34 с.

5. Завьялов Ю.С., Квасов Б.И., Мирошниченко В.Л. Методы сплайн-функций. – М.: Наука, 1980. – 350 с.

6. Фаддеев Д.К., Фаддеева В.И. Вычислительные методы линейной алгебры. – М: Физматгиз, 1963. – 502 с.

7. Дьякова Г.Н., Решетов Л.А., Стрепетов А.В. Вычислительная математика: Программа и методические указания к выполнению контрольных работ/ГУАП. СПб., 2004. – 26 с.

8. Линник А.Е. Метод наименьших квадратов. – М.: Наука, 1980. – 201 с.

9. Демидович Б.П., Марон И.А. Основы вычислительной математики. – М.: Наука, 2006. – 672 с.

Оглавление

Предисловие 1
1. АНАЛИТИЧЕСКИЕ ОСНОВЫ ЧИСЛЕННЫХ МЕТОДОВ 2
1.1 Погрешности численного решения 3
1.2 Метрическое пространство. 4
1.3 Линейное нормированное пространство. 5
1.4. Вычислительные погрешности 7
1.5 Пространство со скалярным произведением 9
1.6 Полнота метрических пространств 11
2. ЧИСЛЕННЫЕ МЕТОДЫ ЛИНЕЙНОЙ АЛГЕБРЫ 14
2.1 Норма и число обусловленности матрицы 16
2.2 Прямые методы решения систем алгебраических уравнений 22
2.3 Итерационные методы решения систем линейных алгебраических уравнений. 31
2.4 Решение систем уравнений с матрицами специального вида (трехдиагональные матрицы) 34
2.5 Методы решения проблемы собственных значений и собственных векторов матриц ... 37
3. ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ АЛГЕБРАИЧЕСКИХ УРАВНЕНИЙ ВЫСШИХ ПОРЯДКОВ И ТРАНСЦЕНДЕНТНЫХ УРАВНЕНИЙ. 45
3.1 Устойчивые решения, число обусловленности функции одной переменой. 46
3.2 Отделение корней 48
3.3 Методы уточнения корней уравнения 49
4. ЧИСЛЕННЫЕ МЕТОДЫ ПРИБЛИЖЕНИЯ ФУНКЦИЙ 53
4.1 Интерполяция функций 56
4.2 Аппроксимация функций в среднеквадратичной метрике. 69
Библиографический список 83