ГУАП

КАФЕДРА № 43

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ

ПРЕПОДАВАТЕЛЬ

старший преподаватель		М.Д. Поляк
должность, уч. степень, звание	подпись, дата	инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №1

Знакомство с Jupyter Notebook

по курсу: ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ ГР. №	4236		А.В. Панченко
		подпись, дата	инициалы, фамилия

Санкт-Петербург 2025

Цель работы:

Знакомство со средами Jupyter Notebook и Google Colaboratory, а также библиотеками Pandas и matplotlib.

Задание:

Задание 1

Откройте Jupyter-ноутбук jupyter_assignment.ipynb в этом репозитории. Скопируйте путь в адресной строке браузера. Перейдите в Google Colab, в меню выберите "Файл" -> "Открыть ноутбук", в открывшемся окне слева выбрать "GitHub", затем:

- вставить в поле для поиска скопированный URL;
- поставить галочку "Показывать личные хранилища" ("Include private repos");
- и нажать на иконку с лупой. При необходимости разрешить Colab доступ к аккаунту GitHub, если откроется новое окно с таким приглашением. Среди результатов поиска выбрать jupyter_assignment.ipynb и приступить к выполнению задания.

Задание 2

Откройте в Google Colab Jupyter-ноутбук matplotlib_assignment.ipynb, ознакомьтесь с его содержимым и выполните задание.

Задание 3

Откройте в Google Colab Jupyter-ноутбук pandas_assignment.ipynb, ознакомьтесь с его содержимым и выполните задание.

Результат выполнения работ:

(сокращенно - Colab). Открыть ознакомительный ноутбук в Colab можно перейдя по ссылке `https://colab.research.google.com/github/<ORGANIZATION>/<REPOSITORY>/blob/main/introduction_and_overview.ipynb`, где `<ORGANIZATION>` необходимо заменить на название организации на GitHub, используемой в этом курсе (это упомянутое выше "сокращенное название курса"), а `<REPOSITORY>` - заменить на название личного репозитория студента (`<assignment_name>-<username>` выше). Следуйте инструкциям в ознакомительном ноутбуке, чтобы настроить свою учетную запись Google Colaboratory.

Измените код в следующей ячейке, чтобы указать, что вы изучили ознакомительный ноутбук, прочитали о работе ноутбуков Jupyter/Colaboratory, настроили свою учетную запись Google Colaboratory и настроили свою учетную запись на GitHub. Вам нужно изменить каждую переменную с `False` на `True`, чтобы показать, какие задачи вы выполнили (по самоотчету). Также обновите переменную `github_username`, чтобы указать свое имя пользователя на GitHub.

```
[ ] ### BEGIN YOUR CODE
    #I have read through the Introduction and Overview notebook
    READ_INTRODUCTION = True

    #I understand (at a high level) what Jupyter notebooks are and how to read and
    #interact with them (or I have been in touch with the course instructor to ask for help)
    LEARNED_ABOUT_JUPYTER = True

    #I've created (or already have) a Google account and can access Google
    #Colaboratory under my own account
    ACCESS_COLABORATORY = True

    #I've created a GitHub account
    CREATED_GITHUB_ACCOUNT = True
    github_username = 'Oblachko-Js'

    #My info
    my_name = 'Andrey'
    ### END YOUR CODE
```

Функция `print` может использоваться как для отображения результатов вычислений, так и для отладки кода. Один из базовых подходов к отладке кода в Jupyter-ноутбуке — периодически выводить диагностические сообщения с помощью `print`, чтобы понять, что происходит в конкретном месте кода.

Самый простой способ использования функции `print` — вызвать `print(...)`, заменив "`...`" на текст, который необходимо вывести. Текст должен быть заключен в одинарные (`'`) или двойные (`"`) кавычки, вот так:

```
print('Hello, world!')
```

Измените код в следующей ячейке, чтобы вывести приветствие себе (например, `"Hello, Noname!"` или что-то в этом роде, заменив `"Noname"` на ваше собственное имя, заданное в предыдущей ячейке). Проверьте результат, нажав shift + enter, чтобы выполнить код в ячейке. Приветствие появится под ячейкой с кодом.

```
def greet(name):
  ### BEGIN YOUR CODE
  return f"Hello, {name}!"
  ### END YOUR CODE
```

```
Hello, Andrey!
```

Объявление функций

Внесите небольшое изменение в программу "Привет, мир!" выше. Вместо того чтобы выводить приветствие, напишите функцию, которая принимает ваше имя `name` в качестве входного параметра и возвращает строку `'Hello, <name>!'`, заменяя `<name>` на то, что указал вызвавший функцию пользователь.

```
[ ] ### BEGIN YOUR CODE
    print(greet("Andrey"))
    ### END YOUR CODE
```

```
[ ] import numpy as np
    from matplotlib import pyplot as plt
```

Перейдите по ссылке из личного кабинета на Google Таблицу со списком студентов. Найдите свое ФИО в списке и запомните соответствующий порядковый номер (поле `№ п/п`) в первом столбце. Заполните его в ячейке ниже и выполните ячейку. Если вы не можете найти себя в списке, обратитесь к преподавателю, принимающему лабораторные работы.

```
### BEGIN YOUR CODE

Student_ID = 18

### END YOUR CODE
```

Теперь выполните следующую ячейку. Она вычислит номер задания и выведет его.

```
[ ] task_id = None if Student_ID is None else Student_ID % 25 if Student_ID % 25 > 0 else 25
    print(f"Пожалуйста, используйте математическую функцию No {task_id} ниже.")
```

```
Пожалуйста, используйте математическую функцию No 18 ниже.
```

$$y = a\cos(bx + c)$$

Часть 2. Вычисления в Python

Напишите функцию на Python, которая вычисляет математическую функцию $y(x)$ с заданными скалярными параметрами a, b, c, d (если применимо) и списком значений независимой переменной x. Найти математические функции, доступные в библиотеке `numpy`, можно здесь.

Пример для функции $y(x) = a\sin^2 x + b\log_c x$ может выглядеть так:

```
def my_function(x,a,b,c,d):
    return a * np.sin(x) ** 2 + b * np.log(x) / np.log(c)
```

```
def my_function(x,a,b,c,d):
  ### BEGIN YOUR CODE
  return a * np.cos(b * x + c)
  ### END YOUR CODE
```

Задайте значения для параметров a, b, c, d и укажите диапазон для переменной x:

```
[ ] ### BEGIN YOUR CODE

    a = 2
    b = 2
    c = 2
    d = 2
    x = np.linspace(0, 10, 100)

    ### END YOUR CODE
```

```python
y = my_function(x, a, b, c, d)

# Строим график
plt.figure(figsize=(10, 5))
plt.plot(x, y, label=r'$y = a \cos(bx + c)$', color='red', linestyle='--', linewidth=2)

# Добавляем подписи, заголовок и сетку
plt.xlabel('x', fontsize=12)
plt.ylabel('y', fontsize=12)
plt.title('График функции $y = a \cos(bx + c)$', fontsize=14)
plt.legend()
plt.grid(True, linestyle='--', alpha=0.6)

### END YOUR CODE
```

```python
[ ] rng = np.random.RandomState(Student_ID)
    vector_a = rng.choice(np.arange(100, dtype=np.int32), size=(1,5), replace=False)
    vector_b = rng.choice(np.arange(100, dtype=np.int32), size=(5,1), replace=False)

    ### BEGIN YOUR CODE

    dot_product = np.dot(vector_a, vector_b)

    ### END YOUR CODE

    print(f'Вектор A: {vector_a}\nВектор B: {vector_b}\nСкалярное произведение <A, B>={dot_product}')
```

```
Вектор A: [[53 47 43 54 33]]
Вектор B: [[83]
 [69]
 [63]
 [96]
 [77]]
Скалярное произведение <A, B>=[[18076]]
```

```
### BEGIN YOUR CODE

Student_ID = 18

### END YOUR CODE
```

+ Код + Текст

Теперь выполните следующую ячейку. Она вычислит номер задания и выведет его.

```
[ ] datasets = [('Chipotle','https://raw.githubusercontent.com/justmarkham/DAT8/master/data/chipotle.tsv'), ('US Air Carrier market in 2019','https://raw.githubuse

    dataset_id = None if Student_ID is None else Student_ID % len(datasets)
    if dataset_id is None:
        print("ОШИБКА! Не указан порядковый номер студента в списке группы.")
    else:
        print(f"Датасет '{datasets[dataset_id][0]}' доступен по следующей ссылке: {datasets[dataset_id][1]}")
        print(f"В заданиях ниже, где нужно выбрать вопрос, всегда выбирайте вопрос № {dataset_id+1}")
```

```
Датасет 'Chipotle' доступен по следующей ссылке: https://raw.githubusercontent.com/justmarkham/DAT8/master/data/chipotle.tsv
В заданиях ниже, где нужно выбрать вопрос, всегда выбирайте вопрос № 1
```

Скачайте датасет с помощью команды `!wget <dataset_url>`, где `<dataset_url>` необходимо заменить на ссылку на датасет, появившуюся после выполнения предыдущей ячейки. При необходимости разархивируйте датасет, используя команды `!unzip`, `!tar` и др.

Примечание: в Jupyter-ноутбуке можно использовать любые команды командного интерпретатора bash. Для этого необходимо поставить в ячейке с кодом восклицательный знак `!`, после которого записать команду bash со всеми необходимыми аргументами. Результат выполнения этой команды bash будет возвращен в Jupyter и его можно использовать в коде на Python.

```
[ ] ### BEGIN YOUR CODE

    !wget https://raw.githubusercontent.com/justmarkham/DAT8/master/data/chipotle.tsv
```

```
[ ] import pandas as pd

    # Загрузим датасет в pandas DataFrame
    df = pd.read_csv('chipotle.tsv', sep='\t')

    # Преобразуем названия столбцов в нижний регистр
    df.columns = df.columns.str.lower()
```

3. Какие столбцы присутствуют в наборе данных? (0.1 балла)

```
# Получаем список столбцов
columns = df.columns

print(columns)
```

```
Index(['order_id', 'quantity', 'item_name', 'choice_description',
       'item_price'],
      dtype='object')
```

4. Ответьте на вопрос и сохраните ответ в переменной `answer1` (0.1 балла)

Вопросы:

1. Какое блюдо (`item_name`) заказывали чаще всего?
2. Сколько авиаперевозчиков (`carrier`) представлены в датасете?
3. По скольким продуктам в датасете имеется информация о содержании аллергенов (`allergens`)?

```
[ ] most_ordered_item = df['item_name'].value_counts().idxmax()

    answer1 = most_ordered_item

    print(answer1)
```

5. Ответьте на вопрос и сохраните ответ в переменной `answer2` (0.1 балла)

Вопросы:

1. Сколько всего было заказов блюда, название которого сохранено в `answer1`?
2. Посчитайте общие суммарные количества перевезенных пассажиров (`passengers`), фунтов груза (`freight`) и почты (`mail`) на маршруте из Великобритании (GB) в США (US). В `answer2` запишите максимальное из трех получившихся чисел.
3. Сколько всего продуктов, относящихся к категории "молочные" (`Dairies,Milks`), с заполненным названием?

```
[ ] order_count = df[df['item_name'] == most_ordered_item]['quantity'].sum()

    answer2 = order_count

    print(answer2)
```

```
761
```

6. Ответьте на вопрос и сохраните ответ в переменной `answer3` (0.2 балла)

Вопросы:

1. Какой доход получила сеть Chipotle Mexican Grill на заказах, попавших в датасет?
2. Какой авиаперевозчик (`unique_carrier_name`) перевез больше всего груза (`mail` + `freight`)?
3. Как называется продукт категории `Fats` с максимальной жирностью, не превышающей 30 г на 100 г продукта?

```
[ ] df['item_price'] = df['item_price'].replace({'\$': '', ',': ''}, regex=True).astype(float)

    total_income = (df['quantity'] * df['item_price']).sum()

    answer3 = total_income

    print(answer3)
```

3. Какова энергетическая ценность в кДж продукта из России (`countries_en`) имеющего максимальное содержание холестерина?

```
[ ] total_income = (df['quantity'] * df['item_price']).sum()

    unique_orders = df['order_id'].nunique()

    answer4 = total_income / unique_orders

    print(answer4)
```

```
21.39423118865867
```

8. Ответьте на вопрос и сохраните ответ в переменной `answer5` (0.25 балл)

Вопросы:

1. Сколько раз был заказан самый популярный напиток (Coke, Sprite, Mountain Dew и т.п.)?
2. Между какими двумя городами было перевезено наибольшее количество пассажиров? Учтите оба направления. Ответ запишите в виде списка из двух строк.
3. Приведите названия всех аллергенов к нижнему регистру. Какой аллерген встречается в продуктах чаще всего?

```
[ ] drinks = ['Coke', 'Sprite', 'Mountain Dew', 'Izze', 'Nantucket Nectar']
    df_drinks = df[df['choice_description'].str.contains('|'.join(drinks), na=False)]

    most_popular_drink_count = df_drinks['quantity'].sum()

    answer5 = most_popular_drink_count

    print(answer5)
```

```
409
```

9. Ответьте на вопрос и сохраните ответ в переменной `answer6` (0.5 балл)

Вопросы:

1. Какой суммарный доход принесли напитки в заказах вегетарианцев?
2. Для пары городов из предыдущего вопроса найдите 3 авиакомпании, которые перевезли больше всего пассажиров. Посчитайте, какой процент от общего пассажиропотока между этими городами перевезла каждая из трех авиакомпаний. В `answer6` запишите найденные проценты в виде списка из трех чисел, округлив их до двух знаков после запятой.
3. Найдити самый опасный продукт, содержащий наибольшее количество аллергенов.

```
drinks = ['Coke', 'Sprite', 'Mountain Dew', 'Izze', 'Nantucket Nectar']

df_drinks = df[df['choice_description'].str.contains('|'.join(drinks), na=False)]

df_vegetarian = df[df['item_name'].str.contains('Vegetarian|Rice|Beans|Cheese|Guacamole|Lettuce', na=False)]

df_vegetarian_drinks = df_drinks[df_drinks['order_id'].isin(df_vegetarian['order_id'])]

df_vegetarian_drinks = df_vegetarian_drinks.copy()

df_vegetarian_drinks['item_price'] = df_vegetarian_drinks['item_price'].replace({'\$': '', ',': ''}, regex=True).astype(float)

total_income_vegetarian_drinks = (df_vegetarian_drinks['quantity'] * df_vegetarian_drinks['item_price']).sum()

answer6 = total_income_vegetarian_drinks

print(answer6)
```

```
346.42
```

10. Ответьте на вопрос и сохраните ответ в переменной `answer7` (0.5 балл)

Вопросы:

1. Сколько было сделано вегетарианских заказов? Заказ не считается вегетарианским, если в нем были не вегетарианские блюда.
2. Для каждой страны найдите процент международного пассажиропотока (относительно США), используя общее количество пассажиров на рейсах класса F. В `answer7` запишите название страны с третьим по величине пассажиропотоком в/из США.
3. Переведите названия групп продуктов (`pnns_groups_1`, `pnns_groups_2`) в нижний регистр. В переменную `answer7` запишите список, содержащий три элемента: название группы продуктов 1, название группы продуктов 2 и среднее количество пищевых волокон (fiber) для седьмой по насыщенности пищевыми волокнами группы продуктов.

```
vegetarian_items = ['Chips', 'Fresh Tomato Salsa', 'Guacamole', 'Lettuce', 'Rice', 'Black Beans', 'Pinto Beans', 'Cheese', 'Veggie']

def is_vegetarian(order_items):
    non_vegetarian_keywords = ['Chicken', 'Steak', 'Carnitas', 'Barbacoa']

    for item in order_items:
        if any(keyword in item for keyword in non_vegetarian_keywords):
            return False
    return True

vegetarian_orders = df.groupby('order_id')['item_name'].apply(list).apply(is_vegetarian)

answer7 = vegetarian_orders.sum()

print(answer7)
```

```
90
```

11. Ответьте на вопрос и сохраните ответ в переменной `answer8` (1 балл)

11. Ответьте на вопрос и сохраните ответ в переменной `answer8` (1 балл)

Вопросы:

1. Какой соус или дополнительный ингредиент по выбору (`choice_description`) чаще всего берут вместе с буррито с курицей (Chicken Burrito)?
2. В каком месяце пассажиропоток между городами, записанными в переменную `answer5`, был максимальным?
3. Какое название у группы продуктов `pnns_groups_2`, являющейся наиболее сбалансированной с точки зрения среднего содержания белков, жиров и углеводов? Под "сбалансированной" понимать близость БЖУ к пропорции 1:1:4.

```
chicken_burrito_orders = df[df['item_name'] == 'Chicken Burrito']

choice_descriptions = chicken_burrito_orders['choice_description']

from collections import Counter

ingredients = []

for description in choice_descriptions:
    if isinstance(description, str):
        description = description.strip('[]').split(', ')
    ingredients.extend(description)

most_common_ingredient = Counter(ingredients).most_common(1)[0][0]

answer8 = most_common_ingredient

print(answer8)
```

```
Cheese
```

```
import matplotlib.pyplot as plt

df['total_order_price'] = df['quantity'] * df['item_price'].replace({'\$': '', ',': ''}, regex=True).astype(float)

plt.figure(figsize=(10, 6))
plt.hist(df['total_order_price'], bins=20, color='skyblue', edgecolor='black', alpha=0.7)

mean_order_price = df['total_order_price'].mean()
median_order_price = df['total_order_price'].median()

plt.axvline(mean_order_price, color='red', linestyle='dashed', linewidth=2, label=f'Средний чек: ${mean_order_price:.2f}')
plt.axvline(median_order_price, color='green', linestyle='dashed', linewidth=2, label=f'Медианная стоимость: ${median_order_price:.2f}')

plt.title('Распределение общей стоимости заказов')
plt.xlabel('Стоимость заказа ($)')
plt.ylabel('Частота')
plt.legend()
```

```
<matplotlib.legend.Legend at 0x79bbc12e2990>
```

Выводы:

В ходе работы мы познакомились с рабочими средами Jupyter Notebook и Google Colaboratory, которые позволяют эффективно выполнять код и анализировать данные в интерактивном режиме. Мы освоили использование библиотеки Pandas для работы с табличными данными, включая загрузку, обработку и анализ данных, а также применение matplotlib для визуализации информации. В процессе выполнения задач мы научились манипулировать данными, производить необходимые вычисления и строить графики, что позволило глубже понять анализ данных и научиться работать с реальными набором данных.