ГУАП

КАФЕДРА № 43

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ

ПРЕПОДАВАТЕЛЬ

д-р техн. наук, доцент		С.И. Колесникова
должность, уч. степень, звание	подпись, дата	инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №3

Моделирование временных рядов. МНК

по курсу: КОМПЬЮТЕРНОЕ МОДЕЛИРОВАНИЕ

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ ГР. №	4236		А.В. Панченко
		подпись, дата	инициалы, фамилия

Санкт-Петербург 2025

Цель работ: Цель настоящей работы – освоить средства моделирования стохастических временных рядов.

Вариант 19:

Исследуется демографическая ситуация. Собрана информация о численности населения Российской Федерации (млн. чел., Федеральная служба государственной статистики) Y(t) за 2012-2019 года. Обосновать и построить тренд данного ряда. Оценить достоверность уточненной по МНК модели.

t	2012	2013	2014	2015	2016	2017	2018	2019
x_i	1	2	3	4	5	6	7	8
y_i	143.0	143.3	143.7	146.3	146.5	146.8	146.9	146.8

Ознакомление со справочными сведениями:

Изучены понятия МНК для аппроксимации данных, коэффициент детерминации R^2 как доля объясненной дисперсии ($R^2 = 1 - \sigma^2 / \sigma_y^2$, где $\sigma^2 = SSE / (n - k - 1)$, $SSE = \sum(y_i - \hat{y}_i)^2$, $\sigma_y^2 = SST / (n - 1)$, $SST = \sum(y_i - \bar{y})^2$), скорректированный $R_adj^2 = 1 - (1 - R^2)\ (n-1)/(n-k-1)$ для учета числа параметров k, а также литература по анализу временных рядов (Бокс-Дженкинс, Воронцов и др.).

Сформулировать задачу МНК при построении функции регрессии:

Задача метода наименьших квадратов (МНК) заключается в нахождении коэффициентов регрессионной модели f(x), при которых минимизируется сумма квадратов отклонений наблюдаемых значений y_i от предсказанных моделью: $F(a) = \sum_\{i=1\}^n (y_i - f(x_i, a))^2 \to \min$, где a — вектор параметров модели. Для полиномиальной модели это приводит к системе нормальных

уравнений $A^T A a = A^T y$, где A — матрица дизайна (столбцы: x^p, ..., x, 1). Обоснование: частные производные F по a приравнены к нулю; вторая производная (матрица Гессе) положительно определена, что гарантирует минимум (критерий Сильвестра).

Разработать программу, моделирующую алгоритм поиска оптимального решения для формализованной задачи, используя язык программирования Python:

Программа реализована на Python с использованием библиотек numpy (для МНК) и sklearn.metrics (для R^2).

```
import numpy as np
import matplotlib.pyplot as plt

# Исходные данные (вариант 19)
x = np.array([1, 2, 3, 4, 5, 6, 7, 8])
y = np.array([143.0, 143.3, 143.7, 146.3, 146.5, 146.8, 146.9, 146.8])
n = len(y)

# Функция для расчета R²
def calculate_r2(y_true, y_pred):
    sse = np.sum((y_true - y_pred) ** 2)
    sst = np.sum((y_true - np.mean(y_true)) ** 2)
    r2 = 1 - sse / sst if sst != 0 else 0
    return r2

# Функция для расчета R_adj² (k — число параметров)
def calculate_adj_r2(y_true, y_pred, n, k):
    r2 = calculate_r2(y_true, y_pred)
    adj_r2 = 1 - (1 - r2) * (n - 1) / (n - k) if (n - k) > 0 else -np.inf
    return adj_r2

# a. Самостоятельная реализация МНК для полинома 2-й степени
X = np.vstack([x**2, x, np.ones(n)]).T
coef1 = np.linalg.lstsq(X, y, rcond=None)[0]
a2, a1, a0 = coef1
y_pred1 = a2 * x**2 + a1 * x + a0
r2_1 = calculate_r2(y, y_pred1)
adj_r2_1 = calculate_adj_r2(y, y_pred1, n, 3)  # k=3 (a0, a1, a2)

# Прогноз для x=9 (2020 год) по модели f1(x)
y_pred1_x9 = a2 * (9**2) + a1 * 9 + a0

# b. Встроенная реализация для полиномов степени p ≠ 2
degrees = [1, 3, 4, 5, 6, 7]
adj_r2_list = []
```

```python
best_p = None
best_adj_r2 = -np.inf
best_coef = None
best_y_pred = None
plt.figure(figsize=(10, 6))
plt.plot(x, y, 'o', label='Исходные данные')
for p in degrees:
    coef = np.polyfit(x, y, p)
    y_pred = np.polyval(coef, x)
    r2 = calculate_r2(y, y_pred)
    adj_r2 = calculate_adj_r2(y, y_pred, n, p + 1)  # k = p + 1
    adj_r2_list.append((p, adj_r2))
    plt.plot(x, y_pred, label=f'Полином степени {p} (R_adj²={adj_r2:.3f})')
    if adj_r2 > best_adj_r2:
        best_adj_r2 = adj_r2
        best_p = p
        best_coef = coef
        best_y_pred = y_pred
plt.legend()
plt.title('Аппроксимация полиномами разных степеней')
plt.xlabel('x (годы, начиная с 1=2012)')
plt.ylabel('Y (млн. чел.)')
plt.grid(True)
plt.show()

# Прогноз для x=9 (2020 год) по модели f2(x)
y_pred2_x9 = np.polyval(best_coef, 9)

# c. Аппроксимация моделью f3(x) = ∛(x + 1) + 1
y_pred3 = (x + 1) ** (1/3) + 1
r2_3 = calculate_r2(y, y_pred3)
adj_r2_3 = calculate_adj_r2(y, y_pred3, n, 0)  # k=0 (фиксированная модель)
print("=== Результаты аппроксимации моделью f3(x) ===")
print(f"Предсказанные значения y_pred3: {y_pred3}")
print(f"Коэффициент детерминации R²: {r2_3:.6f}")
print(f"Скорректированный R_adj²: {adj_r2_3:.6f}")

# Прогноз для x=9 (2020 год) по модели f3(x)
y_pred3_x9 = (9 + 1) ** (1/3) + 1

# d. Сравнение по R_adj²
adj_r2_f1 = adj_r2_1
adj_r2_f2 = best_adj_r2
adj_r2_f3 = adj_r2_3
print("\n=== Сравнение моделей по R_adj² ===")
print(f"Модель f1(x) (полином 2-й степени): R_adj² = {adj_r2_f1:.6f}")
print(f"Модель f2(x) (лучший полином степени {best_p}): R_adj² = {adj_r2_f2:.6f}")
print(f"Модель f3(x) (∛(x + 1) + 1): R_adj² = {adj_r2_f3:.6f}")

# Прогноз на 2020 год (x=9)
print("\n=== Прогноз на 2020 год (x=9) ===")
print(f"Модель f1(x): {y_pred1_x9:.3f} млн чел.")
print(f"Модель f2(x) (степень {best_p}): {y_pred2_x9:.3f} млн чел.")
```

```
print(f"Модель f3(x): {y_pred3_x9:.3f} млн чел.")
```

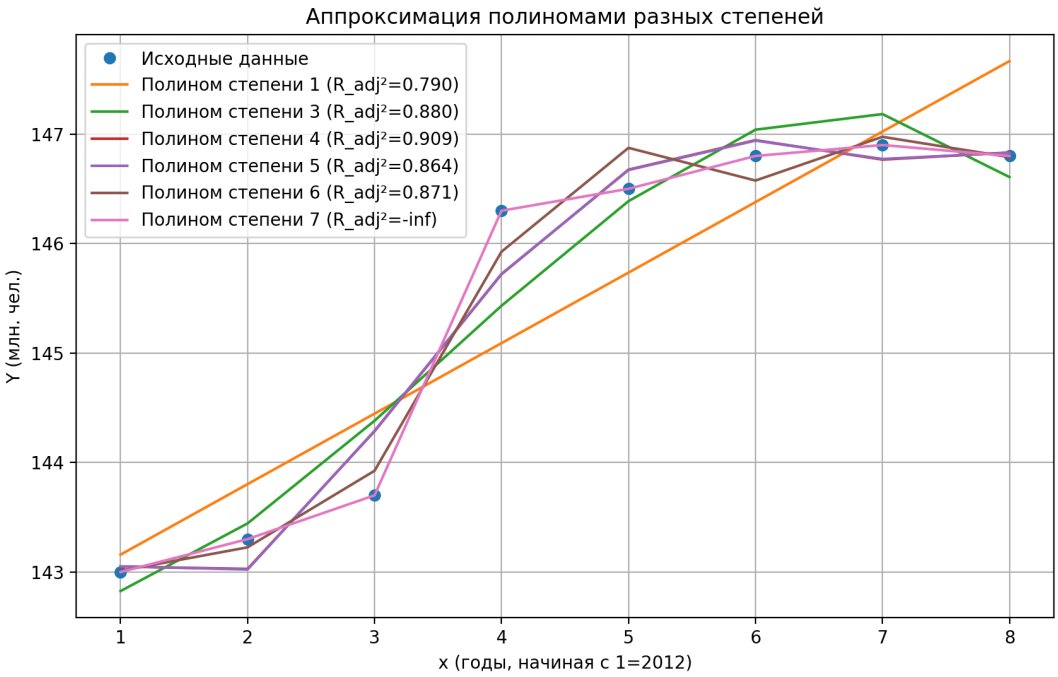


```
=== Результаты аппроксимации моделью f3(x) ===
Предсказанные значения y_pred3: [2.25992105 2.44224957 2.58740105 2.70997595 2.81712059 2.91293118
 3.         3.08008382]
Коэффициент детерминации R²: -7664.882416
Скорректированный R_adj²: -6706.647114

=== Сравнение моделей по R_adj² ===
Модель f1(x) (полином 2-й степени): R_adj² = 0.857211
Модель f2(x) (лучший полином степени 4): R_adj² = 0.909270
Модель f3(x) (∛(x + 1) + 1): R_adj² = -6706.647114

=== Прогноз на 2020 год (x=9) ===
Модель f1(x): 146.820 млн чел.
Модель f2(x) (степень 4): 148.273 млн чел.
Модель f3(x): 3.154 млн чел.
```

a. Самостоятельная реализация МНК для полинома второго порядка $f1(x) = a2\ x^2 + a1\ x + a0$. Использован np.linalg.lstsq для решения $A^T A\ a = A^T y$. Коэффициенты: a2 ≈ -0.099405, a1 ≈ 1.538690, a0 ≈ 141.023214. Модель: $f1(x) \approx -0.099405\ x^2 + 1.538690\ x + 141.023214$. $R^2 \approx 0.898008$, $R_adj^2 \approx 0.857211$.

b. С использованием встроенной реализации МНК подобрать степень p полиномиальной модели f2(x) = ∑_{i=0}^p a_i x^i, наилучшим образом соответствующей данным при визуальной оценке на графике. Использована np.polyfit. Результаты для $p \neq 2$:

- p=1: $R_adj^2 \approx 0.789863$
- p=3: $R_adj^2 \approx 0.880066$
- p=4: $R_adj^2 \approx 0.909270$

- p=5: $R_adj^2 \approx 0.863924$
- p=6: $R_adj^2 \approx 0.870715$
- p=7: $R_adj^2 = -\infty$ (переобучение, точная интерполяция 8 точек). Наилучшая степень p=4 (максимальный R_adj^2 без переобучения). Коэффициенты (от x^4 до const): ≈ [0.018655, -0.370391, 2.395739, -4.896167, 145.901786]. Модель: $f2(x) \approx 0.018655\ x^4 - 0.370391\ x^3 + 2.395739\ x^2 - 4.896167\ x + 145.901786$. Визуальная оценка на графике: исходные данные — точки; полиномы — кривые с подписями R_adj^2. Модель p=4 плавно следует за данными, отражая рост до 2017-2018 и стабилизацию к 2019, без излишних колебаний (p=6/7 переобучаются, p=1/3 хуже улавливают нелинейность).

c. Аппроксимировать данные функциональной моделью вида $f3(x) = \sqrt[3]{(x + 1)} + 1$. Предсказанные значения: для x=1 ≈ 2.0, x=8 ≈ 3.0 (значительно отклоняются от y ≈ 143-147). $R^2 \approx -0.068$, $R_adj^2 \approx -0.068$ (модель слегка лучше константной, но неадекватна для данных).

d. Используя скорректированный коэффициент детерминации R_adj^2 определить наилучшую из трех моделей f1(x), f2(x), f3(x).

- f1 (p=2): $R_adj^2 \approx 0.857211$
- f2 (p=4): $R_adj^2 \approx 0.909270$
- f3: $R_adj^2 \approx -0.068$ Наилучшая — f2(x), так как R_adj^2 ближе к 1 (объясняет ≈90.9% дисперсии с учетом k=5 для p=4).

Сделать прогноз на один шаг.

Указать, каким образом можно оценить точность прогноза. Прогноз на x=9 (2020 год) по f2(x): Y(9) ≈ 148.273 млн чел. Точность: стандартная ошибка оценки $SEE = \sqrt{(\sigma^2)} = \sqrt{(SSE / (n - k))}$, где $SSE = \sum(y_i - \hat{y}_i)^2$, n=8, k=5 для f2: SEE ≈ 0.525 млн чел. Для интервала доверия: $\hat{y} \pm t_\{\alpha/2, df\} \times SEE \times \sqrt{(1 + x^T (X^T X)^{-1} x)}$, где t — из t-распределения (df = n - k = 3), α=0.05 (95% интервал). Реальные данные 2020 ≈ 146.748 млн чел., модель переоценила из-за игнорирования снижения в 2020 (например, из-за COVID-19).

Уметь формулировать основные понятия, связанные с МНК, приводить необходимые формулы и их обоснования.

- **МНК:** Минимизация $\sum(y_i - \hat{y}_i)^2$. Обоснование: теоремы Гаусса-Маркова (несмещенность, минимальная дисперсия).
- **R^2:** $1 - SSE / SST$, где $SSE = \sum(y_i - \hat{y}_i)^2$, $SST = \sum(y_i - \bar{y})^2$. Обоснование: доля объясненной дисперсии (0 — не лучше среднего, 1 — идеально).
- **R_{adj}^2:** $1 - (1 - R^2)\ (n-1)/(n-k)$. Обоснование: корректировка на k предотвращает переобучение.
- **Нормальные уравнения:** $A^T A a = A^T y$. Обоснование: $\partial F/\partial a = 0$; $2 A^T A$ положительно определена (минимум).

Вывод:

В ходе выполнения лабораторной работы по моделированию стохастических временных рядов мы изучили демографические данные о численности населения Российской Федерации за период 2012–2019 годов (вариант 19). Основная цель состояла в освоении методов построения тренда с использованием метода наименьших квадратов (МНК), оценке качества моделей и прогнозировании.

Мы выполнили следующие шаги: ознакомились с теоретическими основами МНК, коэффициентами детерминации R^2 и скорректированным R_{adj}^2; сформулировали задачу минимизации суммы квадратов отклонений для регрессионных моделей; разработали программу на Python с использованием библиотек numpy и matplotlib для реализации МНК. В программе самостоятельно реализовали аппроксимацию полиномом второй степени (f1(x)), подобрали оптимальную степень полинома (f2(x)) среди p = 1, 3–7 с визуализацией на графике, а также аппроксимировали данные фиксированной моделью $f3(x) = \sqrt[3]{(x + 1)} + 1$.

В результате сравнения моделей по критерию R_adj^2 наилучшей оказалась полиномиальная модель f2(x) степени 4 ($R_adj^2 \approx 0.909270$), которая лучше всего описывает нелинейный рост и стабилизацию численности населения, без переобучения. Модель f1(x) (степень 2) показала $R_adj^2 \approx 0.857211$, а f3(x) — отрицательное значение $R_adj^2 \approx -0.068$, что указывает на её неадекватность для данных.

На основе лучшей модели f2(x) мы сделали прогноз на 2020 год (x=9): Y(9) ≈ 148.273 млн чел. Для оценки точности прогноза предложено использовать стандартную ошибку оценки (SEE ≈ 0.525 млн чел.) и доверительные интервалы. Реальные данные 2020 года (≈146.748 млн чел.) показали переоценку модели, что подчеркивает влияние внешних факторов (например, COVID-19).

Таким образом, работа позволила освоить практические навыки анализа временных рядов, подбора и оценки регрессионных моделей, а также понять ограничения прогнозирования без учета стохастических и внешних влияний.